


Introducción a la Probabilidad con **R** y **GeoGebra**

*Teoría, simulación y aplicaciones
para ingeniería y ciencias*

Jesús Gilberto Rodríguez Escobedo



$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$







Tabla de contenidos

Portada	16
Bienvenida	17
Presentación	18
Introducción	19
Notación general	20
1 Incertidumbre y probabilidad	21
1.1 Objetivos de aprendizaje	21
1.2 ¿Por qué necesitamos probabilidad?	21
1.3 Experimentos deterministas y aleatorios	21
1.4 Variabilidad	22
1.5 Frecuencia relativa como intuición	22
1.6 Primer experimento con R	22
1.7 Primer recurso GeoGebra	23
1.8 Aplicación de ingeniería	24
1.9 Ideas clave	24
1.10 Ejercicios	24
1.11 Materiales complementarios del capítulo	24
1.12 Referencias del capítulo	25
2 Conjuntos, espacios muestrales y eventos	26
2.1 Objetivos de aprendizaje	26
2.2 Del experimento al modelo	26
2.3 Repaso de conjuntos	27
2.3.1 Subconjuntos, igualdad y conjunto vacío	27
2.3.2 Operaciones básicas	27
2.3.3 Leyes de De Morgan	28
2.4 Espacio muestral	28
2.4.1 Ejemplo: lanzar un dado	28
2.4.2 Tipos de espacios muestrales	29

2.5	Cómo construir un espacio muestral	29
2.5.1	Enumeración directa	29
2.5.2	Tabla de doble entrada	29
2.5.3	Diagrama de árbol	30
2.6	Eventos	30
2.6.1	Clases frecuentes de eventos	31
2.7	Traducir frases a operaciones con eventos	31
2.8	Trabajo con conjuntos en R	31
2.8.1	Construcción del espacio muestral de dos dados	32
2.9	Diagrama de Venn con R sin paquetes	34
2.10	Actividad interactiva con GeoGebra	35
2.11	Aplicación: sistema de dos sensores	36
2.12	Errores frecuentes	36
2.13	Ejemplo integrador resuelto	36
2.14	Ideas clave	38
2.15	Ejercicios	38
2.15.1	Nivel básico	38
2.15.2	Nivel intermedio	38
2.15.3	R y GeoGebra	39
2.15.4	Aplicación	39
2.16	Materiales complementarios del capítulo	39
2.17	Referencias del capítulo	40
3	Técnicas de conteo y enumeración	41
3.1	Objetivos de aprendizaje	41
3.2	¿Por qué necesitamos contar?	41
3.3	Principio aditivo	42
3.3.1	Ejemplo	42
3.4	Principio multiplicativo	42
3.4.1	Ejemplo: código de identificación	43
3.5	Diagramas de árbol	43
3.5.1	Ejemplo: tres transmisiones	43
3.6	Factorial	43
3.7	Permutaciones	44
3.7.1	Ejemplo	44
3.8	Arreglos o variaciones sin repetición	44
3.8.1	Ejemplo: asignación de cargos	45
3.9	Combinaciones	45
3.9.1	Ejemplo: selección de un comité	45
3.10	Comparación rápida	45

3.11	Conteo con repetición	46
3.11.1	Ejemplo	46
3.12	Permutaciones con objetos repetidos	47
3.12.1	Ejemplo	47
3.13	Ejemplo de ingeniería: selección para inspección	47
3.14	Cálculo con R	48
3.14.1	Enumeración explícita con R	48
3.14.2	Comprobar combinaciones	49
3.15	Simulación como verificación	50
3.16	Interactivo del capítulo	50
3.17	Estrategia para decidir qué fórmula utilizar	51
3.18	Errores frecuentes	51
3.19	Ideas clave	51
3.20	Ejercicios	52
3.21	Materiales complementarios del capítulo	52
3.22	Referencias del capítulo	53
4	Axiomas y propiedades de la probabilidad	54
4.1	Objetivos de aprendizaje	54
4.2	De contar resultados a medir incertidumbre	54
4.3	Los tres axiomas fundamentales	55
4.3.1	No negatividad	55
4.3.2	Normalización	55
4.3.3	Aditividad	55
4.4	Consecuencias inmediatas	56
4.4.1	Probabilidad del evento imposible	56
4.4.2	Regla del complemento	57
4.4.3	Las probabilidades están entre 0 y 1	57
4.5	Monotonía	57
4.5.1	Ejemplo	58
4.6	Regla de la diferencia	58
4.7	Regla general de la adición	59
4.7.1	Ejemplo: fallas de manufactura	59
4.8	Exactamente uno de dos eventos	60
4.9	Tres eventos: principio de inclusión-exclusión	60
4.9.1	Ejemplo: tres alarmas	61
4.10	Asignación de probabilidades en espacios finitos	61
4.10.1	Caso equiprobable	62
4.10.2	Ejemplo: dos dados equilibrados	62
4.11	Comprobación con R	62
4.11.1	Una función para verificar coherencia	63

4.12	Simulación para comprobar una regla	64
4.13	Interactivo del capítulo	65
4.14	Actividad con GeoGebra	65
4.15	Estrategia para resolver problemas	66
4.16	Errores frecuentes	66
4.17	Resumen	66
4.18	Ejercicios	67
4.19	Materiales complementarios del capítulo	67
4.20	Referencias del capítulo	68
5	Probabilidad condicional e independencia	69
5.1	Objetivos de aprendizaje	69
5.2	Cuando aparece nueva información	69
5.3	Definición de probabilidad condicional	70
5.3.1	Ejemplo con datos de calidad	70
5.4	El orden de la condición importa	71
5.4.1	Ejemplo numérico	71
5.5	Regla del producto	72
5.6	Experimentos por etapas	72
5.6.1	Ejemplo: dos componentes sin reemplazo	72
5.7	Regla de la cadena	73
5.8	Árboles de probabilidad	74
5.9	Independencia de dos eventos	74
5.9.1	Ejemplo: dos lanzamientos de una moneda	75
5.10	Independencia no significa exclusión mutua	75
5.10.1	Ejemplo	76
5.11	Independencia y complementos	76
5.12	Con reemplazo y sin reemplazo	76
5.12.1	Con reemplazo	76
5.12.2	Sin reemplazo	77
5.13	Aplicación: confiabilidad de dos módulos	77
5.14	Aplicación: comunicaciones	78
5.15	Cálculos con R	78
5.15.1	Probabilidad condicional	78
5.15.2	Verificar independencia	78
5.16	Simulación: dependencia por muestreo sin reemplazo	79
5.17	Interactivo del capítulo	80
5.18	Actividad GeoGebra: árbol condicional	80
5.19	Estrategia de solución	81
5.20	Errores frecuentes	81
5.21	Resumen	82

5.22	Ejercicios	82
5.23	Materiales complementarios del capítulo	83
5.24	Referencias del capítulo	83
6	Particiones, probabilidad total y teorema de Bayes	84
6.1	Objetivos de aprendizaje	84
6.2	Por qué necesitamos una partición	84
6.2.1	Ejemplo: proveedores	85
6.3	Ley de la probabilidad total	85
6.4	Ejemplo: defectos por proveedor	86
6.5	De la causa al efecto y del efecto a la causa	86
6.6	Teorema de Bayes	87
6.7	Continuación del ejemplo de proveedores	88
6.8	Interpretación bayesiana elemental	88
6.9	Árbol de probabilidad	89
6.10	Ejemplo de diagnóstico	89
6.11	La importancia de la tasa base	90
6.11.1	Interpretación con 10 000 personas	90
6.12	Aplicación: detección de fallas	91
6.13	Actualización sucesiva	92
6.14	Cálculos con R	92
6.14.1	Probabilidad total	92
6.14.2	Bayes para todos los proveedores	92
6.14.3	Función general	93
6.15	Simulación de un problema de diagnóstico	93
6.16	Interactivo del capítulo	94
6.17	Actividad con GeoGebra	94
6.18	Estrategia para resolver problemas de Bayes	95
6.19	Errores frecuentes	96
6.20	Resumen	96
6.21	Ejercicios	96
6.22	Materiales complementarios del capítulo	97
6.23	Referencias del capítulo	98
7	Variable aleatoria y función de distribución acumulada	99
7.1	Objetivos de aprendizaje	99
7.2	Del resultado del experimento a un número	99
7.3	Ejemplo: dos lanzamientos de moneda	100
7.4	Preimagen de un evento numérico	101
7.5	Variables discretas y continuas	101
7.5.1	Variable aleatoria discreta	101

7.5.2	Variable aleatoria continua	102
7.6	Función de distribución acumulada	102
7.7	CDF del ejemplo de las dos monedas	102
7.8	Propiedades fundamentales de la CDF	103
7.9	Probabilidades de intervalos usando la CDF	104
7.9.1	Intervalo de la forma $(a, b]$	104
7.9.2	Probabilidad de exceder un valor	104
7.9.3	Probabilidad de un punto	104
7.10	Ejemplo de ingeniería	104
7.11	Construcción con R	105
7.12	Simulación y CDF empírica	106
7.13	Variable aleatoria como transformación	107
7.14	Interactivo del capítulo	108
7.15	Actividad con GeoGebra	108
7.16	Materiales complementarios del capítulo	109
7.17	Errores frecuentes	110
7.18	Resumen	110
7.19	Ejercicios	110
7.20	Referencias del capítulo	111
8	Variables aleatorias discretas y función de masa de probabilidad	112
8.1	Objetivos de aprendizaje	112
8.2	De la variable aleatoria a su distribución	112
8.3	Variable aleatoria discreta	113
8.4	Función de masa de probabilidad	113
8.5	Ejemplo: tres lanzamientos de moneda	114
8.6	Calcular probabilidades con una PMF	114
8.6.1	Ejemplo	115
8.7	Construcción de una distribución a partir de una constante	115
8.8	Probabilidades mediante complemento	116
8.9	Representación gráfica de la PMF	116
8.9.1	R: gráfica de una PMF	116
8.10	Relación entre PMF y CDF	117
8.11	Recuperar la PMF desde la CDF	118
8.12	Ejemplo de ingeniería: número de sensores activos	118
8.13	Ejemplo: número de retransmisiones	119
8.14	Construcción y cálculo en R	119
8.15	CDF a partir de una PMF en R	120
8.16	Simulación desde una PMF	121
8.17	Comparación entre distribución teórica y empírica	122
8.18	Interactivo del capítulo	123

8.19	Actividad con GeoGebra	123
8.20	Validación de una PMF	124
8.20.1	Ejemplo de función inválida	124
8.21	Errores frecuentes	124
8.22	Resumen	125
8.23	Ejercicios	125
8.24	Materiales complementarios del capítulo	126
8.25	Referencias del capítulo	127
9	Variables aleatorias continuas y función de densidad	128
9.1	Objetivos de aprendizaje	128
9.2	De los conteos a las mediciones	128
9.3	Variable aleatoria continua	129
9.4	Condiciones para una densidad válida	129
9.5	La densidad no es una probabilidad puntual	130
9.6	Probabilidad como área	130
9.7	Ejemplo: densidad uniforme elemental	131
9.8	Determinar una constante de normalización	131
9.9	Función de distribución acumulada	132
9.10	Ejemplo de CDF a partir de una densidad	133
9.11	Probabilidades mediante la CDF	133
9.12	Ejemplo de ingeniería: error de medición	134
9.13	Ejemplo ambiental: concentración de un contaminante	134
9.14	Integración en R	135
9.15	Graficar una densidad y sombrear un intervalo	135
9.16	Construcción numérica de la CDF	136
9.17	Simulación de una variable continua	136
9.18	Histograma y densidad teórica	137
9.19	Interactivo del capítulo	138
9.20	Actividad con GeoGebra	139
9.21	Densidad frente a probabilidad	139
9.22	Errores frecuentes	139
9.23	Resumen	140
9.24	Ejercicios	140
9.25	Materiales complementarios del capítulo	141
9.26	Referencias del capítulo	142
10	Esperanza matemática, momentos, varianza y desigualdad de Chebyshev	143
10.1	Objetivos de aprendizaje	143
10.2	Del modelo completo a medidas resumen	143

10.3	Esperanza de una variable discreta	144
10.3.1	Ejemplo: número de retransmisiones	144
10.4	Interpretación como centro de balance	144
10.5	Esperanza de una variable continua	145
10.5.1	Ejemplo	145
10.6	Esperanza de una función de la variable	145
10.7	Ejemplo: costo esperado	146
10.8	Linealidad de la esperanza	147
10.9	Variables indicadoras	147
10.9.1	Ejemplo: número esperado de sensores que fallan	148
10.10	Momentos	148
10.11	Varianza	149
10.12	Ejemplo discreto completo	149
10.13	Cálculo en R	150
10.14	Transformaciones lineales	150
10.14.1	Ejemplo: conversión de temperatura	151
10.15	Esperanza y varianza mediante simulación	151
10.16	Desigualdad de Markov	152
10.16.1	Ejemplo	152
10.17	Desigualdad de Chebyshev	153
10.18	Interpretación de Chebyshev	153
10.19	Ejemplo de ingeniería	154
10.20	Comparar la cota con la probabilidad real	154
10.21	Interactivo del capítulo	155
10.22	Actividad con GeoGebra	155
10.23	Estrategia de resolución	156
10.24	Errores frecuentes	156
10.25	Resumen	157
10.26	Ejercicios	157
10.27	Materiales complementarios del capítulo	158
10.28	Referencias del capítulo	159
11	Distribuciones discretas especiales I: Bernoulli, binomial, geométrica y binomial negativa	160
11.1	Objetivos de aprendizaje	160
11.2	¿Por qué estudiar familias de distribuciones?	160
11.3	Distribución de Bernoulli	161
11.3.1	Ejemplo de ingeniería	162
11.4	Distribución binomial	162
11.5	¿De dónde aparece el coeficiente binomial?	163
11.6	Ejemplo: defectos en una muestra	163

11.7	Probabilidades acumuladas binomiales	164
11.8	Ejemplo de confiabilidad	165
11.9	Bernoulli como caso particular de la binomial	165
11.10	Distribución geométrica	166
11.11	Ejemplo: intentos de conexión	167
11.12	Atención: parametrización de <code>dgeom()</code> en R	167
11.13	Propiedad sin memoria	168
11.13.1	Ejemplo	168
11.14	Distribución binomial negativa	168
11.15	¿Por qué aparece $\binom{x-1}{r-1}$?	169
11.16	Ejemplo: paquetes correctamente recibidos	169
11.17	Parametrización de <code>dnbinom()</code> en R	170
11.18	Relación entre geométrica y binomial negativa	170
11.19	Comparación conceptual	171
11.20	Funciones principales en R	171
11.21	Simulación binomial	172
11.22	Comparar PMF teórica y simulación	173
11.23	Simulación geométrica con la convención del libro	174
11.24	Simulación binomial negativa con la convención del libro	174
11.25	Interactivo del capítulo	175
11.26	Actividad con GeoGebra	175
11.27	Selección del modelo	176
11.28	Errores frecuentes	176
11.29	Resumen	177
11.30	Ejercicios	177
11.31	Materiales complementarios del capítulo	178
11.32	Referencias del capítulo	179
12	Distribuciones discretas especiales II: hipergeométrica y Poisson	180
12.1	Objetivos de aprendizaje	180
12.2	Dos estructuras nuevas	180
12.3	Distribución hipergeométrica	180
12.4	Ejemplo de control de calidad	181
12.5	Binomial frente a hipergeométrica	182
12.6	Distribución de Poisson	183
12.7	Ejemplo: solicitudes a un servidor	183
12.8	Ejemplo ambiental	184
12.9	Suma de variables Poisson	185
12.10	Aproximación binomial por Poisson	185
12.11	Simulación en R	186
12.12	Interactivo del capítulo	187

12.13	Actividad con GeoGebra	187
12.14	Selección del modelo	187
12.15	Errores frecuentes	187
12.16	Resumen	188
12.17	Ejercicios	188
12.18	Materiales complementarios del capítulo	188
12.19	Referencias del capítulo	189
13	Distribuciones continuas especiales I: uniforme, exponencial y normal	190
13.1	Objetivos de aprendizaje	190
13.2	Tres modelos fundamentales	190
14	Distribución uniforme continua	191
14.1	Función de distribución acumulada	191
14.2	Media y varianza de la uniforme	192
14.3	Ejemplo: error de redondeo	192
14.4	Funciones de R para la uniforme	193
15	Distribución exponencial	194
15.1	CDF y función de supervivencia	194
15.2	Media y varianza de la exponencial	195
15.3	Ejemplo: tiempo entre fallas	195
15.4	Propiedad sin memoria	196
15.5	Ejemplo numérico de la propiedad sin memoria	196
15.6	Funciones de R para la exponencial	196
16	Distribución normal	198
16.1	Propiedades geométricas	198
16.2	Normal estándar	199
16.3	Ejemplo de estandarización	199
16.4	Probabilidad entre dos valores	200
16.5	Cuantiles de la normal	200
16.6	Regla empírica 68–95–99.7	201
16.7	Funciones de R para la normal	201
16.8	Transformaciones lineales de variables normales	202
16.9	Simulación y comparación gráfica	203
16.10	Comparación de las tres distribuciones	203
16.11	Interactivo del capítulo	204
16.12	Actividad con GeoGebra	204
16.13	Estrategia de selección del modelo	205
16.14	Errores frecuentes	205

16.15	Resumen	205
16.16	Ejercicios	206
16.17	Materiales complementarios del capítulo	206
16.18	Referencias del capítulo	207
17	Distribuciones continuas especiales II: Gamma, Weibull y Beta	208
17.1	Objetivos de aprendizaje	208
17.2	Tres familias muy flexibles	208
18	Distribución Gamma	209
18.1	Media y varianza	209
18.2	Relación con la exponencial	210
18.3	Tiempos de espera acumulados	210
18.3.1	Ejemplo: tiempo hasta la cuarta llegada	211
18.4	<code>rate</code> y <code>scale</code> en R	211
18.5	Funciones Gamma en R	212
18.6	Efecto del parámetro de forma	212
19	Distribución Weibull	214
19.1	CDF y función de supervivencia	214
19.2	Tasa de falla	215
19.3	Relación con la exponencial	215
19.4	Media y varianza de Weibull	216
19.5	Ejemplo de confiabilidad	216
19.6	Funciones Weibull en R	217
20	Distribución Beta	218
20.1	Media y varianza de Beta	218
20.2	Formas de la distribución Beta	219
20.3	Ejemplo: fracción de utilización	219
20.4	Uniforme como caso particular de Beta	220
20.5	Funciones Beta en R	220
20.6	Simulación Gamma	221
20.7	Simulación Weibull	221
20.8	Simulación Beta	222
20.9	Comparación conceptual	222
20.10	Interactivo del capítulo	222
20.11	Actividad con GeoGebra	223
20.12	Estrategia de selección del modelo	223
20.13	Errores frecuentes	224
20.14	Resumen	224

20.15Ejercicios	225
20.16Materiales complementarios del capítulo	225
20.17Referencias del capítulo	226
21 Variables aleatorias conjuntas, distribuciones marginales y condicionales	227
21.1 Objetivos de aprendizaje	227
21.2 De una variable a dos variables	227
21.3 Variables aleatorias conjuntas discretas	228
21.4 Ejemplo: dos subsistemas	228
21.5 Probabilidad de una región discreta	229
21.6 Distribuciones marginales discretas	229
21.7 Cálculo de marginales en R	230
21.8 Distribuciones condicionales discretas	231
21.9 Ejemplo condicional	231
21.10Independencia de variables aleatorias discretas	232
21.11Verificación en R	232
21.12Independencia y condicionamiento	233
21.13Función de distribución conjunta	233
21.14Variables aleatorias conjuntas continuas	234
21.15Ejemplo continuo sobre una región triangular	234
21.16Probabilidad sobre una subregión	235
21.17Densidades marginales	235
21.18Densidades condicionales	236
21.19Independencia en el caso continuo	237
21.20Ejemplo continuo independiente	237
21.21Cálculos bidimensionales en R	238
21.22Simulación de una distribución conjunta discreta	238
21.23Simulación del ejemplo triangular	240
21.24Visualización mediante mapa de calor	241
21.25Interactivo del capítulo	242
21.26Actividad con GeoGebra	243
21.27Parte A: soporte continuo	243
21.28Parte B: condicionamiento	243
21.29Estrategia de resolución	244
21.30Errores frecuentes	244
21.31Resumen	244
21.32Ejercicios	245
21.33Materiales complementarios del capítulo	245
21.34Referencias del capítulo	246
Referencias	247

Listado de Figuras

2.1 Unión e intersección de dos eventos.	35
--	----

Listado de Tablas

Portada

Este libro presenta una introducción aplicada a la probabilidad mediante teoría, simulación, programación en R y actividades dinámicas con GeoGebra. Los ejemplos se sitúan en contextos de ingeniería y ciencias.

Los capítulos combinan conceptos, procedimientos, interpretación, comprobación computacional y ejercicios para favorecer un aprendizaje gradual.

Bienvenida

La probabilidad es el lenguaje matemático con el que estudiamos fenómenos cuyo resultado no puede predecirse con certeza absoluta.

En este libro trabajaremos con situaciones reales y simuladas de ingeniería y ciencias. Cada concepto se estudiará primero de manera intuitiva, después matemáticamente y finalmente mediante R y GeoGebra.

El objetivo no es memorizar fórmulas, sino aprender a construir modelos probabilísticos, interpretarlos y utilizarlos para tomar decisiones bajo incertidumbre.

Presentación

La obra está organizada para acompañar un primer curso universitario de probabilidad. El recorrido inicia con conjuntos, experimentos aleatorios, espacios muestrales y eventos; continúa con probabilidad condicional, independencia y Bayes; y después aborda variables aleatorias, esperanza, distribuciones conjuntas y las principales distribuciones discretas y continuas.

La versión aplicada incorpora simulación, gráficos y cálculo con R, además de recursos visuales e interactivos con GeoGebra. Los ejemplos se orientarán especialmente a problemas de ingeniería, ciencias y datos reales.

Introducción

La ingeniería y las ciencias trabajan constantemente con variación, ruido e incertidumbre. Dos mediciones realizadas bajo condiciones aparentemente iguales pueden producir resultados distintos; un componente puede fallar antes o después de lo esperado; una red puede recibir un número impredecible de solicitudes; y una variable ambiental puede fluctuar aun cuando las condiciones generales parezcan estables.

La probabilidad proporciona un marco matemático para representar y cuantificar esa incertidumbre. En lugar de intentar eliminar la variación, construimos modelos capaces de describirla.

A lo largo del libro combinaremos teoría, resolución manual de problemas, simulación y visualización. R permitirá experimentar con miles de repeticiones y contrastar resultados teóricos; GeoGebra ayudará a explorar de forma dinámica espacios muestrales, eventos, funciones de distribución y familias de distribuciones.

Notación general

Se utilizarán, entre otros, los siguientes símbolos:

- S o Ω : espacio muestral.
- A, B, C : eventos.
- A^c : complemento de A .
- $A \cup B$: unión de eventos.
- $A \cap B$: intersección de eventos.
- $P(A)$: probabilidad del evento A .
- $P(A | B)$: probabilidad condicional de A dado B .
- X, Y : variables aleatorias.
- $F_X(x)$: función de distribución acumulada de X .
- $p_X(x)$: función de masa de probabilidad.
- $f_X(x)$: función de densidad.
- $E(X)$: esperanza matemática.
- $\text{Var}(X)$: varianza.
- $\text{Cov}(X, Y)$: covarianza.
- ρ_{XY} : coeficiente de correlación.

1 Incertidumbre y probabilidad

1.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de distinguir fenómenos deterministas y aleatorios, reconocer la variabilidad como parte natural de los sistemas reales, describir experimentos aleatorios sencillos y utilizar simulación para aproximar probabilidades.

1.2. ¿Por qué necesitamos probabilidad?

En un modelo determinista, unas mismas condiciones producen idealmente el mismo resultado. Sin embargo, muchos sistemas de ingeniería y ciencias contienen fuentes de variación no controladas. Por ello, aun repitiendo un procedimiento de manera semejante, los resultados pueden cambiar.

La probabilidad permite construir modelos matemáticos para esa variación. Un modelo probabilístico no pretende adivinar exactamente qué ocurrirá en una repetición particular; busca describir qué resultados son posibles y con qué grado de plausibilidad pueden presentarse.

1.3. Experimentos deterministas y aleatorios

Un **experimento aleatorio** es un procedimiento que puede producir resultados diferentes aun cuando se repita bajo condiciones esencialmente iguales.

Ejemplos:

- registrar si un componente electrónico falla durante cierto periodo;
- contar llamadas que llegan a un servidor durante un minuto;
- medir la concentración de un contaminante en una estación ambiental;
- observar la cara obtenida al lanzar una moneda.

1.4. Variabilidad

La variabilidad puede provenir de ruido de medición, cambios ambientales, diferencias entre materiales, comportamiento humano o factores no observados. En ingeniería, ignorar esta variabilidad puede conducir a diseños poco confiables.

La idea central será:

modelar la incertidumbre en lugar de fingir que no existe.

1.5. Frecuencia relativa como intuición

Si un experimento se repite n veces y el evento A ocurre n_A veces, su frecuencia relativa es

$$\widehat{P}_n(A) = \frac{n_A}{n}.$$

Cuando aumentamos el número de repeticiones, esta cantidad suele estabilizarse alrededor de un valor. Más adelante estudiaremos formalmente la relación entre esta observación y la Ley de los Grandes Números.

1.6. Primer experimento con R


Simulemos lanzamientos de una moneda equilibrada.

```
set.seed(123)
n <- 1000
lanzamientos <- sample(c("cara", "cruz"), n, replace = TRUE)
mean(lanzamientos == "cara")
```

```
[1] 0.506
```

Podemos observar cómo evoluciona la frecuencia relativa:

```
frecuencia <- cumsum(lanzamientos == "cara") / seq_len(n)
plot(frecuencia, type = "l",
     xlab = "Número de lanzamientos",
     ylab = "Frecuencia relativa de cara")
abline(h = 0.5, lty = 2)
```



Este ejemplo muestra una idea que aparecerá una y otra vez: la simulación permite observar experimentalmente un resultado probabilístico antes de demostrarlo formalmente.

1.7. Primer recurso GeoGebra

En la versión web construiremos experimentos interactivos que permitan comparar resultados observados con modelos teóricos. En el capítulo siguiente comenzaremos con diagramas de Venn y representación de eventos.

1.8. Aplicación de ingeniería

Supongamos que un sensor transmite correctamente un paquete con probabilidad aproximada de 0.98. Una sola transmisión no puede predecirse con certeza. Sin embargo, el modelo probabilístico permite analizar cuántos errores esperar, la probabilidad de varias fallas consecutivas y la confiabilidad global del sistema.

Este tipo de preguntas motivará el desarrollo de eventos, probabilidad condicional, variables aleatorias y distribuciones.

1.9. Ideas clave

- La incertidumbre no implica ausencia de estructura.
- La probabilidad cuantifica fenómenos aleatorios.
- La repetición experimental permite observar regularidades.
- La simulación complementa, pero no sustituye, el razonamiento matemático.

1.10. Ejercicios

1. Clasifica como determinista o aleatorio: calcular el área de un círculo de radio conocido; medir el tiempo de vida de un foco; lanzar un dado; calcular $2 + 3$.
2. Propón tres fuentes de variabilidad en una medición de temperatura ambiental.
3. Simula en R 100, 1000 y 10000 lanzamientos de una moneda y compara las frecuencias relativas de cara.
4. Explica por qué una frecuencia relativa observada de 0.47 no demuestra que una moneda sea sesgada.
5. Describe un experimento aleatorio relacionado con tu área de ingeniería e identifica al menos tres resultados posibles.

1.11. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

1.12. Referencias del capítulo

El desarrollo conceptual de este capítulo toma como referencia la organización y el enfoque aplicado de textos de probabilidad para ingeniería y ciencias, especialmente Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018), Johnson (2018) y el enfoque computacional con R de Kerns (2010).

2 Conjuntos, espacios muestrales y eventos

2.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- utilizar la notación y las operaciones básicas de conjuntos;
- construir espacios muestrales mediante listas, tablas y diagramas de árbol;
- distinguir espacios muestrales finitos, numerables y continuos;
- representar eventos como subconjuntos del espacio muestral;
- traducir expresiones como “al menos uno”, “ambos” y “ninguno” al lenguaje de conjuntos;
- comprobar operaciones con eventos mediante R;
- interpretar diagramas de Venn y construir una representación dinámica en GeoGebra.

2.2. Del experimento al modelo

Un experimento aleatorio se convierte en un modelo matemático cuando especificamos con claridad:

1. qué procedimiento se realiza;
2. qué se observa o registra;
3. cuáles resultados se consideran posibles;
4. qué resultados forman el evento de interés.

Esta precisión es esencial. Si lanzamos un dado, podemos registrar el número de puntos, la paridad o simplemente si el resultado supera a 4. El experimento físico es el mismo, pero el espacio muestral cambia con la observación que decidimos conservar.

2.3. Repaso de conjuntos

Un **conjunto** es una colección bien definida de objetos. Los objetos que lo integran son sus **elementos**.

Si x pertenece a A , escribimos $x \in A$; si no pertenece, $x \notin A$. Un conjunto puede describirse por extensión,

$$A = \{2, 4, 6\},$$

o mediante una propiedad,

$$A = \{x \in \mathbb{N} : 1 \leq x \leq 6 \text{ y } x \text{ es par}\}.$$

2.3.1. Subconjuntos, igualdad y conjunto vacío

Decimos que A es subconjunto de B , y escribimos $A \subseteq B$, cuando todo elemento de A también pertenece a B .

Dos conjuntos son iguales si contienen exactamente los mismos elementos:

$$A = B \iff A \subseteq B \text{ y } B \subseteq A.$$

El conjunto sin elementos se llama **conjunto vacío** y se representa por $\emptyset$.

2.3.2. Operaciones básicas

Sean A y B subconjuntos de un universo S .

Operación	Notación	Interpretación
Unión	$A \cup B$	elementos que están en A , en B o en ambos
Intersección	$A \cap B$	elementos comunes a A y B
Diferencia	$A \setminus B$	elementos de A que no están en B
Complemento	A^c	elementos de S que no están en A

Operación	Notación	Interpretación
Diferencia simétrica	$A \triangle B$	elementos que están en exactamente uno de los dos conjuntos

La palabra **o** se interpreta de manera inclusiva: $A \cup B$ contiene también los resultados donde ocurren ambos eventos. Si queremos “uno u otro, pero no ambos”, utilizamos $A \triangle B$.

2.3.3. Leyes de De Morgan

Dos identidades especialmente útiles son

$$(A \cup B)^c = A^c \cap B^c,$$

$$(A \cap B)^c = A^c \cup B^c.$$

En lenguaje cotidiano:

- “no ocurre A ni ocurre B ” equivale a “no ocurre A y no ocurre B ”;
- “no ocurren ambos” equivale a “falla al menos uno de los dos”.

2.4. Espacio muestral

El **espacio muestral**, denotado por S o Ω , es el conjunto de todos los resultados posibles del experimento, de acuerdo con lo que se decidió observar. Cada elemento de S es un **punto muestral**.

2.4.1. Ejemplo: lanzar un dado

Si registramos el número de puntos,

$$S_1 = \{1, 2, 3, 4, 5, 6\}.$$

Si sólo registramos la paridad,

$$S_2 = \{\text{par}, \text{impar}\}.$$

S_1 conserva más información: a partir del resultado 4 podemos determinar que ocurrió “par”, pero saber únicamente “par” no permite reconstruir el número observado.

2.4.2. Tipos de espacios muestrales

- **Finito:** contiene un número finito de resultados. Ejemplo: inspeccionar tres piezas y registrar para cada una si es conforme o defectuosa.
- **Infinito numerable:** sus resultados pueden listarse como una sucesión. Ejemplo: número de paquetes recibidos hasta el primer error, $S = \{1, 2, 3, \dots\}$.
- **Continuo:** contiene un intervalo o una región de valores. Ejemplo: tiempo de vida de un componente, $S = [0, \infty)$.

En este capítulo enumeraremos principalmente espacios finitos. Los espacios continuos se retomarán al estudiar variables aleatorias continuas.

2.5. Cómo construir un espacio muestral

2.5.1. Enumeración directa

Para dos lanzamientos de una moneda, con C = cara y X = cruz,

$$S = \{CC, CX, XC, XX\}.$$

El orden importa: CX y XC son resultados distintos.

2.5.2. Tabla de doble entrada

Al lanzar dos dados, cada resultado se representa mediante un par ordenado (i, j) :

$$S = \{(i, j) : i, j \in \{1, 2, 3, 4, 5, 6\}\}.$$

La tabla tiene $6 \times 6 = 36$ puntos muestrales. Esta representación facilita localizar eventos como “la suma es 7”:

$$A = \{(1, 6), (2, 5), (3, 4), (4, 3), (5, 2), (6, 1)\}.$$

2.5.3. Diagrama de árbol

Un árbol es conveniente cuando el experimento ocurre por etapas. Cada trayectoria completa, desde la raíz hasta una hoja, representa un punto muestral.

Por ejemplo, un sistema intenta transmitir un paquete. Si el primer intento falla, realiza un segundo intento. Con E = éxito y F = falla,

$$S = \{E, FE, FF\}.$$

No aparece EE , porque el procedimiento termina después del primer éxito.

2.6. Eventos

Un **evento** es cualquier subconjunto del espacio muestral. El evento ocurre cuando el resultado observado pertenece a ese subconjunto.

En el lanzamiento de un dado, sea

$$S = \{1, 2, 3, 4, 5, 6\}, \quad A = \{2, 4, 6\}, \quad B = \{4, 5, 6\}.$$

Entonces:

$$A \cap B = \{4, 6\},$$

$$A \cup B = \{2, 4, 5, 6\},$$

$$A^c = \{1, 3, 5\},$$

$$A \setminus B = \{2\}.$$

2.6.1. Clases frecuentes de eventos

- **Evento simple:** contiene un solo punto muestral.
- **Evento compuesto:** contiene dos o más puntos muestrales.
- **Evento seguro:** es todo el espacio muestral S .
- **Evento imposible:** es $\emptyset$.
- **Eventos mutuamente excluyentes:** satisfacen $A \cap B = \emptyset$.
- **Eventos exhaustivos:** su unión es S .

Mutuamente excluyentes no significa independientes. La independencia se estudiará después de introducir la probabilidad condicional.

2.7. Traducir frases a operaciones con eventos

Frase	Expresión
ocurre A y ocurre B	$A \cap B$
ocurre A o ocurre B , o ambos	$A \cup B$
no ocurre A	A^c
ocurre A , pero no B	$A \cap B^c = A \setminus B$
ocurre exactamente uno	$A \triangle B$
no ocurre ninguno	$(A \cup B)^c = A^c \cap B^c$
ocurre al menos uno	$A \cup B$
ocurren ambos	$A \cap B$
ocurre a lo más uno	$(A \cap B)^c$

2.8. Trabajo con conjuntos en R

R representa naturalmente un conjunto finito mediante un vector cuyos elementos no se repiten.

```
S <- 1:6
A <- c(2, 4, 6)
B <- c(4, 5, 6)

union(A, B)
```

```
[1] 2 4 6 5
```

```
intersect(A, B)
```

```
[1] 4 6
```

```
setdiff(S, A)      # complemento de A respecto de S
```

```
[1] 1 3 5
```

```
setdiff(A, B)      # A menos B
```

```
[1] 2
```

La diferencia simétrica se obtiene reuniendo las dos diferencias:

```
simetrica <- union(setdiff(A, B), setdiff(B, A))  
simetrica
```

```
[1] 2 5
```

2.8.1. Construcción del espacio muestral de dos dados

```
dados <- expand.grid(dado_1 = 1:6, dado_2 = 1:6)  
head(dados)
```

	dado_1	dado_2
1	1	1
2	2	1
3	3	1
4	4	1
5	5	1
6	6	1

```
nrow(dados)
```

```
[1] 36
```


Seleccionemos tres eventos:

```
A_suma_7 <- subset(dados, dado_1 + dado_2 == 7)
B_dobles <- subset(dados, dado_1 == dado_2)
C_al_menos_un_6 <- subset(dados, dado_1 == 6 | dado_2 == 6)
```

A_suma_7

	dado_1	dado_2
6	6	1
11	5	2
16	4	3
21	3	4
26	2	5
31	1	6

B_dobles

	dado_1	dado_2
1	1	1
8	2	2
15	3	3
22	4	4
29	5	5
36	6	6

C_al_menos_un_6

	dado_1	dado_2
6	6	1
12	6	2
18	6	3
24	6	4
30	6	5
31	1	6
32	2	6
33	3	6
34	4	6
35	5	6
36	6	6

Obsérvese la diferencia entre `|` y `&`:

```
evento_union <- subset(dados,
                       dado_1 + dado_2 == 7 | dado_1 == dado_2)

evento_interseccion <- subset(dados,
                              dado_1 + dado_2 == 7 & dado_1 == dado_2)

nrow(evento_union)
```

```
[1] 12
```

```
nrow(evento_interseccion)
```

```
[1] 0
```

La intersección es vacía: ningún doble suma 7.

2.9. Diagrama de Venn con R sin paquetes

El siguiente código genera una representación conceptual. Las áreas de los círculos no expresan probabilidades; sólo muestran relaciones entre eventos.

```
plot.new()
plot.window(xlim = c(0, 10), ylim = c(0, 7), asp = 1)
rect(0.4, 0.4, 9.6, 6.6, border = "#34495e", lwd = 2)
symbols(x = c(4, 6), y = c(3.5, 3.5),
        circles = c(2.2, 2.2), inches = FALSE,
        add = TRUE, fg = c("#1565c0", "#c62828"), lwd = 3)
text(2.5, 3.5, "A", cex = 1.4, col = "#1565c0")
text(7.5, 3.5, "B", cex = 1.4, col = "#c62828")
text(5, 3.5, expression(A %intersection% B), cex = 1.1)
text(9.1, 6.1, "S", cex = 1.2)
box()
```




Figura 2.1: Unión e intersección de dos eventos.

2.10. Actividad interactiva con GeoGebra

En la versión web puede abrirse [GeoGebra Classic](#). En la vista **Geometría**, construye un rectángulo para representar S y dos circunferencias superpuestas para A y B .

1. Crea dos puntos, por ejemplo $O=(-1,0)$ y $P=(1,0)$.
2. Escribe $a=\text{Circle}(O,2.2)$ y $b=\text{Circle}(P,2.2)$.
3. Utiliza $\text{Intersect}(a,b)$ para mostrar los puntos de cruce.
4. Mueve O o P y observa cuándo los eventos quedarían disjuntos.
5. Añade textos para $A \cap B$, $A \cup B$, $A \setminus B$ y $(A \cup B)^c$.

La meta no es calcular áreas, sino visualizar cómo cambian las relaciones de inclusión, intersección y exclusión al mover los conjuntos.

2.11. Aplicación: sistema de dos sensores

Dos sensores, A y B , supervisan una variable ambiental. Al finalizar una prueba se registra si cada sensor respondió correctamente (C) o falló (F):

$$S = \{CC, CF, FC, FF\}.$$

Definamos:

$$E_A = \{CC, CF\}, \quad E_B = \{CC, FC\}.$$

Entonces:

- ambos sensores responden correctamente: $E_A \cap E_B = \{CC\}$;
- al menos uno responde correctamente: $E_A \cup E_B = \{CC, CF, FC\}$;
- sólo uno responde correctamente: $E_A \triangle E_B = \{CF, FC\}$;
- ninguno responde correctamente: $(E_A \cup E_B)^c = \{FF\}$.

Esta descripción prepara el análisis de confiabilidad. En el siguiente capítulo asignaremos probabilidades a estos eventos.

2.12. Errores frecuentes

1. **Omitir el orden:** en experimentos secuenciales, CF y FC suelen ser resultados distintos.
2. **Confundir elemento y evento:** $4 \in S$, pero $\{4\} \subseteq S$.
3. **Interpretar “o” como exclusiva:** en matemáticas, $A \cup B$ incluye la intersección.
4. **Cambiar el universo:** el complemento siempre depende del espacio muestral elegido.
5. **Confundir disjunción e independencia:** son conceptos distintos.

2.13. Ejemplo integrador resuelto

Se inspeccionan dos componentes y cada uno se clasifica como conforme (C), reparable (R) o desecho (D).

El espacio muestral es

$$S = \{CC, CR, CD, RC, RR, RD, DC, DR, DD\}.$$

Sea A el evento “al menos un componente es desecho” y B el evento “los dos componentes reciben la misma clasificación”. Entonces

$$A = \{CD, RD, DC, DR, DD\},$$

$$B = \{CC, RR, DD\}.$$

Por tanto,

$$A \cap B = \{DD\},$$

$$A \cup B = \{CC, RR, CD, RD, DC, DR, DD\},$$

$$B^c = \{CR, CD, RC, RD, DC, DR\}.$$

Podemos verificarlo en R:

```
estados <- c("C", "R", "D")
S_componentes <- apply(expand.grid(estados, estados), 1,
                        paste0, collapse = "")

A <- S_componentes[grepl("D", S_componentes)]
B <- S_componentes[substr(S_componentes, 1, 1) ==
                    substr(S_componentes, 2, 2)]

intersect(A, B)
```

```
[1] "DD"
```

```
union(A, B)
```

```
[1] "DC" "DR" "CD" "RD" "DD" "CC" "RR"
```

```
setdiff(S_componentes, B)
```

```
[1] "RC" "DC" "CR" "DR" "CD" "RD"
```

2.14. Ideas clave

- El espacio muestral depende de qué resultado se registra.
- Un evento es un subconjunto del espacio muestral.
- Unión, intersección y complemento traducen afirmaciones sobre eventos.
- Tablas, árboles y productos cartesianos ayudan a no omitir resultados.
- R permite construir y verificar espacios muestrales finitos.
- Los diagramas de Venn apoyan la interpretación, pero no sustituyen la definición por conjuntos.

2.15. Ejercicios

2.15.1. Nivel básico

1. Sea $S = \{1, 2, 3, 4, 5, 6, 7, 8\}$, $A = \{2, 4, 6, 8\}$ y $B = \{5, 6, 7, 8\}$. Obtén $A \cup B$, $A \cap B$, A^c , B^c , $A \setminus B$ y $A \triangle B$.
2. Escribe el espacio muestral de tres lanzamientos de una moneda.
3. Clasifica como evento simple, compuesto, seguro o imposible: obtener 7 al lanzar un dado; obtener un número par; obtener un número del 1 al 6.
4. Expresa con símbolos: “ocurre A pero no B ”, “no ocurre ninguno” y “ocurre al menos uno”.

2.15.2. Nivel intermedio

5. Se lanzan dos dados. Enumera los resultados cuya suma es 5 y los resultados en que aparece al menos un 2. Obtén su unión e intersección.
6. Un paquete puede llegar a tiempo (T), con retraso (R) o perderse (P). Se observan dos paquetes. Construye S y el evento “exactamente uno llega a tiempo”.
7. Verifica mediante una tabla de pertenencia las dos leyes de De Morgan.
8. Construye un diagrama de árbol para una inspección que termina al encontrar la primera pieza defectuosa o después de tres piezas conformes.

2.15.3. R y GeoGebra

9. Usa `expand.grid()` para construir el espacio muestral de tres lanzamientos de un dado. Filtra el evento “la suma es 10”.
10. En R, crea tres eventos finitos y verifica las identidades $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$ y $(A \cup B)^c = A^c \cap B^c$.
11. Modifica el diagrama de Venn en R para representar tres eventos.
12. En GeoGebra, construye dos eventos disjuntos y después muévelos hasta que uno quede contenido en el otro. Describe qué cambia en $A \cap B$ y $A \cup B$.

2.15.4. Aplicación

13. Define un experimento aleatorio relacionado con ingeniería ambiental, biomédica, electrónica o telecomunicaciones. Especifica el procedimiento, la observación, el espacio muestral y tres eventos relevantes.
14. Un sistema tiene tres alarmas binarias. Construye el espacio muestral y los eventos “exactamente una alarma se activa”, “al menos dos se activan” y “ninguna se activa”.

2.16. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.

Material	Formato	Acceso	Propósito
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

2.17. Referencias del capítulo

El orden conceptual —espacio muestral, eventos y operaciones— sigue el programa oficial del curso y se apoya principalmente en Walpole et al. (2012). Se complementa con los enfoques para ingeniería y ciencias de Devore (2016), Montgomery y Runger (2018) y Johnson (2018), y con el tratamiento computacional en R de Kerns (2010).

3 Técnicas de conteo y enumeración

3.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- aplicar los principios aditivo y multiplicativo del conteo;
- construir y leer diagramas de árbol;
- distinguir entre permutaciones, arreglos y combinaciones;
- identificar cuándo el orden importa y cuándo no;
- resolver problemas con y sin repetición;
- enumerar espacios muestrales finitos con R;
- verificar resultados exactos mediante simulación;
- explorar visualmente problemas combinatorios mediante un recurso interactivo.

3.2. ¿Por qué necesitamos contar?

En muchos problemas de probabilidad el espacio muestral contiene un número grande de resultados. Enumerarlos uno por uno puede ser tedioso o prácticamente imposible. Las técnicas de conteo permiten determinar cuántos resultados existen sin escribirlos todos.

Si los resultados elementales son equiprobables, el conteo será posteriormente la base para calcular probabilidades mediante

$$P(A) = \frac{|A|}{|S|}.$$

En este capítulo nos concentraremos primero en aprender a contar correctamente. La asignación formal de probabilidades se desarrollará en el capítulo siguiente.

3.3. Principio aditivo

Supongamos que una tarea puede realizarse mediante alternativas mutuamente excluyentes. Si la primera alternativa puede realizarse de n_1 formas, la segunda de n_2 formas, y así sucesivamente, entonces el número total de posibilidades es

$$n_1 + n_2 + \cdots + n_k.$$

3.3.1. Ejemplo

Un laboratorio dispone de 4 sensores ópticos y 3 sensores térmicos. Si se debe elegir exactamente un sensor, existen

$$4 + 3 = 7$$

selecciones posibles.

El principio aditivo se utiliza cuando las alternativas representan caminos diferentes que no ocurren simultáneamente.

3.4. Principio multiplicativo

Si un procedimiento consta de varias etapas y cada etapa admite cierto número de opciones para cada elección previa, el número total de resultados es el producto de las posibilidades de cada etapa.

Si existen n_1 opciones en la primera etapa, n_2 en la segunda, ..., n_k en la última, entonces

$$N = n_1 n_2 \cdots n_k.$$

3.4.1. Ejemplo: código de identificación

Un código contiene dos letras seguidas de tres dígitos. Si se permiten repeticiones, el número de códigos es

$$26^2 \cdot 10^3 = 676000.$$

Aquí el procedimiento tiene cinco etapas: dos elecciones de letra y tres elecciones de dígito.

3.5. Diagramas de árbol

Un diagrama de árbol representa un experimento por etapas. Cada rama corresponde a una elección y cada trayectoria completa desde la raíz hasta una hoja representa un resultado.

3.5.1. Ejemplo: tres transmisiones

Cada transmisión puede ser correcta (C) o errónea (E). Para tres transmisiones,

$$|S| = 2 \cdot 2 \cdot 2 = 8.$$

Los resultados son

$$S = \{CCC, CCE, CEC, CEE, ECC, ECE, EEC, EEE\}.$$

El árbol no sólo ayuda a contar: también ayuda a evitar omisiones y duplicaciones.

3.6. Factorial

Para un entero positivo n definimos

$$n! = n(n-1)(n-2) \cdots 2 \cdot 1,$$

y por convenio

$$0! = 1.$$

Ejemplos:

$$5! = 5 \cdot 4 \cdot 3 \cdot 2 \cdot 1 = 120,$$

$$7! = 5040.$$

El factorial aparece naturalmente cuando contamos ordenamientos de objetos distintos.

3.7. Permutaciones

Una **permutación** es un ordenamiento de todos los objetos de una colección.

El número de permutaciones de n objetos distintos es

$$P_n = n!.$$

3.7.1. Ejemplo

Cinco dispositivos distintos deben colocarse en fila para una prueba. El número de órdenes posibles es

$$5! = 120.$$

3.8. Arreglos o variaciones sin repetición

Cuando se eligen r objetos de un conjunto de n y el orden importa, el número de arreglos es

$$P(n, r) = \frac{n!}{(n-r)!}.$$

3.8.1. Ejemplo: asignación de cargos

De 10 estudiantes se eligen presidente, secretario y tesorero. Como los cargos son diferentes, el orden importa:

$$P(10, 3) = 10 \cdot 9 \cdot 8 = 720.$$

3.9. Combinaciones

Cuando se eligen r objetos de un conjunto de n y el orden no importa, utilizamos combinaciones:

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}.$$

3.9.1. Ejemplo: selección de un comité

De 10 estudiantes se selecciona un comité de 3 personas. Como no existen cargos diferenciados,

$$\binom{10}{3} = 120.$$

La diferencia conceptual es fundamental:

si cambiar el orden produce un resultado diferente, usamos un conteo ordenado;
si no produce un resultado diferente, usamos combinaciones.

3.10. Comparación rápida

Situación	¿Importa el orden?	¿Se permite repetición?	Número de resultados
ordenar los n objetos	sí	no	$n!$
elegir y ordenar r de n	sí	no	$\frac{n!}{(n-r)!}$

Situación	¿Importa el orden?	¿Se permite repetición?	Número de resultados
elegir r de n	no	no	$\binom{n}{r}$
formar una secuencia de longitud r con n símbolos	sí	sí	n^r

3.11. Conteo con repetición

Si cada una de r posiciones puede ocuparse por cualquiera de n símbolos y se permite repetición, existen

$$n^r$$

secuencias.

3.11.1. Ejemplo

Una contraseña de cuatro dígitos, permitiendo repeticiones y ceros iniciales, tiene

$$10^4 = 10000$$

posibilidades.

Si no se permiten repeticiones, el conteo cambia a

$$P(10, 4) = 10 \cdot 9 \cdot 8 \cdot 7 = 5040.$$

3.12. Permutaciones con objetos repetidos

Si existen n objetos, pero algunos son indistinguibles, el número de ordenamientos distintos disminuye.

Si hay n_1 objetos de un tipo, n_2 de otro, ..., n_k de otro, con

$$n_1 + n_2 + \cdots + n_k = n,$$

entonces el número de permutaciones distintas es

$$\frac{n!}{n_1!n_2!\cdots n_k!}.$$

3.12.1. Ejemplo

La palabra **RADAR** tiene cinco letras, con dos R y dos A. El número de arreglos distintos es

$$\frac{5!}{2!2!} = 30.$$

3.13. Ejemplo de ingeniería: selección para inspección

Una caja contiene 12 componentes. Se seleccionan 3 para inspección.

Si únicamente interesa qué componentes fueron seleccionados, y no el orden en que se extrajeron,

$$|S| = \binom{12}{3} = 220.$$

Si en cambio el primer componente se asigna a una prueba térmica, el segundo a una prueba eléctrica y el tercero a una prueba mecánica, entonces las posiciones tienen funciones diferentes y el orden sí importa:

$$P(12, 3) = 12 \cdot 11 \cdot 10 = 1320.$$

El contexto determina el modelo de conteo apropiado.

3.14. Cálculo con R

R proporciona funciones directas para factoriales y combinaciones:

```
factorial(6)
```

```
[1] 720
```

```
choose(12, 3)
```

```
[1] 220
```

Podemos definir los arreglos sin repetición mediante

```
arreglos <- function(n, r) {  
  factorial(n) / factorial(n - r)  
}
```

```
arreglos(10, 3)
```

```
[1] 720
```

3.14.1. Enumeración explícita con R

Para tres transmisiones, cada una correcta o errónea:

```
S <- expand.grid(  
  t1 = c("C", "E"),  
  t2 = c("C", "E"),  
  t3 = c("C", "E")  
)  
S
```


	t1	t2	t3
1	C	C	C
2	E	C	C
3	C	E	C
4	E	E	C
5	C	C	E
6	E	C	E
7	C	E	E
8	E	E	E

```
nrow(S)
```

```
[1] 8
```

El resultado debe contener $2^3 = 8$ filas.

3.14.2. Comprobar combinaciones

Podemos enumerar todas las selecciones de 3 elementos tomadas de 5:

```
combn(1:5, 3)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]	[,9]	[,10]
[1,]	1	1	1	1	1	1	2	2	2	3
[2,]	2	2	2	3	3	4	3	3	4	4
[3,]	3	4	5	4	5	5	4	5	5	5

```
choose(5, 3)
```

```
[1] 10
```

La primera instrucción muestra las selecciones y la segunda devuelve únicamente su cantidad.

3.15. Simulación como verificación

La simulación puede utilizarse para comprobar que un mecanismo de generación recorre los tipos de resultados esperados.

Por ejemplo, si generamos aleatoriamente claves de dos letras entre A, B y C:

```
set.seed(123)
replicate(10, paste(sample(c("A", "B", "C"), 2,
                           replace = TRUE), collapse = ""))
```

```
[1] "CC" "CB" "CB" "BB" "CA" "BB" "AB" "CA" "CC" "AA"
```

El número total de claves posibles es

$$3^2 = 9.$$

La simulación no sustituye el conteo exacto, pero ayuda a comprender cómo se generan los resultados.

3.16. Interactivo del capítulo

En la edición web se incluye un recurso interactivo con dos deslizadores, n y r , que permite comparar simultáneamente:

$$n!,$$

$$P(n, r) = \frac{n!}{(n-r)!},$$

y

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}.$$

El objetivo es que el estudiante observe visualmente cuánto cambia el número de resultados cuando el orden importa y cuando no importa. También se incluye un árbol de decisiones de tres etapas para ilustrar el principio multiplicativo.

3.17. Estrategia para decidir qué fórmula utilizar

Antes de calcular, contesta estas preguntas:

1. ¿El procedimiento ocurre por etapas?
2. ¿Las alternativas son mutuamente excluyentes o consecutivas?
3. ¿Importa el orden?
4. ¿Se permite repetir elementos?
5. ¿Se seleccionan todos los elementos o sólo una parte?

Una buena práctica es describir primero el proceso con palabras y después elegir la fórmula.

3.18. Errores frecuentes

- utilizar combinaciones cuando el orden sí importa;
- utilizar permutaciones cuando sólo interesa el grupo seleccionado;
- olvidar si la repetición está permitida;
- multiplicar cantidades correspondientes a alternativas excluyentes;
- sumar cantidades correspondientes a etapas consecutivas;
- contar dos veces resultados que representan la misma selección;
- aplicar una fórmula antes de entender qué constituye un resultado diferente.

3.19. Ideas clave

- El principio aditivo combina alternativas excluyentes.
- El principio multiplicativo combina etapas sucesivas.
- Los diagramas de árbol ayudan a visualizar procesos por etapas.
- El factorial cuenta ordenamientos completos.
- Los arreglos se utilizan cuando el orden importa.
- Las combinaciones se utilizan cuando el orden no importa.
- La repetición cambia de manera esencial el conteo.
- R permite enumerar y comprobar espacios muestrales finitos.

3.20. Ejercicios

1. Una cafetería ofrece 4 bebidas y 6 alimentos. ¿Cuántos desayunos distintos pueden formarse eligiendo una bebida y un alimento?
2. ¿Cuántas claves de tres letras pueden formarse con 26 letras si se permite repetición?
3. Resuelve el ejercicio anterior si no se permite repetición.
4. ¿De cuántas maneras pueden ordenarse 8 libros distintos en un estante?
5. De 12 estudiantes, ¿de cuántas maneras pueden asignarse los cargos de presidente, secretario y tesorero?
6. De los mismos 12 estudiantes, ¿cuántos comités distintos de 3 personas pueden formarse?
7. ¿Cuántos resultados posibles tiene una secuencia de 5 lanzamientos de moneda?
8. ¿Cuántos arreglos distintos pueden formarse con las letras de la palabra PROBABILIDAD? Identifica primero las letras repetidas.
9. Usa R para enumerar todos los resultados de cuatro transmisiones, cada una correcta o errónea, y verifica el principio multiplicativo.
10. Diseña un problema de ingeniería en el que usar una combinación en lugar de un arreglo produzca una respuesta incorrecta. Explica por qué.

3.21. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.

Material	Formato	Acceso	Propósito
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

3.22. Referencias del capítulo

El tratamiento de técnicas de conteo sigue el enfoque habitual de probabilidad para ingeniería y ciencias de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018), complementado con verificación computacional mediante R inspirada en Kerns (2010).

4 Axiomas y propiedades de la probabilidad

4.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- interpretar la probabilidad como una asignación numérica coherente a los eventos;
- reconocer y aplicar los axiomas fundamentales de la probabilidad;
- deducir y utilizar las reglas del complemento, diferencia y unión de eventos;
- justificar por qué una respuesta probabilística debe encontrarse entre 0 y 1;
- resolver problemas de ingeniería y ciencias mediante reglas de probabilidad;
- comprobar resultados mediante R y simulación;
- explorar de manera interactiva cómo se distribuye la probabilidad entre regiones de eventos.

4.2. De contar resultados a medir incertidumbre

En los capítulos anteriores aprendimos a describir experimentos, construir espacios muestrales, representar eventos y contar resultados. Ahora damos un paso fundamental: asignar a cada evento un número que represente su grado de posibilidad.

La probabilidad de un evento A se denota por

$$P(A).$$

Ese número no puede asignarse arbitrariamente. Debe satisfacer ciertas reglas de coherencia. Estas reglas son los **axiomas de la probabilidad**.

Un modelo probabilístico completo puede escribirse como

$$(\Omega, \mathcal{F}, P),$$

donde:

- Ω es el espacio muestral;
- $\mathcal{F}$ es la familia de eventos que pueden recibir probabilidad;
- P es la función que asigna probabilidades.

En este libro aplicado trabajaremos primero con la interpretación y el uso de estas reglas. La formulación más formal se desarrolla paralelamente en *Fundamentos Teóricos de Introducción a la Probabilidad*.

4.3. Los tres axiomas fundamentales

4.3.1. No negatividad

Para cualquier evento A ,

$$P(A) \geq 0.$$

Una probabilidad negativa no tiene interpretación como grado de posibilidad.

4.3.2. Normalización

El espacio muestral representa el evento seguro. Por tanto,

$$P(\Omega) = 1.$$

Decir que un resultado pertenece a Ω significa que alguno de los resultados considerados por el modelo necesariamente ocurrirá.

4.3.3. Aditividad

Si A y B son eventos mutuamente excluyentes,

$$A \cap B = \emptyset,$$

entonces

$$P(A \cup B) = P(A) + P(B).$$

La formulación general del axioma se aplica a una colección numerable de eventos mutuamente excluyentes:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

En los problemas elementales utilizaremos con mayor frecuencia su versión finita.

4.4. Consecuencias inmediatas

Los axiomas permiten deducir muchas de las fórmulas que usamos en la práctica. No son reglas independientes: se derivan de una estructura común.

4.4.1. Probabilidad del evento imposible

Como

$$\Omega = \Omega \cup \emptyset$$

y los conjuntos son disjuntos,

$$P(\Omega) = P(\Omega) + P(\emptyset).$$

Por tanto,

$$\boxed{P(\emptyset) = 0}.$$

4.4.2. Regla del complemento

Los eventos A y A^c son mutuamente excluyentes y

$$A \cup A^c = \Omega.$$

Entonces

$$P(A) + P(A^c) = 1,$$

de donde

$$\boxed{P(A^c) = 1 - P(A)}.$$

Esta regla es especialmente útil para eventos expresados como “al menos uno”. Con frecuencia resulta más sencillo calcular el complemento “ninguno”.

4.4.3. Las probabilidades están entre 0 y 1

Como $A \subseteq \Omega$,

$$0 \leq P(A) \leq 1.$$

Este hecho proporciona una comprobación elemental de cualquier cálculo. Si obtenemos -0.2 o 1.4 , hay un error en el planteamiento o en las operaciones.

4.5. Monotonía

Si

$$A \subseteq B,$$

entonces todo resultado que hace ocurrir A también hace ocurrir B . En consecuencia,

$$\boxed{P(A) \leq P(B)}.$$

4.5.1. Ejemplo

Sea

- A = “un sistema presenta exactamente dos fallas durante el día”;
- B = “el sistema presenta al menos una falla durante el día”.

Claramente $A \subseteq B$, de modo que necesariamente

$$P(A) \leq P(B).$$

Si unos datos produjeran estimaciones que violaran esta relación, tendríamos que revisar la definición de los eventos o el procedimiento de estimación.

4.6. Regla de la diferencia

Si queremos que ocurra A pero no B , utilizamos

$$A \setminus B = A \cap B^c.$$

Como

$$A = (A \setminus B) \cup (A \cap B)$$

y las dos regiones son disjuntas,

$$P(A) = P(A \setminus B) + P(A \cap B).$$

Por tanto,

$$\boxed{P(A \setminus B) = P(A) - P(A \cap B)}.$$

4.7. Regla general de la adición

Cuando A y B se superponen, no podemos sumar directamente $P(A)$ y $P(B)$ porque la intersección se contaría dos veces.

La regla correcta es

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

4.7.1. Ejemplo: fallas de manufactura

En una línea de producción definimos:

- A = “la pieza tiene defecto dimensional”;
- B = “la pieza tiene defecto superficial”.

Supongamos que

$$P(A) = 0.08, \quad P(B) = 0.05, \quad P(A \cap B) = 0.02.$$

Entonces

$$P(A \cup B) = 0.08 + 0.05 - 0.02 = 0.11.$$

La probabilidad de que una pieza tenga **al menos uno** de los dos defectos es 0.11.

La probabilidad de que no tenga ninguno es

$$P((A \cup B)^c) = 1 - 0.11 = 0.89.$$

4.8. Exactamente uno de dos eventos

El evento “ocurre exactamente uno de A y B ” es la diferencia simétrica

$$A \triangle B = (A \setminus B) \cup (B \setminus A).$$

Como las dos partes son disjuntas,

$$P(A \triangle B) = P(A) + P(B) - 2P(A \cap B).$$

En el ejemplo anterior,

$$P(A \triangle B) = 0.08 + 0.05 - 2(0.02) = 0.09.$$

Por tanto, 9 % de las piezas presentan exactamente uno de esos defectos.

4.9. Tres eventos: principio de inclusión-exclusión

Para tres eventos,

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(A \cap B) - P(A \cap C) - P(B \cap C) \\ &\quad + P(A \cap B \cap C). \end{aligned}$$

La triple intersección se suma al final porque al restar las tres intersecciones dobles quedó eliminada demasiadas veces.

4.9.1. Ejemplo: tres alarmas

Tres subsistemas generan alertas A , B y C . Supongamos:

$$P(A) = 0.12, \quad P(B) = 0.09, \quad P(C) = 0.07,$$

$$P(A \cap B) = 0.03, \quad P(A \cap C) = 0.02, \quad P(B \cap C) = 0.01,$$

$$P(A \cap B \cap C) = 0.005.$$

Entonces

$$P(A \cup B \cup C) = 0.12 + 0.09 + 0.07 - 0.03 - 0.02 - 0.01 + 0.005 = 0.225.$$

Por tanto, la probabilidad de que se active al menos una alarma es 0.225.

4.10. Asignación de probabilidades en espacios finitos

Sea

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_N\}.$$

Podemos asignar a cada resultado elemental una probabilidad p_i siempre que

$$p_i \geq 0$$

y

$$\sum_{i=1}^N p_i = 1.$$

Para un evento A ,

$$P(A) = \sum_{\omega_i \in A} p_i.$$

4.10.1. Caso equiprobable

Si los N resultados son igualmente probables,

$$P(\{\omega_i\}) = \frac{1}{N},$$

y por tanto

$$P(A) = \frac{|A|}{|\Omega|}.$$

Esta fórmula **sólo** es válida cuando la equiprobabilidad está justificada.

4.10.2. Ejemplo: dos dados equilibrados

Al lanzar dos dados equilibrados existen 36 pares ordenados equiprobables. El evento

$$A = \{\text{suma} \geq 10\}$$

contiene los resultados

$$(4, 6), (5, 5), (5, 6), (6, 4), (6, 5), (6, 6).$$

Por tanto,

$$P(A) = \frac{6}{36} = \frac{1}{6}.$$

4.11. Comprobación con R

Podemos representar directamente las probabilidades de cuatro regiones determinadas por dos eventos:

```

p_A <- 0.08
p_B <- 0.05
p_AB <- 0.02

p_union <- p_A + p_B - p_AB
p_ninguno <- 1 - p_union
p_exactamente_uno <- p_A + p_B - 2 * p_AB

c(union = p_union,
   ninguno = p_ninguno,
   exactamente_uno = p_exactamente_uno)

```

union	ninguno	exactamente_uno
0.11	0.89	0.09

4.11.1. Una función para verificar coherencia

```

verificar_dos_eventos <- function(pA, pB, pAB) {
  inferior <- max(0, pA + pB - 1)
  superior <- min(pA, pB)

  c(
    interseccion_minima = inferior,
    interseccion_maxima = superior,
    interseccion_valida = pAB >= inferior && pAB <= superior,
    union = pA + pB - pAB
  )
}

verificar_dos_eventos(0.55, 0.40, 0.20)

```

interseccion_minima	interseccion_maxima	interseccion_valida	union
0.00	0.40	1.00	0.75

Para que una intersección sea posible debe satisfacer

$$\max\{0, P(A) + P(B) - 1\} \leq P(A \cap B) \leq \min\{P(A), P(B)\}.$$

Estas cotas evitan asignaciones incompatibles.

4.12. Simulación para comprobar una regla

Construyamos un modelo con cuatro regiones:

- sólo A : 0.35;
- sólo B : 0.20;
- $A \cap B$: 0.15;
- ninguno: 0.30.

Entonces

$$P(A) = 0.50, \quad P(B) = 0.35,$$

y

$$P(A \cup B) = 0.70.$$

```
set.seed(2026)
n <- 20000
region <- sample(
  c("solo_A", "solo_B", "ambos", "ninguno"),
  size = n,
  replace = TRUE,
  prob = c(0.35, 0.20, 0.15, 0.30)
)

A <- region %in% c("solo_A", "ambos")
B <- region %in% c("solo_B", "ambos")

c(
  P_A = mean(A),
  P_B = mean(B),
  P_AB = mean(A & B),
  P_union = mean(A | B),
  formula_union = mean(A) + mean(B) - mean(A & B)
)
```


P_A	P_B	P_AB	P_union	formula_union
0.50555	0.34665	0.15275	0.69945	0.69945

Las dos últimas cantidades serán muy próximas. La pequeña diferencia respecto de los valores teóricos se debe a la variabilidad de la simulación.

4.13. Interactivo del capítulo

La edición web incluye un recurso dinámico para experimentar con $P(A)$, $P(B)$ y $P(A \cap B)$. Al modificar los controles se actualizan automáticamente:

$$P(A \cup B), \quad P((A \cup B)^c), \quad P(A \triangle B).$$

El interactivo impide seleccionar una intersección incompatible con las probabilidades marginales. Esto permite visualizar que los axiomas no sólo producen fórmulas: también restringen qué combinaciones de números pueden constituir un modelo probabilístico válido.

4.14. Actividad con GeoGebra

Construye en GeoGebra una representación de cuatro regiones correspondientes a

$$A \cap B, \quad A \cap B^c, \quad A^c \cap B, \quad A^c \cap B^c.$$

Asocia a cada región un deslizador no negativo y obliga a que la suma de las cuatro probabilidades sea 1. Después define dinámicamente:

$$P(A) = P(A \cap B) + P(A \cap B^c),$$

$$P(B) = P(A \cap B) + P(A^c \cap B),$$

y comprueba visualmente que

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

La construcción puede utilizar rectángulos coloreados en lugar de círculos; así cada área representa de manera conceptual una de las cuatro regiones disjuntas.

4.15. Estrategia para resolver problemas

Cuando trabajes con reglas básicas de probabilidad:

1. Define claramente los eventos.
2. Traduce expresiones como “al menos uno”, “ninguno” y “exactamente uno”.
3. Identifica qué regiones se superponen.
4. Decide si conviene trabajar con el evento o con su complemento.
5. Aplica la regla correspondiente.
6. Verifica que el resultado esté entre 0 y 1.
7. Comprueba que respete relaciones de inclusión conocidas.
8. Interpreta la respuesta en el contexto original.

4.16. Errores frecuentes

- Sumar $P(A) + P(B)$ sin restar la intersección cuando los eventos pueden ocurrir simultáneamente.
- Utilizar $P(A) = |A|/|\Omega|$ cuando los resultados no son equiprobables.
- Confundir A^c con “lo contrario verbalmente” sin definir primero el universo Ω .
- Interpretar $P(\emptyset) = 0$ como si todo evento de probabilidad cero fuera necesariamente imposible; esta diferencia será importante en modelos continuos.
- Aceptar una probabilidad mayor que 1 o negativa sin revisar el cálculo.
- Confundir eventos mutuamente excluyentes con eventos independientes.

4.17. Resumen

- La probabilidad es una función coherente definida sobre eventos.
- Los axiomas fundamentales son no negatividad, normalización y aditividad numerable.
- De ellos se deducen $P(\emptyset) = 0$, la regla del complemento y la monotonía.
- Para dos eventos,

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

- En espacios finitos equiprobables,

$$P(A) = \frac{|A|}{|\Omega|}.$$

- R y la simulación permiten comprobar cálculos y detectar asignaciones incompatibles.

4.18. Ejercicios

1. Sean $P(A) = 0.42$, $P(B) = 0.35$ y $P(A \cap B) = 0.18$. Calcula $P(A \cup B)$, $P((A \cup B)^c)$ y $P(A \triangle B)$.
2. Una estación de monitoreo registra una alarma de ozono con probabilidad 0.12 y una alarma de PM_{10} con probabilidad 0.18. Ambas aparecen simultáneamente con probabilidad 0.05. Calcula la probabilidad de al menos una alarma y de ninguna alarma.
3. Si $A \subseteq B$, $P(A) = 0.31$ y $P(B) = 0.28$, explica por qué los datos son incompatibles.
4. Determina el intervalo de valores posibles para $P(A \cap B)$ si $P(A) = 0.70$ y $P(B) = 0.55$.
5. Al lanzar dos dados equilibrados, calcula la probabilidad de obtener suma 7 o al menos un 6.
6. Verifica mediante enumeración en R la respuesta del ejercicio anterior.
7. Tres sistemas de alarma satisfacen $P(A) = 0.20$, $P(B) = 0.15$, $P(C) = 0.10$, $P(A \cap B) = 0.06$, $P(A \cap C) = 0.04$, $P(B \cap C) = 0.03$ y $P(A \cap B \cap C) = 0.02$. Calcula $P(A \cup B \cup C)$.
8. Simula en R 50 000 repeticiones de un modelo con cuatro regiones de probabilidades 0.25, 0.30, 0.10 y 0.35. Define adecuadamente A y B y verifica la regla de adición.
9. Explica con tus propias palabras por qué restamos $P(A \cap B)$ en la regla de la unión.
10. **Reto** . Prueba, usando sólo reglas de este capítulo, que

$$P(A \cup B) \leq P(A) + P(B).$$

4.19. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

4.20. Referencias del capítulo

El tratamiento de axiomas, reglas de probabilidad y aplicaciones sigue la estructura conceptual habitual de textos de probabilidad para ingeniería y ciencias, especialmente Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). La integración computacional con R se desarrolla con código original y toma como referencia general el enfoque de Kerns (2010).

5 Probabilidad condicional e independencia

5.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- interpretar una probabilidad condicional como una actualización del espacio de referencia;
- calcular $P(A | B)$ y distinguirla de $P(B | A)$;
- aplicar la regla del producto para eventos sucesivos;
- construir y leer árboles de probabilidad;
- reconocer cuándo dos eventos son independientes;
- diferenciar independencia de exclusión mutua;
- resolver problemas de confiabilidad, diagnóstico, comunicaciones y calidad;
- comprobar resultados mediante R y simulación;
- explorar interactivamente cómo cambia una probabilidad al incorporar información.

5.2. Cuando aparece nueva información

Hasta ahora hemos calculado probabilidades utilizando todo el espacio muestral. En muchas aplicaciones, sin embargo, recibimos información adicional antes de responder una pregunta.

Supongamos que elegimos al azar una pieza de una producción y queremos estudiar el evento

$$A = \{\text{la pieza presenta defecto eléctrico}\}.$$

Después nos informan que la pieza pertenece al turno nocturno. Si definimos

$$B = \{\text{la pieza proviene del turno nocturno}\},$$

ya no tiene sentido utilizar toda la producción como universo de referencia: ahora sabemos que el resultado pertenece a B .

La probabilidad de A **dada** la información B se denota por

$$P(A \mid B).$$

El símbolo $\mid$ se lee “dado que”.

5.3. Definición de probabilidad condicional

Si $P(B) > 0$, definimos

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

La fórmula tiene una interpretación geométrica muy sencilla:

1. restringimos la atención al evento B ;
2. dentro de B , identificamos la parte que también pertenece a A ;
3. comparamos la probabilidad de $A \cap B$ con la probabilidad total disponible en B .

5.3.1. Ejemplo con datos de calidad

En una planta, 30 % de las piezas provienen del turno nocturno:

$$P(B) = 0.30.$$

El 6 % de todas las piezas proviene del turno nocturno y presenta defecto:

$$P(A \cap B) = 0.06.$$

Entonces

$$P(A \mid B) = \frac{0.06}{0.30} = 0.20.$$

La interpretación correcta es:

entre las piezas del turno nocturno, 20 % presenta el defecto considerado.

5.4. El orden de la condición importa

En general,

$$P(A \mid B) \neq P(B \mid A).$$

En el ejemplo anterior, $P(A \mid B)$ responde:

¿qué proporción de las piezas nocturnas es defectuosa?

Mientras que $P(B \mid A)$ responde:

entre las piezas defectuosas, ¿qué proporción proviene del turno nocturno?

Son preguntas diferentes y pueden tener respuestas muy distintas.

5.4.1. Ejemplo numérico

Supongamos además que

$$P(A) = 0.10.$$

Como $P(A \cap B) = 0.06$,

$$P(B \mid A) = \frac{0.06}{0.10} = 0.60.$$

Por tanto,

$$P(A \mid B) = 0.20, \quad P(B \mid A) = 0.60.$$

No hay contradicción: los denominadores son distintos.

5.5. Regla del producto

A partir de la definición,

$$P(A | B) = \frac{P(A \cap B)}{P(B)},$$

obtenemos

$$\boxed{P(A \cap B) = P(B)P(A | B)}$$

También podemos invertir el orden:

$$\boxed{P(A \cap B) = P(A)P(B | A)}$$

Por tanto,

$$P(A)P(B | A) = P(B)P(A | B).$$

Esta identidad será la base del teorema de Bayes en el siguiente capítulo.

5.6. Experimentos por etapas

La regla del producto resulta especialmente natural cuando un experimento ocurre secuencialmente.

5.6.1. Ejemplo: dos componentes sin reemplazo

Una caja contiene 8 componentes, de los cuales 3 son defectuosos y 5 conformes. Se seleccionan dos componentes sin reemplazo.

Sea

- D_1 = “el primero es defectuoso”;
- D_2 = “el segundo es defectuoso”.

Entonces

$$P(D_1) = \frac{3}{8}.$$

Si el primero fue defectuoso, quedan 2 defectuosos entre 7 componentes:

$$P(D_2 \mid D_1) = \frac{2}{7}.$$

Por tanto,

$$P(D_1 \cap D_2) = \frac{3}{8} \cdot \frac{2}{7} = \frac{3}{28}.$$

Aquí las probabilidades cambian porque no hay reemplazo.

5.7. Regla de la cadena

Para tres eventos,

$$P(A \cap B \cap C) = P(A)P(B \mid A)P(C \mid A \cap B),$$

si las probabilidades condicionales están definidas.

En general,

$$P\left(\bigcap_{i=1}^n A_i\right) = P(A_1)P(A_2 \mid A_1)P(A_3 \mid A_1 \cap A_2) \cdots P\left(A_n \mid \bigcap_{i=1}^{n-1} A_i\right).$$

Esta forma es muy útil en confiabilidad, procesos secuenciales y árboles de probabilidad.

5.8. Árboles de probabilidad

Un árbol organiza visualmente un experimento por etapas. Cada rama lleva una probabilidad condicional y la probabilidad de una trayectoria completa se obtiene multiplicando sus ramas.

Supongamos:

$$P(A) = 0.40,$$

$$P(B \mid A) = 0.70, \quad P(B \mid A^c) = 0.20.$$

Entonces las cuatro hojas del árbol tienen probabilidades

$$P(A \cap B) = 0.40(0.70) = 0.28,$$

$$P(A \cap B^c) = 0.40(0.30) = 0.12,$$

$$P(A^c \cap B) = 0.60(0.20) = 0.12,$$

$$P(A^c \cap B^c) = 0.60(0.80) = 0.48.$$

La suma de las cuatro hojas es 1.

5.9. Independencia de dos eventos

Dos eventos A y B son **independientes** cuando conocer la ocurrencia de uno no modifica la probabilidad del otro.

Si $P(B) > 0$, una forma intuitiva de expresarlo es

$$P(A \mid B) = P(A).$$

La definición algebraica, válida sin exigir probabilidades positivas, es

$$\boxed{P(A \cap B) = P(A)P(B)}$$

5.9.1. Ejemplo: dos lanzamientos de una moneda

Sea

- A = “el primer lanzamiento es cara”;
- B = “el segundo lanzamiento es cara”.

Para una moneda equilibrada,

$$P(A) = \frac{1}{2}, \quad P(B) = \frac{1}{2},$$

y

$$P(A \cap B) = \frac{1}{4}.$$

Como

$$\frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2},$$

los eventos son independientes.

5.10. Independencia no significa exclusión mutua

Este punto es esencial.

Si A y B son mutuamente excluyentes,

$$P(A \cap B) = 0.$$

Si además $P(A) > 0$ y $P(B) > 0$, entonces

$$P(A)P(B) > 0,$$

por lo que no pueden ser independientes.

Así, dos eventos positivos que no pueden ocurrir simultáneamente son **dependientes**, no independientes.

5.10.1. Ejemplo

En un lanzamiento de dado,

- $A = \text{“sale 2”}$;
- $B = \text{“sale 5”}$.

Son mutuamente excluyentes, pero conocer que ocurrió A hace que la probabilidad de B sea cero. Por tanto, no son independientes.

5.11. Independencia y complementos

Si A y B son independientes, también son independientes:

$$A^c \text{ y } B,$$

$$A \text{ y } B^c,$$

y

$$A^c \text{ y } B^c.$$

Por ejemplo,

$$P(A^c \cap B) = P(B) - P(A \cap B) = P(B) - P(A)P(B) = P(A^c)P(B).$$

5.12. Con reemplazo y sin reemplazo

La diferencia entre ambos esquemas aparece con frecuencia.

5.12.1. Con reemplazo

Si extraemos una pieza, registramos su estado y la devolvemos antes de la siguiente extracción, la composición original se conserva. Bajo las condiciones usuales de muestreo aleatorio, las extracciones sucesivas pueden modelarse como independientes.

5.12.2. Sin reemplazo

Si no devolvemos la pieza, la composición cambia y las probabilidades de las siguientes extracciones dependen de lo ocurrido antes.

Este contraste explica por qué el muestreo con y sin reemplazo produce modelos probabilísticos diferentes.

5.13. Aplicación: confiabilidad de dos módulos

Dos módulos electrónicos trabajan en paralelo. Sea

- A = “falla el módulo 1 durante la misión”;
- B = “falla el módulo 2 durante la misión”.

Supongamos

$$P(A) = 0.02, \quad P(B) = 0.03.$$

Si las fallas pueden considerarse independientes,

$$P(A \cap B) = 0.02(0.03) = 0.0006.$$

Por tanto, la probabilidad de que falle al menos uno es

$$P(A \cup B) = 0.02 + 0.03 - 0.0006 = 0.0494.$$

Pero la independencia debe justificarse. Si ambos módulos comparten fuente de alimentación, temperatura o vibración, una causa común puede volver dependientes sus fallas.

5.14. Aplicación: comunicaciones

Un paquete atraviesa dos enlaces. El primer enlace transmite correctamente con probabilidad 0.98. Si el primero transmite correctamente, el segundo lo hace con probabilidad 0.97.

La probabilidad de que el paquete supere ambos enlaces es

$$0.98(0.97) = 0.9506.$$

Obsérvese que no necesitamos asumir independencia para utilizar esta multiplicación: estamos usando explícitamente una probabilidad condicional.

5.15. Cálculos con R

5.15.1. Probabilidad condicional

```
p_A <- 0.10
p_B <- 0.30
p_AB <- 0.06

p_A_dado_B <- p_AB / p_B
p_B_dado_A <- p_AB / p_A

c(P_A_dado_B = p_A_dado_B,
  P_B_dado_A = p_B_dado_A)
```

```
P_A_dado_B P_B_dado_A
      0.2      0.6
```

5.15.2. Verificar independencia

```
es_independiente <- function(pA, pB, pAB, tol = 1e-10) {
  abs(pAB - pA * pB) < tol
}
```

```
es_independiente(0.5, 0.5, 0.25)
```

```
[1] TRUE
```

```
es_independiente(0.4, 0.3, 0.18)
```

```
[1] FALSE
```

5.16. Simulación: dependencia por muestreo sin reemplazo

```
set.seed(2026)
B <- 50000

resultado <- replicate(B, {
  caja <- c(rep("D", 3), rep("C", 5))
  muestra <- sample(caja, 2, replace = FALSE)
  c(D1 = muestra[1] == "D",
    D2 = muestra[2] == "D")
})

D1 <- resultado["D1", ]
D2 <- resultado["D2", ]

c(
  P_D1 = mean(D1),
  P_D2 = mean(D2),
  P_D2_dado_D1 = mean(D2[D1]),
  P_D1_inter_D2 = mean(D1 & D2),
  producto_marginales = mean(D1) * mean(D2)
)
```

	P_D1	P_D2	P_D2_dado_D1	P_D1_inter_D2
	0.3781200	0.3722800	0.2818682	0.1065800
producto_marginales	0.1407665			

Si hubiera independencia, esperaríamos que

$$P(D_2 \mid D_1) \approx P(D_2).$$

La simulación muestra que no ocurre: conocer el primer resultado cambia la composición de la caja.

5.17. Interactivo del capítulo

La edición web incluye un árbol dinámico con tres controles:

- $P(A)$;
- $P(B \mid A)$;
- $P(B \mid A^c)$.

El recurso calcula automáticamente las probabilidades de las cuatro hojas, obtiene $P(B)$ y compara

$$P(B \mid A) \quad \text{con} \quad P(B).$$

Cuando ambas cantidades coinciden, A y B son independientes. Así puede observarse visualmente que independencia significa que las ramas hacia B mantienen la misma probabilidad independientemente de que haya ocurrido A o A^c .

5.18. Actividad GeoGebra: árbol condicional

Construye un árbol con un deslizador p para $P(A)$ y dos deslizadores q_1 y q_0 para

$$P(B \mid A) = q_1, \quad P(B \mid A^c) = q_0.$$

Muestra en las hojas:

$$pq_1, \quad p(1 - q_1), \quad (1 - p)q_0, \quad (1 - p)(1 - q_0).$$

Después calcula

$$P(B) = pq_1 + (1 - p)q_0.$$

Explora qué ocurre cuando $q_1 = q_0$. Esa configuración representa independencia entre A y B .

5.19. Estrategia de solución

Ante un problema condicional:

1. Define los eventos antes de sustituir números.
2. Identifica claramente cuál evento aparece después de la barra $|$.
3. Pregunta si la información reduce el universo de referencia.
4. Si el problema es secuencial, considera un árbol.
5. Para una trayectoria, multiplica las probabilidades de sus ramas.
6. No supongas independencia sólo porque el problema no menciona dependencia.
7. Si se afirma independencia, aprovecha

$$P(A \cap B) = P(A)P(B).$$

8. Interpreta el resultado con palabras.

5.20. Errores frecuentes

- Intercambiar $P(A | B)$ y $P(B | A)$.
- Multiplicar $P(A)P(B)$ sin haber establecido independencia.
- Sumar probabilidades a lo largo de una misma trayectoria del árbol; en una trayectoria se multiplican.
- Confundir independencia con eventos mutuamente excluyentes.
- Usar una probabilidad condicional cuyo evento condicionante tiene probabilidad cero.
- Ignorar que el muestreo sin reemplazo modifica las probabilidades posteriores.

5.21. Resumen

Si $P(B) > 0$,

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

La regla del producto es

$$P(A \cap B) = P(B)P(A | B) = P(A)P(B | A).$$

Dos eventos son independientes si

$$P(A \cap B) = P(A)P(B).$$

Cuando las probabilidades condicionales están definidas, la independencia equivale a que conocer uno de los eventos no altere la probabilidad del otro.

5.22. Ejercicios

1. Si $P(A) = 0.45$, $P(B) = 0.50$ y $P(A \cap B) = 0.20$, calcula $P(A | B)$ y $P(B | A)$.
2. Una empresa recibe 40 % de sus componentes del proveedor 1. El 3 % de todos los componentes son simultáneamente del proveedor 1 y defectuosos. Calcula la probabilidad de defecto dado que el componente proviene del proveedor 1.
3. De una caja con 6 piezas conformes y 4 defectuosas se extraen dos sin reemplazo. Calcula la probabilidad de que ambas sean defectuosas.
4. Repite el ejercicio anterior suponiendo reemplazo y compara los resultados.
5. Sean $P(A) = 0.60$, $P(B) = 0.25$ y $P(A \cap B) = 0.15$. ¿Son independientes? Justifica.
6. Sean A y B mutuamente excluyentes con $P(A) = 0.20$ y $P(B) = 0.30$. ¿Son independientes? Explica.
7. Un sistema tiene tres etapas con probabilidades condicionales de éxito 0.98, 0.95 y 0.99 a lo largo de una trayectoria de operación normal. Calcula la probabilidad de completar las tres etapas.
8. Construye en R un árbol de dos etapas para $P(A) = 0.35$, $P(B | A) = 0.80$ y $P(B | A^c) = 0.25$. Obtén las cuatro hojas y verifica que sumen 1.
9. Simula 100 000 extracciones dobles sin reemplazo de una urna con 5 bolas blancas y 3 negras. Estima $P(N_2 | N_1)$ y compárala con $P(N_2)$.
10. **Reto** . Si A y B son independientes, demuestra utilizando reglas de probabilidad que A^c y B^c también son independientes.

5.23. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

5.24. Referencias del capítulo

El tratamiento de probabilidad condicional, regla del producto, árboles e independencia sigue el desarrollo estándar de probabilidad para ingeniería y ciencias de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, simulaciones y código R de este capítulo son originales; para el enfoque computacional se toma como referencia general Kerns (2010).

6 Particiones, probabilidad total y teorema de Bayes

6.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- reconocer una partición del espacio muestral;
- aplicar la ley de la probabilidad total;
- utilizar el teorema de Bayes para actualizar probabilidades;
- distinguir probabilidades previas, verosimilitudes y probabilidades posteriores;
- construir árboles de probabilidad para organizar cálculos;
- interpretar el efecto de las tasas base en problemas de diagnóstico;
- resolver problemas de calidad, confiabilidad y clasificación;
- implementar cálculos de Bayes en R;
- explorar mediante un interactivo cómo cambia una probabilidad posterior al modificar la evidencia.

6.2. Por qué necesitamos una partición

En muchos problemas un mismo evento puede ocurrir por diferentes causas o rutas. Una forma natural de organizar esas posibilidades es dividir el espacio muestral en regiones mutuamente excluyentes que, juntas, cubran todo el espacio.

Una colección de eventos

$$B_1, B_2, \dots, B_k$$

forma una **partición** de Ω si:

1. $B_i \cap B_j = \emptyset$ para $i \neq j$;
2. $B_1 \cup B_2 \cup \dots \cup B_k = \Omega$;
3. $P(B_i) > 0$ para los eventos que utilizaremos como condicionantes.

Cada resultado pertenece exactamente a una de las partes.

6.2.1. Ejemplo: proveedores

Una planta recibe componentes de tres proveedores:

$$B_1 = \{\text{proveedor 1}\}, \quad B_2 = \{\text{proveedor 2}\}, \quad B_3 = \{\text{proveedor 3}\}.$$

Si todo componente proviene de uno y sólo uno de ellos, entonces B_1, B_2, B_3 forman una partición.

6.3. Ley de la probabilidad total

Sea A un evento y $B_1, \dots, B_k$ una partición. Como

$$A = (A \cap B_1) \cup (A \cap B_2) \cup \dots \cup (A \cap B_k),$$

y esas intersecciones son mutuamente excluyentes,

$$P(A) = \sum_{i=1}^k P(A \cap B_i).$$

Aplicando la regla del producto,

$$P(A \cap B_i) = P(B_i)P(A \mid B_i),$$

obtenemos

$$P(A) = \sum_{i=1}^k P(B_i)P(A \mid B_i).$$

Esta expresión se conoce como **ley de la probabilidad total**.

6.4. Ejemplo: defectos por proveedor

Una empresa compra componentes de tres proveedores:

$$P(B_1) = 0.50, \quad P(B_2) = 0.30, \quad P(B_3) = 0.20.$$

Las tasas de defecto son

$$P(D \mid B_1) = 0.01,$$

$$P(D \mid B_2) = 0.03,$$

$$P(D \mid B_3) = 0.05.$$

La probabilidad total de seleccionar un componente defectuoso es

$$\begin{aligned} P(D) &= 0.50(0.01) + 0.30(0.03) + 0.20(0.05) \\ &= 0.005 + 0.009 + 0.010 \\ &= 0.024. \end{aligned}$$

Por tanto, 2.4 % de los componentes recibidos son defectuosos en promedio.

6.5. De la causa al efecto y del efecto a la causa

La probabilidad total permite calcular un efecto a partir de las posibles causas:

$$P(D \mid B_i) \longrightarrow P(D).$$

Pero muchas veces observamos primero el efecto y queremos inferir la causa.

Por ejemplo:

Si encontramos un componente defectuoso, ¿qué probabilidad hay de que provenga del proveedor 3?

La cantidad buscada es

$$P(B_3 \mid D).$$

Ésta es precisamente la pregunta que resuelve el teorema de Bayes.

6.6. Teorema de Bayes

Por definición de probabilidad condicional,

$$P(B_i \mid A) = \frac{P(B_i \cap A)}{P(A)}.$$

Por la regla del producto,

$$P(B_i \cap A) = P(B_i)P(A \mid B_i).$$

Y por la probabilidad total,

$$P(A) = \sum_{j=1}^k P(B_j)P(A \mid B_j).$$

Sustituyendo,

$$P(B_i \mid A) = \frac{P(B_i)P(A \mid B_i)}{\sum_{j=1}^k P(B_j)P(A \mid B_j)}.$$

6.7. Continuación del ejemplo de proveedores

Queremos calcular

$$P(B_3 | D).$$

Ya sabemos que

$$P(D) = 0.024.$$

Entonces

$$P(B_3 | D) = \frac{0.20(0.05)}{0.024} = \frac{0.010}{0.024} \approx 0.4167.$$

Aunque sólo 20 % de los componentes provienen del proveedor 3, entre los defectuosos aproximadamente 41.7 % proceden de él. La razón es que su tasa de defecto es mayor.

6.8. Interpretación bayesiana elemental

En una aplicación de Bayes aparecen tres ideas:

- **Probabilidad previa:** $P(B_i)$. Representa lo que sabemos sobre la causa antes de observar el evento A .
- **Verosimilitud:** $P(A | B_i)$. Mide qué tan compatible es la evidencia observada con esa causa.
- **Probabilidad posterior:** $P(B_i | A)$. Es la probabilidad actualizada después de incorporar la evidencia.

Podemos resumir la lógica como

$$\text{posterior} \propto \text{previa} \times \text{verosimilitud}.$$

La constante de normalización es $P(A)$.

6.9. Árbol de probabilidad

Los árboles son especialmente útiles en estos problemas.

Primero se ramifica según la causa:

$$B_1, B_2, \dots, B_k.$$

Después, desde cada causa, se ramifica según la evidencia A o A^c .

La probabilidad de una hoja es el producto de sus ramas:

$$P(B_i \cap A) = P(B_i)P(A | B_i).$$

Para calcular $P(A)$ se suman todas las hojas que terminan en A . Para Bayes se divide la hoja correspondiente entre esa suma.

6.10. Ejemplo de diagnóstico

Supongamos una condición médica con prevalencia

$$P(E) = 0.01.$$

Una prueba tiene sensibilidad

$$P(+ | E) = 0.95$$

y especificidad

$$P(- | E^c) = 0.90.$$

Entonces la tasa de falso positivo es

$$P(+ | E^c) = 0.10.$$

La probabilidad total de obtener un resultado positivo es

$$P(+) = 0.01(0.95) + 0.99(0.10) = 0.1085.$$

Por Bayes,

$$P(E | +) = \frac{0.01(0.95)}{0.1085} \approx 0.0876.$$

Es decir, un resultado positivo no implica una probabilidad posterior de 95 %. En este ejemplo es aproximadamente 8.8 %.

6.11. La importancia de la tasa base

El ejemplo anterior ilustra la **falacia de la tasa base**: confundir la sensibilidad $P(+ | E)$ con la probabilidad posterior $P(E | +)$.

Cuando una condición es poco frecuente, puede haber muchos falsos positivos incluso con una prueba razonablemente precisa.

6.11.1. Interpretación con 10 000 personas

En una población de 10 000 personas:

- aproximadamente 100 tienen la condición;
- de ellas, unas 95 resultan positivas;
- aproximadamente 9900 no tienen la condición;
- con una tasa de falso positivo de 10 %, unas 990 resultan positivas.

En total habría aproximadamente

$$95 + 990 = 1085$$

resultados positivos, de los cuales sólo 95 corresponden a personas con la condición:

$$\frac{95}{1085} \approx 0.0876.$$

La tabla de frecuencias suele hacer Bayes mucho más intuitivo.

6.12. Aplicación: detección de fallas

Un sistema puede operar en dos estados:

$$F = \{\text{falla real}\}, \quad F^c = \{\text{sin falla}\}.$$

Supongamos

$$P(F) = 0.04,$$

$$P(A \mid F) = 0.92,$$

$$P(A \mid F^c) = 0.08,$$

donde A significa “se activa la alarma”.

Entonces

$$P(A) = 0.04(0.92) + 0.96(0.08) = 0.1136.$$

Y

$$P(F \mid A) = \frac{0.04(0.92)}{0.1136} \approx 0.3239.$$

La alarma aumenta la probabilidad de falla de 4 % a aproximadamente 32.4 %, pero no la convierte en certeza.

6.13. Actualización sucesiva

Bayes también puede utilizarse de manera secuencial. Una probabilidad posterior obtenida con una primera evidencia puede convertirse en la nueva probabilidad previa cuando llega una segunda evidencia.

Conceptualmente:

$$P(H) \xrightarrow{E_1} P(H | E_1) \xrightarrow{E_2} P(H | E_1, E_2).$$

Esta idea aparece en filtrado, diagnóstico iterativo, clasificación y sistemas de decisión.

6.14. Cálculos con R

6.14.1. Probabilidad total

```
p_proveedor <- c(0.50, 0.30, 0.20)
p_defecto_dado_proveedor <- c(0.01, 0.03, 0.05)

p_defecto <- sum(p_proveedor * p_defecto_dado_proveedor)
p_defecto
```

```
[1] 0.024
```

6.14.2. Bayes para todos los proveedores

```
posterior <- p_proveedor * p_defecto_dado_proveedor / p_defecto
posterior
```

```
[1] 0.2083333 0.3750000 0.4166667
```

```
sum(posterior)
```

```
[1] 1
```

La suma de las probabilidades posteriores debe ser 1.

6.14.3. Función general

```
bayes_discreto <- function(prior, likelihood) {  
  numerador <- prior * likelihood  
  numerador / sum(numerador)  
}  
  
bayes_discreto(  
  prior = c(0.50, 0.30, 0.20),  
  likelihood = c(0.01, 0.03, 0.05)  
)
```

```
[1] 0.2083333 0.3750000 0.4166667
```

6.15. Simulación de un problema de diagnóstico

```
set.seed(2026)  
n <- 200000  
  
estado <- rbinom(n, size = 1, prob = 0.01)  
positivo <- ifelse(  
  estado == 1,  
  rbinom(n, size = 1, prob = 0.95),  
  rbinom(n, size = 1, prob = 0.10)  
)  
  
mean(estado == 1)
```

```
[1] 0.010285
```

```
mean(positivo == 1)
```

```
[1] 0.110065
```

```
mean(estados[positivo == 1] == 1)
```

```
[1] 0.08931086
```

La última cantidad aproxima $P(E \mid +)$ y debe acercarse al resultado teórico.

6.16. Interactivo del capítulo

La edición web incluye un recurso de Bayes para dos hipótesis. El estudiante puede modificar:

- la probabilidad previa $P(H)$;
- la sensibilidad $P(+ \mid H)$;
- la tasa de falso positivo $P(+ \mid H^c)$.

El interactivo muestra en tiempo real:

$$P(+),$$

$$P(H \mid +),$$

y una representación mediante frecuencias esperadas por cada 1000 observaciones.

Esto permite visualizar inmediatamente el efecto de la prevalencia o tasa base.

6.17. Actividad con GeoGebra

Construye un árbol con dos primeras ramas:

$$H \text{ y } H^c.$$

Utiliza deslizadores para

$$p = P(H),$$

$$s = P(+ | H),$$

y

$$f = P(+ | H^c).$$

Muestra en las hojas

$$ps, \quad p(1-s), \quad (1-p)f, \quad (1-p)(1-f).$$

Después calcula

$$P(+) = ps + (1-p)f$$

y

$$P(H | +) = \frac{ps}{ps + (1-p)f}.$$

Mueve el deslizador p desde valores muy pequeños hasta valores grandes y observa cómo cambia la probabilidad posterior aun manteniendo constantes las características de la prueba.

6.18. Estrategia para resolver problemas de Bayes

1. Identifica las posibles causas o hipótesis.
2. Comprueba que formen una partición.
3. Escribe sus probabilidades previas.
4. Escribe la probabilidad de la evidencia bajo cada causa.
5. Calcula la probabilidad total de la evidencia.
6. Aplica Bayes a la causa que interesa.
7. Comprueba que el resultado esté entre 0 y 1.
8. Si calculas todas las posteriores, verifica que sumen 1.
9. Interpreta el resultado en palabras y compáralo con la probabilidad previa.

6.19. Errores frecuentes

- Confundir $P(A | B)$ con $P(B | A)$.
- Omitir alguna rama al calcular la probabilidad total.
- Utilizar probabilidades previas que no suman 1.
- Confundir sensibilidad con valor predictivo positivo.
- Ignorar la tasa base o prevalencia.
- Sumar probabilidades dentro de una trayectoria del árbol; las ramas de una trayectoria se multiplican.
- Interpretar una probabilidad posterior como certeza.

6.20. Resumen

Si $B_1, \dots, B_k$ forman una partición,

$$P(A) = \sum_{i=1}^k P(B_i)P(A | B_i).$$

El teorema de Bayes es

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_{j=1}^k P(B_j)P(A | B_j)}.$$

Bayes actualiza una probabilidad previa utilizando evidencia observada. La magnitud de la probabilidad posterior depende tanto de la evidencia como de la tasa base.

6.21. Ejercicios

1. Tres máquinas producen 40 %, 35 % y 25 % de la producción. Sus tasas de defecto son 1 %, 2 % y 4 %. Calcula la probabilidad de seleccionar una pieza defectuosa.
2. Para el ejercicio anterior, si una pieza es defectuosa, calcula la probabilidad de que provenga de la tercera máquina.
3. Una prueba tiene sensibilidad 0.90, especificidad 0.95 y la prevalencia de una condición es 0.02. Calcula $P(+)$ y $P(E | +)$.
4. Repite el ejercicio anterior para prevalencias 0.10 y 0.50. Explica el efecto de la tasa base.

5. Una alarma se activa con probabilidad 0.97 cuando existe una falla y con probabilidad 0.04 cuando no existe. Si la probabilidad previa de falla es 0.03, calcula la probabilidad de falla dada una alarma.
6. Construye en R una función que reciba un vector de probabilidades previas y un vector de verosimilitudes y devuelva el vector posterior.
7. Simula en R el ejercicio 3 con 500 000 observaciones y compara el valor simulado con el teórico.
8. En una población de 100 000 personas, traduce el ejercicio 3 a frecuencias naturales y explica Bayes sin usar fórmulas.
9. Dos proveedores entregan 70 % y 30 % de las piezas. Una inspección rechaza una pieza con probabilidad 0.08 si proviene del primero y 0.18 si proviene del segundo. Si una pieza fue rechazada, ¿de cuál proveedor es más probable que proceda?
10. **Reto** . Demuestra que si $B_1, \dots, B_k$ forman una partición, entonces las probabilidades posteriores $P(B_i | A)$ suman 1 siempre que $P(A) > 0$.

6.22. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.

Material	Formato	Acceso	Propósito
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

6.23. Referencias del capítulo

La exposición de particiones, probabilidad total y teorema de Bayes se apoya en el tratamiento estándar de probabilidad para ingeniería y ciencias de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). El código R, las simulaciones y los ejemplos del capítulo son originales; el enfoque computacional general es consistente con Kerns (2010).

7 Variable aleatoria y función de distribución acumulada

7.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- interpretar una variable aleatoria como una función definida sobre el espacio muestral;
- distinguir entre resultados del experimento y valores numéricos de una variable aleatoria;
- identificar variables aleatorias discretas y continuas;
- construir y utilizar la función de distribución acumulada;
- interpretar probabilidades mediante $F_X(x) = P(X \leq x)$;
- recuperar probabilidades de intervalos a partir de la función de distribución;
- representar variables aleatorias y funciones de distribución con R;
- utilizar simulación para estudiar distribuciones empíricas;
- explorar interactivamente cómo una variable aleatoria transforma resultados en valores numéricos.

7.2. Del resultado del experimento a un número

Un experimento aleatorio produce resultados en un espacio muestral Ω . Sin embargo, en muchas aplicaciones no interesa conservar toda la descripción del resultado: necesitamos asociarle un valor numérico.

Una **variable aleatoria** es una función

$$X : \Omega \longrightarrow \mathbb{R}.$$

A cada resultado elemental $\omega \in \Omega$ le asigna un número real $X(\omega)$.

La palabra “variable” puede ser engañosa al principio. Una variable aleatoria no es un número que cambia caprichosamente: es una función perfectamente definida. Lo aleatorio proviene de que no sabemos qué ω ocurrirá.

7.3. Ejemplo: dos lanzamientos de moneda

Consideremos

$$\Omega = \{CC, CS, SC, SS\},$$

donde C significa cara y S sello. Definamos

$$X = \text{número de caras obtenidas.}$$

Entonces

$$X(CC) = 2,$$

$$X(CS) = X(SC) = 1,$$

y

$$X(SS) = 0.$$

La variable aleatoria transforma cuatro resultados elementales en sólo tres valores posibles:

$$\{0, 1, 2\}.$$

Si la moneda es equilibrada,

$$P(X = 0) = \frac{1}{4}, \quad P(X = 1) = \frac{1}{2}, \quad P(X = 2) = \frac{1}{4}.$$

7.4. Preimagen de un evento numérico

La expresión

$$\{X \leq 1\}$$

representa en realidad el conjunto de resultados elementales para los cuales la variable toma un valor menor o igual que 1:

$$\{X \leq 1\} = \{SS, CS, SC\}.$$

Por eso podemos escribir

$$P(X \leq 1) = \frac{3}{4}.$$

Esta conexión entre eventos en Ω e intervalos de números reales es central para toda la teoría de variables aleatorias.

7.5. Variables discretas y continuas

7.5.1. Variable aleatoria discreta

Una variable es **discreta** cuando sus valores posibles forman un conjunto finito o numerable.

Ejemplos:

- número de fallas en una máquina durante una semana;
- número de paquetes perdidos en una transmisión;
- número de pacientes que llegan a urgencias durante una hora;
- número de caras en varios lanzamientos de moneda.

7.5.2. Variable aleatoria continua

Una variable es **continua** cuando puede tomar valores en intervalos de la recta real.

Ejemplos:

- tiempo hasta la falla de un componente;
- concentración de ozono;
- temperatura;
- resistencia eléctrica medida en un material.

En los capítulos siguientes estudiaremos por separado las distribuciones discretas y continuas.

7.6. Función de distribución acumulada

Para cualquier variable aleatoria X , definimos su **función de distribución acumulada** por

$$F_X(x) = P(X \leq x)$$

para todo $x \in \mathbb{R}$.

La función F_X responde una pregunta muy concreta:

¿qué probabilidad se ha acumulado hasta el valor x ?

7.7. CDF del ejemplo de las dos monedas

Para $X =$ número de caras en dos lanzamientos,

$$P(X = 0) = \frac{1}{4}, \quad P(X = 1) = \frac{1}{2}, \quad P(X = 2) = \frac{1}{4}.$$

Por tanto,

$$F_X(x) = \begin{cases} 0, & x < 0, \\ \frac{1}{4}, & 0 \leq x < 1, \\ \frac{3}{4}, & 1 \leq x < 2, \\ 1, & x \geq 2. \end{cases}$$

La CDF de una variable discreta tiene forma escalonada. Cada salto corresponde a una probabilidad puntual.

7.8. Propiedades fundamentales de la CDF

Toda función de distribución acumulada satisface:

1. $0 \leq F_X(x) \leq 1$.
2. $F_X(x)$ es no decreciente.
- 3.

$$\lim_{x \rightarrow -\infty} F_X(x) = 0.$$

- 4.

$$\lim_{x \rightarrow \infty} F_X(x) = 1.$$

5. Es continua por la derecha:

$$\lim_{t \downarrow x} F_X(t) = F_X(x).$$

En una variable discreta, la magnitud del salto en x es precisamente

$$P(X = x) = F_X(x) - F_X(x^-),$$

donde

$$F_X(x^-) = \lim_{t \uparrow x} F_X(t).$$

7.9. Probabilidades de intervalos usando la CDF

La CDF permite obtener muchas probabilidades sin volver al espacio muestral.

7.9.1. Intervalo de la forma $(a, b]$

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

7.9.2. Probabilidad de exceder un valor

$$P(X > x) = 1 - F_X(x).$$

7.9.3. Probabilidad de un punto

En general,

$$P(X = x) = F_X(x) - F_X(x^-).$$

Para una variable continua, este salto es cero en todos los puntos.

7.10. Ejemplo de ingeniería

Sea X el número de paquetes perdidos en un bloque de transmisión y supongamos

$$P(X = 0) = 0.70,$$

$$P(X = 1) = 0.20,$$

$$P(X = 2) = 0.08,$$

$$P(X = 3) = 0.02.$$

Entonces

$$F_X(0) = 0.70,$$

$$F_X(1) = 0.90,$$

$$F_X(2) = 0.98,$$

y

$$F_X(3) = 1.$$

La probabilidad de perder más de un paquete es

$$P(X > 1) = 1 - F_X(1) = 0.10.$$

7.11. Construcción con R

Podemos representar una distribución discreta mediante sus valores y probabilidades.


```
x <- 0:3
p <- c(0.70, 0.20, 0.08, 0.02)
F <- cumsum(p)

data.frame(x = x, probabilidad = p, acumulada = F)
```

	x	probabilidad	acumulada
1	0	0.70	0.70
2	1	0.20	0.90
3	2	0.08	0.98
4	3	0.02	1.00

La función escalonada puede graficarse con:

```
plot(x, F, type = "s",
     ylim = c(0, 1),
     xlab = "x",
     ylab = "F_X(x)")
points(x, F, pch = 19)
```




7.12. Simulación y CDF empírica

La función `ecdf()` de R construye una función de distribución empírica a partir de una muestra.

```
set.seed(2026)
valores <- sample(
  0:3,
  size = 5000,
  replace = TRUE,
  prob = c(0.70, 0.20, 0.08, 0.02)
)
```

```
F_emp <- ecdf(valores)
plot(F_emp,
      xlab = "Número de paquetes perdidos",
      ylab = "Frecuencia acumulada")
```



Al aumentar el tamaño de la simulación, la CDF empírica se aproxima a la CDF teórica.

7.13. Variable aleatoria como transformación

En aplicaciones reales, una variable aleatoria resume aspectos relevantes de un resultado complejo.

Por ejemplo, el resultado de un sistema de sensores podría ser un vector completo de mediciones. Podemos definir

$$X(\omega) = \text{máxima temperatura registrada,}$$

o

$Y(\omega)$ = número de sensores que excedieron un umbral.

Dos variables diferentes pueden construirse sobre el mismo experimento y responder preguntas distintas.

7.14. Interactivo del capítulo

La edición web incluye un recurso interactivo basado en tres lanzamientos de moneda. El estudiante puede elegir una regla de transformación, por ejemplo:

- número de caras;
- número de cambios entre resultados consecutivos;
- indicador de que aparece al menos una cara.

El recurso muestra:

1. los resultados del espacio muestral;
2. el valor $X(\omega)$ asignado a cada resultado;
3. la distribución de probabilidades de X ;
4. la función acumulada $F_X(x)$.

Así se observa directamente que una variable aleatoria es una función que agrupa resultados y que la CDF acumula probabilidades.

7.15. Actividad con GeoGebra

Representa en una tabla los valores posibles $x_1 < \dots < x_m$ y sus probabilidades p_i . Construye los acumulados

$$F_i = \sum_{j=1}^i p_j.$$

Después representa la función escalonada que mantiene el valor F_i desde x_i hasta antes de x_{i+1} .

Utiliza deslizadores para modificar las probabilidades p_i manteniendo

$$\sum_i p_i = 1.$$

Observa cómo cambian simultáneamente la distribución puntual y la CDF.

7.16. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Experimentar con transformaciones y CDF mediante código ejecutable.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir los ejemplos y simulaciones del capítulo en R/RStudio.
Interactivo	HTML/GeoGebra	Integrado en la edición web	Explorar visualmente la transformación $\omega \mapsto X(\omega)$ y la CDF.
Presentación	PDF / PPT	Próximamente	Material de clase; se incorporará cuando estén disponibles los enlaces.
Video	Video	Próximamente	Explicación audiovisual del capítulo.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas principales.

Los **cuadernos de R** acompañan cada capítulo para que los ejemplos puedan reproducirse, modificarse y extenderse localmente en R/RStudio. Los cuadernos de Google Colab permiten trabajar desde el navegador sin preparar previamente el entorno local.

7.17. Errores frecuentes

- Confundir el resultado ω con el número $X(\omega)$.
- Pensar que una variable aleatoria debe tomar valores diferentes para todos los resultados.
- Confundir $P(X = x)$ con $F_X(x)$.
- Olvidar que $F_X(x)$ utiliza $X \leq x$, no $X < x$.
- Dibujar una CDF decreciente.
- Suponer que toda CDF debe ser continua.

7.18. Resumen

Una variable aleatoria es una función

$$X : \Omega \rightarrow \mathbb{R}.$$

Su función de distribución acumulada es

$$F_X(x) = P(X \leq x).$$

La CDF existe para cualquier variable aleatoria, discreta o continua, y permite obtener probabilidades de intervalos. En los próximos capítulos estudiaremos las funciones específicas que describen distribuciones discretas y continuas.

7.19. Ejercicios

1. Para tres lanzamientos de moneda, define $X =$ número de caras. Construye la tabla de valores posibles y probabilidades.
2. Para la variable del ejercicio anterior, escribe explícitamente $F_X(x)$.
3. Calcula $P(1 < X \leq 3)$ utilizando la CDF.
4. Sea X el número de fallas de una unidad con probabilidades 0.55, 0.30, 0.10, 0.05 para $x = 0, 1, 2, 3$. Construye su CDF.
5. Con la distribución anterior calcula $P(X > 1)$ y $P(X \leq 2)$.
6. Implementa en R una función que reciba un vector de probabilidades y devuelva sus acumulados.
7. Simula 20 000 observaciones de la distribución del ejercicio 4 y compara la CDF empírica con la teórica.

8. Propón dos variables aleatorias diferentes definidas sobre el resultado de dos dados y explica qué información resume cada una.
9. ¿Puede una variable aleatoria asignar el mismo valor a varios resultados? Explica con un ejemplo.
10. **Reto** . Demuestra, usando propiedades de probabilidad, que toda CDF es no decreciente.

7.20. Referencias del capítulo

El concepto de variable aleatoria y función de distribución acumulada sigue el tratamiento estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). El código y las simulaciones son originales y se desarrollan en el espíritu computacional de Kerns (2010).

8 Variables aleatorias discretas y función de masa de probabilidad

8.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- reconocer cuándo una variable aleatoria es discreta;
- identificar su soporte o conjunto de valores posibles;
- construir una función de masa de probabilidad;
- verificar que una función propuesta puede ser una PMF válida;
- calcular probabilidades mediante sumas de masas;
- relacionar la PMF con la función de distribución acumulada;
- construir tablas y gráficas de distribuciones discretas;
- utilizar R para calcular, representar y simular variables discretas;
- explorar interactivamente cómo cambian la PMF y la CDF al modificar probabilidades.

8.2. De la variable aleatoria a su distribución

En el capítulo anterior introdujimos una variable aleatoria como una función

$$X : \Omega \rightarrow \mathbb{R}.$$

Ahora nos concentraremos en el caso en que X sólo puede tomar valores aislados: por ejemplo,

$$0, 1, 2, 3,$$

o bien

$$0, 1, 2, \dots$$

Este tipo de variable aparece de manera natural cuando contamos objetos, fallas, llamadas, defectos, éxitos o eventos.

8.3. Variable aleatoria discreta

Una variable aleatoria X es **discreta** cuando su conjunto de valores posibles es finito o infinito numerable.

Ejemplos:

- número de piezas defectuosas en una muestra de 10;
- número de paquetes perdidos durante una hora;
- número de intentos necesarios hasta lograr una transmisión correcta;
- número de alarmas activadas en una red de sensores;
- número de pacientes que llegan a un servicio durante un intervalo.

El conjunto de valores posibles de X se denomina **soporte** y puede escribirse como

$$\mathcal{S}_X = \{x : P(X = x) > 0\}.$$

8.4. Función de masa de probabilidad

Para una variable aleatoria discreta, definimos la **función de masa de probabilidad** o PMF por

$$p_X(x) = P(X = x).$$

Para que una función sea una PMF válida debe satisfacer:

$$p_X(x) \geq 0$$

para todo x , y

$$\sum_{x \in \mathcal{S}_X} p_X(x) = 1.$$

Estas dos condiciones expresan exactamente los axiomas fundamentales de la probabilidad aplicados a los valores de una variable discreta.

8.5. Ejemplo: tres lanzamientos de moneda

Sea X el número de caras obtenidas al lanzar tres veces una moneda equilibrada.

El soporte es

$$\mathcal{S}_X = \{0, 1, 2, 3\}.$$

Los ocho resultados elementales son equiprobables. Al agruparlos según el valor de X obtenemos:

x	Resultados con $X = x$	$p_X(x)$
0	XXX	1/8
1	CXX, XCX, XXC	3/8
2	CCX, CXC, XCC	3/8
3	CCC	1/8

Por tanto,

$$p_X(0) = \frac{1}{8}, \quad p_X(1) = \frac{3}{8}, \quad p_X(2) = \frac{3}{8}, \quad p_X(3) = \frac{1}{8}.$$

Y comprobamos

$$\frac{1}{8} + \frac{3}{8} + \frac{3}{8} + \frac{1}{8} = 1.$$

8.6. Calcular probabilidades con una PMF

Si queremos la probabilidad de que X pertenezca a un conjunto A , sumamos las masas correspondientes:

$$P(X \in A) = \sum_{x \in A} p_X(x).$$

8.6.1. Ejemplo

Para la variable anterior,

$$P(X \geq 2) = p_X(2) + p_X(3) = \frac{3}{8} + \frac{1}{8} = \frac{1}{2}.$$

También

$$P(1 \leq X \leq 2) = p_X(1) + p_X(2) = \frac{3}{4}.$$

8.7. Construcción de una distribución a partir de una constante

Supongamos que una variable discreta tiene soporte

$$\{1, 2, 3, 4\}$$

y PMF

$$p_X(x) = cx, \quad x = 1, 2, 3, 4.$$

Para determinar c , utilizamos la condición de normalización:

$$\sum_{x=1}^4 cx = 1.$$

Entonces

$$c(1 + 2 + 3 + 4) = 1,$$

$$10c = 1,$$

por lo que

$$\boxed{c = 0.1}.$$

La distribución queda

$$p_X(1) = 0.1, \quad p_X(2) = 0.2, \quad p_X(3) = 0.3, \quad p_X(4) = 0.4.$$

8.8. Probabilidades mediante complemento

Aunque las probabilidades discretas se calculan sumando masas, a veces resulta más fácil utilizar el complemento.

Por ejemplo,

$$P(X \geq 1) = 1 - P(X = 0).$$

Si X representa el número de fallas en un periodo, esta forma es muy útil para calcular la probabilidad de **al menos una falla**.

8.9. Representación gráfica de la PMF

Una PMF se representa mediante barras o segmentos verticales en los valores posibles de X .

La altura en x es

$$p_X(x).$$

A diferencia de una densidad continua, aquí la probabilidad está concentrada directamente en puntos aislados.

8.9.1. R: gráfica de una PMF


```
x <- 0:3
p <- c(1, 3, 3, 1) / 8

plot(x, p,
     type = "h",
     lwd = 5,
```

```

ylim = c(0, 0.45),
xlab = "x",
ylab = "p_X(x)"
points(x, p, pch = 19)

```



8.10. Relación entre PMF y CDF

La función de distribución acumulada es

$$F_X(x) = P(X \leq x).$$

Si X es discreta,

$$F_X(x) = \sum_{t \leq x} p_X(t)$$

La CDF es, por tanto, la suma acumulada de las masas.

Para el ejemplo de tres monedas:

$$F_X(x) = \begin{cases} 0, & x < 0, \\ 1/8, & 0 \leq x < 1, \\ 4/8, & 1 \leq x < 2, \\ 7/8, & 2 \leq x < 3, \\ 1, & x \geq 3. \end{cases}$$

La CDF de una variable discreta tiene forma escalonada. Cada salto en x tiene tamaño

$$p_X(x).$$

8.11. Recuperar la PMF desde la CDF

En una variable discreta,

$$p_X(x) = F_X(x) - F_X(x^-)$$

donde $F_X(x^-)$ representa el valor límite de la CDF inmediatamente antes de x .

En términos intuitivos, la masa puntual es exactamente el tamaño del salto de la CDF.

8.12. Ejemplo de ingeniería: número de sensores activos

Un sistema contiene tres sensores. Después de una prueba se registra

X = número de sensores que responden correctamente.

Supongamos la siguiente distribución experimental:

x	0	1	2	3
$p_X(x)$	0.02	0.08	0.25	0.65

La probabilidad de que funcionen al menos dos sensores es

$$P(X \geq 2) = 0.25 + 0.65 = 0.90.$$

La probabilidad de que no funcionen los tres es

$$P(X < 3) = 1 - 0.65 = 0.35.$$

La distribución completa contiene mucho más información que una sola probabilidad aislada.

8.13. Ejemplo: número de retransmisiones

Supongamos que X es el número de retransmisiones requeridas por un paquete, con soporte

$$\{0, 1, 2, 3\}$$

y PMF

$$(0.70, 0.20, 0.08, 0.02).$$

Entonces

$$P(X \leq 1) = 0.70 + 0.20 = 0.90,$$

mientras que

$$P(X \geq 2) = 0.08 + 0.02 = 0.10.$$

La PMF permite cuantificar directamente el comportamiento operativo del sistema.

8.14. Construcción y cálculo en R

```
x <- 0:3
p <- c(0.70, 0.20, 0.08, 0.02)

sum(p)
```

```
[1] 1
```

```
p[p >= 0]
```

```
[1] 0.70 0.20 0.08 0.02
```

```
P_menor_igual_1 <- sum(p[x <= 1])
P_mayor_igual_2 <- sum(p[x >= 2])

c(P_X_le_1 = P_menor_igual_1,
  P_X_ge_2 = P_mayor_igual_2)
```

```
P_X_le_1 P_X_ge_2
      0.9      0.1
```

8.15. CDF a partir de una PMF en R


```
F <- cumsum(p)

data.frame(
  x = x,
  pmf = p,
  cdf = F
)
```

```
  x pmf cdf
1 0 0.70 0.70
2 1 0.20 0.90
3 2 0.08 0.98
4 3 0.02 1.00
```


Podemos representar la CDF con una gráfica escalonada:

```
plot(x, F,  
     type = "s",  
     ylim = c(0, 1.05),  
     xlab = "x",  
     ylab = "F_X(x)")  
points(x, F, pch = 19)
```



8.16. Simulación desde una PMF

En R podemos generar observaciones de una variable discreta mediante `sample()`:

```
set.seed(2026)  
n <- 20000  
  
muestra <- sample(  
  x,  
  size = n,
```

```

    replace = TRUE,
    prob = p
  )

tabla <- prop.table(table(muestra))
tabla

```

```

muestra
      0      1      2      3
0.70030 0.19845 0.08065 0.02060

```

Las frecuencias relativas se aproximan a las probabilidades teóricas cuando el tamaño de la simulación es grande.

8.17. Comparación entre distribución teórica y empírica

```

teorica <- p
empirica <- as.numeric(tabla[as.character(x)])

comparacion <- data.frame(
  x = x,
  teorica = teorica,
  empirica = empirica
)
comparacion

```

```

  x teorica empirica
1 0    0.70  0.70030
2 1    0.20  0.19845
3 2    0.08  0.08065
4 3    0.02  0.02060

```

Esta comparación ayuda a distinguir entre:

- una **distribución teórica**, definida por el modelo;
- una **distribución empírica**, obtenida a partir de observaciones.

8.18. Interactivo del capítulo

La edición web incluye un recurso que permite modificar las probabilidades asociadas a cuatro valores discretos.

El interactivo:

- normaliza automáticamente las masas para que sumen 1;
- muestra la PMF mediante barras;
- construye la CDF acumulada;
- permite seleccionar un valor x y leer $p_X(x)$ y $F_X(x)$;
- muestra visualmente que el tamaño de cada salto de la CDF coincide con la masa puntual.

Esta relación entre PMF y CDF será central en los siguientes capítulos.

8.19. Actividad con GeoGebra

Construye cuatro deslizadores positivos w_0, w_1, w_2, w_3 y define

$$p_i = \frac{w_i}{w_0 + w_1 + w_2 + w_3}.$$

Representa las barras

$$(0, p_0), (1, p_1), (2, p_2), (3, p_3)$$

y calcula las acumuladas

$$F_0 = p_0,$$

$$F_1 = p_0 + p_1,$$

$$F_2 = p_0 + p_1 + p_2,$$

$$F_3 = 1.$$

Mueve los deslizadores y observa simultáneamente cómo cambia la distribución puntual y su acumulación.

8.20. Validación de una PMF

Ante una función propuesta $p(x)$, verifica siempre:

1. que ningún valor sea negativo;
2. que la suma de todas las masas sea 1;
3. que el soporte esté claramente identificado.

8.20.1. Ejemplo de función inválida

Supongamos

$$p_X(0) = 0.20, \quad p_X(1) = 0.55, \quad p_X(2) = 0.40.$$

Aunque todos los valores son no negativos,

$$0.20 + 0.55 + 0.40 = 1.15,$$

por lo que no puede ser una distribución de probabilidad válida.

8.21. Errores frecuentes

- Confundir $p_X(x)$ con $F_X(x)$.
- Olvidar que las masas deben sumar 1.
- Asignar probabilidad positiva a valores fuera del soporte.
- Interpretar la altura de una PMF como densidad continua.
- Sumar valores de x en lugar de sumar probabilidades.
- Utilizar una gráfica de barras sin distinguir entre frecuencia empírica y probabilidad teórica.

8.22. Resumen

Una variable aleatoria discreta toma valores en un conjunto finito o numerable. Su PMF es

$$p_X(x) = P(X = x),$$

con

$$p_X(x) \geq 0, \quad \sum_x p_X(x) = 1.$$

Las probabilidades de eventos se obtienen sumando masas:

$$P(X \in A) = \sum_{x \in A} p_X(x).$$

La CDF se obtiene acumulando:

$$F_X(x) = \sum_{t \leq x} p_X(t).$$

Y la masa puntual coincide con el tamaño del salto de la CDF.

8.23. Ejercicios

1. Una variable tiene soporte $\{0, 1, 2, 3\}$ y PMF $(0.10, 0.25, 0.40, 0.25)$. Calcula $P(X \geq 2)$, $P(X < 2)$ y $P(1 \leq X \leq 3)$.
2. Decide si $(0.15, 0.30, 0.35, 0.25)$ define una PMF válida. Justifica.
3. Sea $p_X(x) = c(x + 1)$ para $x = 0, 1, 2, 3$. Determina c y calcula $P(X \geq 2)$.
4. Construye la CDF completa del ejercicio anterior.
5. El número de sensores activos tiene distribución $(0.01, 0.04, 0.20, 0.75)$ para $x = 0, 1, 2, 3$. Calcula la probabilidad de que funcionen al menos dos.
6. Representa en R la PMF y CDF del ejercicio 5.
7. Simula 50 000 valores de la distribución del ejercicio 5 y compara las frecuencias empíricas con las probabilidades teóricas.
8. Una CDF presenta saltos de tamaños 0.20, 0.35 y 0.45 en $x = 1, 2, 5$. Escribe la PMF correspondiente.

9. Explica por qué una variable discreta puede tener soporte infinito numerable aunque la suma total de probabilidades deba ser 1.
10. **Reto** . Supón que X tiene soporte $\{1, 2, 3, \dots\}$ y

$$p_X(x) = \frac{c}{2^x}.$$

Determina c y calcula $P(X \geq 4)$.

8.24. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

8.25. Referencias del capítulo

El tratamiento de variables aleatorias discretas, funciones de masa y funciones de distribución acumulada sigue la organización estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, ejercicios, simulaciones y código R son originales; el enfoque computacional general toma como referencia Kerns (2010).

9 Variables aleatorias continuas y función de densidad

9.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- reconocer cuándo una variable aleatoria se modela como continua;
- interpretar una función de densidad de probabilidad;
- verificar si una función propuesta puede ser una densidad válida;
- calcular probabilidades como áreas bajo una curva;
- relacionar la densidad con la función de distribución acumulada;
- comprender por qué $P(X = x) = 0$ para una variable continua;
- calcular probabilidades de intervalos mediante integrales;
- utilizar R para integrar, graficar y simular modelos continuos;
- explorar interactivamente cómo cambia un área de probabilidad al mover los límites de un intervalo.

9.2. De los conteos a las mediciones

Las variables discretas aparecen cuando contamos. Las variables continuas aparecen con frecuencia cuando **medimos**.

Ejemplos típicos son:

- tiempo de vida de un componente;
- temperatura ambiental;
- concentración de un contaminante;
- voltaje de una señal;
- diámetro de una pieza manufacturada;
- velocidad de un vehículo;
- duración de una llamada.

Aunque un instrumento digital muestre un número finito de decimales, el modelo matemático suele considerar que la variable puede tomar cualquier valor dentro de un intervalo.

9.3. Variable aleatoria continua

En un modelo elemental, decimos que una variable aleatoria X es **continua** cuando existe una función no negativa $f_X(x)$ tal que las probabilidades pueden obtenerse mediante áreas:

$$P(a < X < b) = \int_a^b f_X(x) dx.$$

La función f_X se denomina **función de densidad de probabilidad**, o PDF por sus siglas en inglés.

9.4. Condiciones para una densidad válida

Una función f_X es una densidad de probabilidad si satisface:

$$f_X(x) \geq 0$$

para todo x , y

$$\boxed{\int_{-\infty}^{\infty} f_X(x) dx = 1}.$$

La segunda condición expresa que el área total bajo la curva es 1.

9.5. La densidad no es una probabilidad puntual

Ésta es una diferencia fundamental respecto de una PMF discreta.

Para una variable continua,

$$\boxed{P(X = x) = 0}.$$

Por tanto,

$$f_X(x) \neq P(X = x).$$

La densidad describe **concentración de probabilidad alrededor de un valor**, mientras que la probabilidad se obtiene integrando sobre un intervalo.

Una densidad incluso puede tomar valores mayores que 1 sin violar las reglas de probabilidad, siempre que el área total sea 1.

9.6. Probabilidad como área

Si $a < b$, entonces

$$\boxed{P(a < X < b) = \int_a^b f_X(x) dx}.$$

Como un punto aislado tiene probabilidad cero, para variables continuas no importa incluir o excluir los extremos:

$$P(a < X < b) = P(a \leq X < b) = P(a < X \leq b) = P(a \leq X \leq b).$$

Esta igualdad no es cierta, en general, para variables discretas.

9.7. Ejemplo: densidad uniforme elemental

Supongamos que

$$f_X(x) = \begin{cases} \frac{1}{10}, & 0 \leq x \leq 10, \\ 0, & \text{en otro caso.} \end{cases}$$

El área total es

$$\int_0^{10} \frac{1}{10} dx = 1.$$

La probabilidad de observar un valor entre 2 y 6 es

$$P(2 \leq X \leq 6) = \int_2^6 \frac{1}{10} dx = \frac{4}{10} = 0.4.$$

9.8. Determinar una constante de normalización

Sea

$$f_X(x) = \begin{cases} cx, & 0 \leq x \leq 2, \\ 0, & \text{en otro caso.} \end{cases}$$

Para que sea una densidad,

$$\int_0^2 cx dx = 1.$$

Entonces

$$c \left[\frac{x^2}{2} \right]_0^2 = 1,$$

$$2c = 1,$$

por lo que

$$c = \frac{1}{2}.$$

La densidad es

$$f_X(x) = \frac{x}{2}, \quad 0 \leq x \leq 2.$$

Por ejemplo,

$$P(0.5 < X < 1.5) = \int_{0.5}^{1.5} \frac{x}{2} dx = 0.5.$$

9.9. Función de distribución acumulada

Para cualquier variable aleatoria,

$$F_X(x) = P(X \leq x).$$

Si X tiene densidad f_X , entonces

$$F_X(x) = \int_{-\infty}^x f_X(t) dt.$$

La CDF acumula el área situada a la izquierda de x .

Cuando F_X es diferenciable,

$$f_X(x) = F'_X(x).$$

Así, densidad y distribución acumulada son dos formas relacionadas de describir el mismo modelo continuo.

9.10. Ejemplo de CDF a partir de una densidad

Para

$$f_X(x) = \frac{x}{2}, \quad 0 \leq x \leq 2,$$

obtenemos

$$F_X(x) = \begin{cases} 0, & x < 0, \\ \frac{x^2}{4}, & 0 \leq x \leq 2, \\ 1, & x > 2. \end{cases}$$

Podemos verificar que

$$F_X(2) = 1.$$

Además,

$$P(0.5 < X < 1.5) = F_X(1.5) - F_X(0.5).$$

9.11. Probabilidades mediante la CDF

Para $a < b$,

$$P(a < X \leq b) = F_X(b) - F_X(a).$$

En el caso continuo, como $P(X = a) = 0$,

$$P(a < X < b) = F_X(b) - F_X(a).$$

También

$$P(X > x) = 1 - F_X(x).$$

Estas relaciones serán muy útiles cuando trabajemos con distribuciones continuas conocidas.

9.12. Ejemplo de ingeniería: error de medición

Sea X el error, en milímetros, de un instrumento de inspección. Supongamos que el modelo asigna una densidad triangular sobre el intervalo $[-1, 1]$:

$$f_X(x) = \begin{cases} 1 - |x|, & -1 \leq x \leq 1, \\ 0, & \text{en otro caso.} \end{cases}$$

El área total es 1. La probabilidad de que el error absoluto sea menor que 0.25 mm es

$$P(|X| < 0.25) = \int_{-0.25}^{0.25} (1 - |x|) dx.$$

Por simetría,

$$P(|X| < 0.25) = 2 \int_0^{0.25} (1 - x) dx = 0.4375.$$

Este tipo de cálculo relaciona directamente una tolerancia de ingeniería con un área de probabilidad.

9.13. Ejemplo ambiental: concentración de un contaminante

Supongamos que X representa una concentración normalizada y que su densidad en $0 \leq x \leq 1$ es

$$f_X(x) = 2(1 - x).$$

La probabilidad de observar una concentración superior a 0.7 es

$$P(X > 0.7) = \int_{0.7}^1 2(1 - x) dx = 0.09.$$

La interpretación es que, bajo este modelo, aproximadamente 9% de las observaciones exceden 0.7.

9.14. Integración en R

R puede calcular probabilidades mediante `integrate()`.

```
f <- function(x) x / 2  
  
integrate(f, lower = 0, upper = 2)
```

1 with absolute error < 1.1e-14


```
integrate(f, lower = 0.5, upper = 1.5)
```

0.5 with absolute error < 5.6e-15

El primer resultado debe ser 1 y el segundo corresponde a la probabilidad del intervalo.

9.15. Graficar una densidad y sombrear un intervalo

```
f <- function(x) ifelse(x >= 0 & x <= 2, x / 2, 0)  
  
grid <- seq(0, 2, length.out = 500)  
y <- f(grid)  
  
plot(grid, y, type = "l", lwd = 2,  
      xlab = "x", ylab = "f_X(x)")  
  
a <- 0.5  
b <- 1.5  
sel <- grid >= a & grid <= b  
polygon(c(a, grid[sel], b),  
        c(0, y[sel], 0),  
        density = 20)
```



La región sombreada representa exactamente una probabilidad.

9.16. Construcción numérica de la CDF

Podemos definir la CDF directamente mediante integración:

```
F <- function(x) {
  if (x <= 0) return(0)
  if (x >= 2) return(1)
  integrate(f, lower = 0, upper = x)$value
}
```

```
sapply(c(-1, 0, 0.5, 1, 1.5, 2, 3), F)
```

```
[1] 0.0000 0.0000 0.0625 0.2500 0.5625 1.0000 1.0000
```

9.17. Simulación de una variable continua

Para la densidad

$$f_X(x) = \frac{x}{2}, \quad 0 \leq x \leq 2,$$

la CDF es

$$F_X(x) = \frac{x^2}{4}.$$

Si U es uniforme en $(0, 1)$, podemos resolver

$$U = \frac{X^2}{4}$$

para obtener

$$X = 2\sqrt{U}.$$

Esto permite simular valores:

```
set.seed(2026)
n <- 20000
u <- runif(n)
xsim <- 2 * sqrt(u)

mean(xsim >= 0.5 & xsim <= 1.5)
```


```
[1] 0.50265
```

La frecuencia relativa debe aproximarse a la probabilidad teórica 0.5.

9.18. Histograma y densidad teórica

```
hist(xsim, probability = TRUE,
     breaks = 30,
     xlab = "x",
     main = "Simulación y densidad teórica")
curve(x / 2, from = 0, to = 2,
      add = TRUE, lwd = 2)
```

Simulación y densidad teórica



El histograma representa la distribución empírica; la curva representa el modelo teórico.

9.19. Interactivo del capítulo

La edición web incluye una densidad triangular normalizada sobre $[0, 1]$. El estudiante puede modificar:

- el punto modal de la distribución;
- el límite inferior a ;
- el límite superior b .

El recurso sombrea automáticamente el área

$$P(a < X < b)$$

y muestra simultáneamente el valor de la probabilidad. También permite observar que mover los límites cambia el área, no la “altura puntual” como probabilidad.

9.20. Actividad con GeoGebra

Construye una densidad triangular sobre $[0, 1]$ con modo m , donde $0 < m < 1$:

$$f(x) = \begin{cases} \frac{2x}{m}, & 0 \leq x \leq m, \\ \frac{2(1-x)}{1-m}, & m < x \leq 1, \\ 0, & \text{en otro caso.} \end{cases}$$

Crea deslizadores para m , a y b y utiliza el comando de integral para sombrear

$$\int_a^b f(x) dx.$$

Comprueba que el área total bajo la densidad es siempre 1 aunque cambie el modo m .

9.21. Densidad frente a probabilidad

Conviene mantener esta distinción:

Concepto	Discreto	Continuo
Probabilidad puntual	$P(X = x) = p_X(x)$	$P(X = x) = 0$
Probabilidad de intervalo	suma de masas	integral de densidad
Función básica	PMF	PDF
CDF	suma acumulada	integral acumulada

9.22. Errores frecuentes

- Interpretar $f_X(x)$ como $P(X = x)$.
- Exigir que una densidad nunca sea mayor que 1.
- Olvidar verificar que el área total sea 1.
- Calcular probabilidades continuas mediante sumas de alturas.
- Confundir área bajo la densidad con área bajo la CDF.
- Olvidar que incluir o excluir un extremo no cambia una probabilidad continua.

9.23. Resumen

Una variable continua puede describirse mediante una densidad f_X tal que

$$f_X(x) \geq 0,$$

$$\int_{-\infty}^{\infty} f_X(x) dx = 1,$$

y

$$P(a < X < b) = \int_a^b f_X(x) dx.$$

Su CDF es

$$F_X(x) = \int_{-\infty}^x f_X(t) dt,$$

y, donde exista la derivada,

$$f_X(x) = F'_X(x).$$

Para una variable absolutamente continua,

$$P(X = x) = 0.$$

9.24. Ejercicios

1. Decide si $f(x) = 2x$ para $0 \leq x \leq 1$ y cero fuera de ese intervalo es una densidad válida.
2. Sea $f(x) = c(1+x)$ para $0 \leq x \leq 1$. Determina c .
3. Para la densidad del ejercicio 2, calcula $P(X < 0.4)$ y $P(0.2 < X < 0.8)$.
4. Obtén la CDF correspondiente al ejercicio 2.
5. Para $f(x) = x/2$ en $[0, 2]$, verifica mediante R que $P(0.5 < X < 1.5) = 0.5$.
6. Simula 50 000 valores del modelo anterior usando $X = 2\sqrt{U}$ y compara la probabilidad empírica con la teórica.

7. Una variable de error tiene densidad $f(x) = 1 - |x|$ para $-1 \leq x \leq 1$. Calcula $P(|X| < 0.5)$.
8. Explica por qué una densidad puede valer 2 en algún punto sin que exista una probabilidad mayor que 1.
9. Una CDF continua y diferenciable está dada por $F(x) = x^2$ para $0 \leq x \leq 1$, con las extensiones usuales 0 y 1 fuera del intervalo. Obtén su densidad.
10. **Reto** . Para la densidad triangular con modo $m \in (0, 1)$ utilizada en el interactivo, demuestra que el área total es 1 para cualquier valor de m .

9.25. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente los conceptos centrales del capítulo.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

9.26. Referencias del capítulo

El tratamiento de variables continuas, densidades y funciones de distribución acumulada sigue el desarrollo estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, actividades, código R y simulaciones de este capítulo son originales; el enfoque computacional general toma como referencia Kerns (2010).

10 Esperanza matemática, momentos, varianza y desigualdad de Chebyshev

10.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- interpretar la esperanza matemática como centro de balance de una distribución;
- calcular esperanzas de variables aleatorias discretas y continuas;
- utilizar la esperanza de una función $g(X)$ sin construir primero la distribución de $g(X)$;
- aplicar las propiedades de linealidad de la esperanza;
- calcular momentos ordinarios y centrales;
- obtener la varianza y la desviación estándar;
- interpretar el efecto de transformaciones lineales sobre media y varianza;
- utilizar indicadores para contar eventos esperados;
- aplicar las desigualdades de Markov y Chebyshev;
- verificar resultados mediante R, simulación e interactivos.

10.2. Del modelo completo a medidas resumen

Una distribución de probabilidad contiene toda la información probabilística del modelo. Sin embargo, en muchas aplicaciones necesitamos resumirla mediante unas cuantas cantidades numéricas.

Dos de las más importantes son:

- una medida de **centro**: la esperanza o media;
- una medida de **dispersión**: la varianza o desviación estándar.

Estas medidas no sustituyen a la distribución, pero permiten compararla, interpretarla y utilizarla en modelos de ingeniería y ciencias.

10.3. Esperanza de una variable discreta

Si X es discreta, con soporte $\mathcal{S}_X$ y PMF $p_X(x)$, su esperanza se define como

$$E[X] = \sum_{x \in \mathcal{S}_X} x p_X(x).$$

La esperanza es un promedio ponderado de los valores posibles de X .

10.3.1. Ejemplo: número de retransmisiones

Supongamos

x	0	1	2	3
$p_X(x)$	0.70	0.20	0.08	0.02

Entonces

$$\begin{aligned} E[X] &= 0(0.70) + 1(0.20) + 2(0.08) + 3(0.02) \\ &= 0.42. \end{aligned}$$

Esto no significa que una transmisión individual requiera 0.42 retransmisiones. Significa que, en muchas transmisiones, el promedio de retransmisiones por paquete tenderá a acercarse a 0.42.

10.4. Interpretación como centro de balance

Podemos imaginar las probabilidades como masas colocadas en los puntos x . La esperanza es el punto donde la distribución quedaría equilibrada.

Por ello, la media puede encontrarse incluso en un valor que la variable nunca toma.

Por ejemplo, si

$$P(X = 0) = P(X = 1) = 0.5,$$

entonces

$$E[X] = 0.5,$$

aunque X nunca tome el valor 0.5.

10.5. Esperanza de una variable continua

Si X es continua con densidad $f_X(x)$, entonces

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx,$$

si la integral existe.

10.5.1. Ejemplo

Para

$$f_X(x) = \frac{x}{2}, \quad 0 \leq x \leq 2,$$

obtenemos

$$E[X] = \int_0^2 x \frac{x}{2} dx = \frac{1}{2} \int_0^2 x^2 dx = \frac{4}{3}.$$

10.6. Esperanza de una función de la variable

Con frecuencia interesa calcular

$$E[g(X)].$$

No es necesario obtener primero la distribución de $Y = g(X)$.

Para una variable discreta,

$$E[g(X)] = \sum_x g(x)p_X(x).$$

Para una variable continua,

$$E[g(X)] = \int_{-\infty}^{\infty} g(x)f_X(x) dx.$$

Esta regla suele llamarse ley del estadístico inconsciente o LOTUS.

10.7. Ejemplo: costo esperado

Supongamos que el costo, en pesos, asociado a X retransmisiones es

$$C(X) = 5 + 3X + 2X^2.$$

Si X tiene la distribución del ejemplo anterior, entonces

$$E[C(X)] = \sum_x (5 + 3x + 2x^2)p_X(x).$$

En R:

```
x <- 0:3
p <- c(0.70, 0.20, 0.08, 0.02)
costo <- 5 + 3*x + 2*x^2
sum(costo * p)
```

```
[1] 7.66
```

10.8. Linealidad de la esperanza

Para constantes a y b ,

$$\boxed{E[aX + b] = aE[X] + b}.$$

Más generalmente,

$$E[aX + bY] = aE[X] + bE[Y],$$

si las esperanzas existen.

Un punto muy importante es que la linealidad de la esperanza **no requiere independencia**.

10.9. Variables indicadoras

Sea A un evento. Definimos su variable indicadora por

$$I_A = \begin{cases} 1, & \text{si ocurre } A, \\ 0, & \text{si no ocurre } A. \end{cases}$$

Entonces

$$\boxed{E[I_A] = P(A)}.$$

Esta identidad es extremadamente útil para contar eventos.

10.9.1. Ejemplo: número esperado de sensores que fallan

Si I_i indica que el sensor i falla y

$$X = I_1 + I_2 + \cdots + I_n,$$

entonces

$$E[X] = \sum_{i=1}^n P(\text{falla del sensor } i).$$

No necesitamos que las fallas sean independientes para calcular este valor esperado.

10.10. Momentos

Los **momentos ordinarios** de una variable se definen como

$$\mu'_r = E[X^r].$$

En particular,

$$\mu'_1 = E[X].$$

Los **momentos centrales** son

$$\mu_r = E[(X - \mu)^r],$$

donde

$$\mu = E[X].$$

El segundo momento central es la varianza.

10.11. Varianza

La varianza mide la dispersión alrededor de la media:

$$\text{Var}(X) = E[(X - \mu)^2],$$

donde $\mu = E[X]$.

Una forma computacional muy útil es

$$\text{Var}(X) = E[X^2] - \{E[X]\}^2.$$

La desviación estándar es

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

La desviación estándar tiene las mismas unidades que X , mientras que la varianza tiene unidades al cuadrado.

10.12. Ejemplo discreto completo

Para

$$x = 0, 1, 2, 3$$

con probabilidades

$$(0.70, 0.20, 0.08, 0.02),$$

ya obtuvimos

$$E[X] = 0.42.$$

Además,

$$E[X^2] = 0^2(0.70) + 1^2(0.20) + 2^2(0.08) + 3^2(0.02) = 0.70.$$

Por tanto,

$$\text{Var}(X) = 0.70 - (0.42)^2 = 0.5236.$$

Y

$$\sigma_X \approx 0.7236.$$

10.13. Cálculo en R

```
x <- 0:3
p <- c(0.70, 0.20, 0.08, 0.02)

mu <- sum(x * p)
EX2 <- sum(x^2 * p)
varX <- EX2 - mu^2
sdX <- sqrt(varX)

c(media = mu,
  segundo_momento = EX2,
  varianza = varX,
  desviacion = sdX)
```

media	segundo_momento	varianza	desviacion
0.4200000	0.7000000	0.5236000	0.7236021

10.14. Transformaciones lineales

Si

$$Y = aX + b,$$

entonces

$$E[Y] = aE[X] + b,$$

mientras que

$$\boxed{\text{Var}(Y) = a^2 \text{Var}(X)}.$$

El término b desplaza la distribución, pero no altera su dispersión.

Para la desviación estándar,

$$\sigma_Y = |a| \sigma_X.$$

10.14.1. Ejemplo: conversión de temperatura

Si

$$F = 1.8C + 32,$$

entonces

$$E[F] = 1.8E[C] + 32$$

y

$$\text{Var}(F) = 1.8^2 \text{Var}(C).$$

10.15. Esperanza y varianza mediante simulación

Supongamos que simulamos la variable de retransmisiones:

```
set.seed(2026)
n <- 100000
muestra <- sample(x, n, replace = TRUE, prob = p)
mean(muestra)
```

```
[1] 0.4241
```

```
var(muestra)
```

```
[1] 0.5280245
```

```
sd(muestra)
```

```
[1] 0.7266529
```

Al aumentar n , la media y la varianza muestrales tienden a acercarse a los valores teóricos.

10.16. Desigualdad de Markov

Si $X \geq 0$ y $a > 0$, entonces

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

Markov proporciona una cota válida aun cuando no conozcamos la distribución completa.

10.16.1. Ejemplo

Si el tiempo de respuesta T es no negativo y

$$E[T] = 4 \text{ ms},$$

entonces

$$P(T \geq 20) \leq \frac{4}{20} = 0.20.$$

La cota puede ser conservadora, pero requiere muy poca información.

10.17. Desigualdad de Chebyshev

Si X tiene media μ y varianza finita σ^2 , entonces para $k > 0$,

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Equivalentemente,

$$P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}.$$

Chebyshev no exige que la distribución sea normal ni simétrica.

10.18. Interpretación de Chebyshev

Para cualquier distribución con varianza finita:

- con $k = 2$, al menos

$$1 - \frac{1}{4} = 0.75$$

de la probabilidad se encuentra dentro de dos desviaciones estándar de la media;

- con $k = 3$, al menos

$$1 - \frac{1}{9} = \frac{8}{9} \approx 0.8889$$

de la probabilidad se encuentra dentro de tres desviaciones estándar.

Estas son garantías mínimas, no valores exactos.

10.19. Ejemplo de ingeniería

El diámetro X de una pieza tiene

$$E[X] = 20 \text{ mm}$$

y

$$\sigma = 0.4 \text{ mm.}$$

Sin conocer la distribución, Chebyshev asegura que

$$P(|X - 20| < 0.8) \geq 0.75.$$

Por tanto, al menos 75 % de las piezas se encuentran entre

$$19.2 \text{ mm}$$

y

$$20.8 \text{ mm.}$$

10.20. Comparar la cota con la probabilidad real

Si conocemos la distribución completa, podemos comparar la cota de Chebyshev con la probabilidad real.

```
k <- 2
lim_inf <- mu - k * sdX
lim_sup <- mu + k * sdX

prob_real <- sum(p[x > lim_inf & x < lim_sup])
cota_cheb <- 1 - 1/k^2

c(probabilidad_real = prob_real,
  cota_chebyshev = cota_cheb)
```

probabilidad_real	cota_chebyshev
0.90	0.75

La probabilidad real puede ser mucho mayor que la cota.

10.21. Interactivo del capítulo

El recurso interactivo permite modificar las masas de una distribución discreta sobre cuatro valores. En tiempo real muestra:

- la media μ ;
- la varianza σ^2 ;
- la desviación estándar σ ;
- el intervalo $\mu \pm k\sigma$;
- la probabilidad real que queda dentro del intervalo;
- la garantía mínima de Chebyshev

$$1 - \frac{1}{k^2}.$$

Al mover las probabilidades puede observarse cómo la media funciona como centro de balance y cómo aumenta o disminuye la dispersión.

10.22. Actividad con GeoGebra

Construye cuatro puntos en

$$x_0 = 0, \quad x_1 = 1, \quad x_2 = 2, \quad x_3 = 3$$

con pesos positivos w_i . Normaliza mediante

$$p_i = \frac{w_i}{\sum_j w_j}.$$

Calcula

$$\mu = \sum_i x_i p_i$$

y

$$\sigma^2 = \sum_i (x_i - \mu)^2 p_i.$$

Agrega un deslizador $k > 1$ y representa el intervalo

$$[\mu - k\sigma, \mu + k\sigma].$$

Compara la masa contenida en él con

$$1 - \frac{1}{k^2}.$$

10.23. Estrategia de resolución

Ante un problema de esperanza o varianza:

1. identifica el soporte y la PMF o densidad;
2. verifica que el modelo esté normalizado;
3. calcula $E[X]$;
4. calcula $E[X^2]$ si necesitas la varianza;
5. utiliza $\text{Var}(X) = E[X^2] - E[X]^2$;
6. interpreta las unidades;
7. si existe una transformación lineal, usa las propiedades antes de recalcular todo;
8. si sólo conoces media o varianza y necesitas una cota, considera Markov o Chebyshev.

10.24. Errores frecuentes

- Interpretar la esperanza como un valor que necesariamente puede ocurrir.
- Promediar valores posibles sin ponderarlos por sus probabilidades.
- Confundir $E[X^2]$ con $E[X]^2$.
- Olvidar elevar al cuadrado el factor a en $\text{Var}(aX + b)$.
- Suponer que $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ sin revisar la dependencia.
- Interpretar Chebyshev como una probabilidad exacta.
- Aplicar Markov a variables que pueden tomar valores negativos sin una transformación adecuada.

10.25. Resumen

Para una variable discreta,

$$E[X] = \sum_x x p_X(x),$$

y para una variable continua,

$$E[X] = \int x f_X(x) dx.$$

La varianza es

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - \mu^2.$$

Bajo una transformación $Y = aX + b$,

$$E[Y] = aE[X] + b,$$

$$\text{Var}(Y) = a^2 \text{Var}(X).$$

Chebyshev garantiza

$$P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}.$$

10.26. Ejercicios

1. Para X con soporte $\{0, 1, 2, 3\}$ y probabilidades $(0.1, 0.3, 0.4, 0.2)$, calcula $E[X]$, $E[X^2]$, $\text{Var}(X)$ y σ_X .
2. Sea $f(x) = 2x$ para $0 \leq x \leq 1$. Calcula $E[X]$ y $E[X^2]$.
3. Para la variable del ejercicio anterior, obtén $\text{Var}(X)$.
4. Si $Y = 5X - 3$, expresa $E[Y]$ y $\text{Var}(Y)$ en términos de $E[X]$ y $\text{Var}(X)$.
5. Un sistema tiene 20 sensores y cada uno falla con probabilidad 0.03. Sin asumir independencia, calcula el número esperado de sensores que fallan.
6. Si una variable no negativa tiene $E[X] = 12$, utiliza Markov para acotar $P(X \geq 60)$.

7. Una variable tiene media 50 y desviación estándar 4. Utiliza Chebyshev para dar una cota inferior de $P(42 < X < 58)$.
8. Repite el ejercicio anterior para el intervalo $(38, 62)$.
9. Simula en R la distribución del ejercicio 1 y compara media y varianza empíricas con las teóricas.
10. **Reto** . Demuestra Chebyshev aplicando Markov a la variable no negativa $(X - \mu)^2$.

10.27. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y experimentar con los ejemplos computacionales del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir y ampliar los ejemplos en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar visualmente media, dispersión y la cota de Chebyshev.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de conceptos y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

10.28. Referencias del capítulo

El tratamiento de esperanza, momentos, varianza y desigualdades probabilísticas sigue el desarrollo estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, ejercicios, simulaciones e implementación en R son originales; el enfoque computacional general toma como referencia Kerns (2010).

11 Distribuciones discretas especiales I: Bernoulli, binomial, geométrica y binomial negativa

11.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- reconocer experimentos de Bernoulli;
- modelar el número de éxitos en ensayos independientes mediante una distribución binomial;
- modelar tiempos de espera discretos con las distribuciones geométrica y binomial negativa;
- distinguir entre contar éxitos, contar ensayos y contar fallas;
- calcular probabilidades puntuales y acumuladas;
- identificar la media y la varianza de cada distribución;
- utilizar correctamente las funciones de R para estas distribuciones;
- simular observaciones y comparar resultados empíricos con probabilidades teóricas;
- interpretar aplicaciones en confiabilidad, comunicaciones, control de calidad y ciencias.

11.2. ¿Por qué estudiar familias de distribuciones?

En capítulos anteriores construimos funciones de masa caso por caso. Sin embargo, muchos experimentos reales comparten estructuras matemáticas comunes. Cuando esa estructura se reconoce, podemos utilizar una distribución conocida en lugar de reconstruir el modelo desde cero.

En este capítulo estudiaremos cuatro familias estrechamente relacionadas:

1. Bernoulli: un ensayo con dos resultados;
2. binomial: número de éxitos en n ensayos de Bernoulli;

3. geométrica: número de ensayos hasta el primer éxito;
4. binomial negativa: número de ensayos hasta alcanzar r éxitos.

La clave será identificar **qué está contando la variable aleatoria**.

11.3. Distribución de Bernoulli

Un ensayo de Bernoulli tiene sólo dos resultados relevantes:

- éxito, con probabilidad p ;
- fracaso, con probabilidad $q = 1 - p$.

Definimos

$$X = \begin{cases} 1, & \text{si ocurre éxito,} \\ 0, & \text{si ocurre fracaso.} \end{cases}$$

Entonces

$$X \sim \text{Bernoulli}(p)$$

y su función de masa es

$$\boxed{p_X(x) = p^x(1-p)^{1-x}}, \quad x \in \{0, 1\}.$$

Su media y varianza son

$$\boxed{E[X] = p}$$

y

$$\boxed{\text{Var}(X) = p(1-p)}.$$

11.3.1. Ejemplo de ingeniería

Un paquete se transmite correctamente con probabilidad 0.98. Definimos

$$X = 1$$

si la transmisión es correcta y $X = 0$ si falla. Entonces

$$X \sim \text{Bernoulli}(0.98).$$

La probabilidad de error es

$$P(X = 0) = 0.02.$$

11.4. Distribución binomial

Supongamos que realizamos n ensayos de Bernoulli que cumplen:

1. cada ensayo tiene dos resultados: éxito o fracaso;
2. los ensayos son independientes;
3. la probabilidad de éxito p permanece constante;
4. el número de ensayos n está fijado de antemano.

Sea

X = número de éxitos en los n ensayos.

Entonces

$$X \sim \text{Binomial}(n, p).$$

La PMF es

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x},$$

para

$$x = 0, 1, \dots, n.$$

La media y la varianza son

$$E[X] = np$$

y

$$\text{Var}(X) = np(1 - p).$$

11.5. ¿De dónde aparece el coeficiente binomial?

Para obtener exactamente x éxitos y $n - x$ fracasos, una secuencia particular tiene probabilidad

$$p^x(1 - p)^{n-x}.$$

Pero los x éxitos pueden ocupar

$$\binom{n}{x}$$

posiciones diferentes. Por ello multiplicamos por ese número de arreglos.

11.6. Ejemplo: defectos en una muestra

Una línea produce piezas defectuosas con probabilidad $p = 0.04$. Si tomamos 20 piezas y suponemos independencia, el número de defectuosas X satisface

$$X \sim \text{Binomial}(20, 0.04).$$

La probabilidad de observar exactamente dos defectuosas es

$$P(X = 2) = \binom{20}{2}(0.04)^2(0.96)^{18}.$$

En R:

```
dbinom(2, size = 20, prob = 0.04)
```

```
[1] 0.1457994
```

11.7. Probabilidades acumuladas binomiales

Para calcular

$$P(X \leq x)$$

utilizamos `pbinom()`:

```
pbinom(2, size = 20, prob = 0.04)
```

```
[1] 0.9561372
```

Para

$$P(X \geq 2),$$

podemos usar el complemento:

```
1 - pbinom(1, size = 20, prob = 0.04)
```

```
[1] 0.1896622
```

11.8. Ejemplo de confiabilidad

Cada uno de 8 sensores responde correctamente con probabilidad 0.95, de manera independiente. Si X es el número de sensores que responden correctamente,

$$X \sim \text{Binomial}(8, 0.95).$$

La probabilidad de que respondan al menos 7 es

$$P(X \geq 7) = P(X = 7) + P(X = 8).$$

```
sum(dbinom(7:8, size = 8, prob = 0.95))
```

```
[1] 0.9427553
```

11.9. Bernoulli como caso particular de la binomial

Si $n = 1$,

$$\text{Binomial}(1, p) = \text{Bernoulli}(p).$$

Esta relación será útil para entender que una binomial puede escribirse como suma de variables indicadoras independientes:

$$X = X_1 + \cdots + X_n,$$

con

$$X_i \sim \text{Bernoulli}(p).$$

11.10. Distribución geométrica

Ahora cambia la pregunta. Ya no fijamos el número de ensayos y contamos éxitos. Repetimos ensayos independientes hasta obtener el primer éxito.

Sea

X = número de ensayos necesarios hasta el primer éxito.

Entonces

$$X \sim \text{Geométrica}(p)$$

con soporte

$$1, 2, 3, \dots$$

y PMF

$$P(X = x) = (1 - p)^{x-1}p.$$

La media y la varianza son

$$E[X] = \frac{1}{p}$$

y

$$\text{Var}(X) = \frac{1-p}{p^2}.$$

11.11. Ejemplo: intentos de conexión

Un enlace logra conectarse en cada intento con probabilidad $p = 0.30$. Si los intentos son independientes y X es el número de intentos hasta la primera conexión,

$$X \sim \text{Geométrica}(0.30).$$

La probabilidad de conectarse exactamente en el cuarto intento es

$$P(X = 4) = (0.70)^3(0.30).$$

11.12. Atención: parametrización de `dgeom()` en R

R define la variable geométrica como el **número de fracasos antes del primer éxito**.

Si nuestro libro utiliza

$$X = \text{número de ensayos hasta el primer éxito},$$

entonces la variable de R es

$$Y = X - 1.$$

Por ejemplo,

```
# P(X = 4): tres fracasos antes del primer éxito  
dgeom(3, prob = 0.30)
```

```
[1] 0.1029
```

Y

```
# P(X <= 4) equivale a P(Y <= 3)  
pgeom(3, prob = 0.30)
```

```
[1] 0.7599
```

Esta diferencia de parametrización es una fuente frecuente de errores.

11.13. Propiedad sin memoria

La distribución geométrica tiene una propiedad especial:

$$P(X > s + t \mid X > s) = P(X > t).$$

En palabras: si ya hemos esperado s intentos sin éxito, el tiempo adicional de espera se comporta como si comenzáramos de nuevo.

11.13.1. Ejemplo

Si $p = 0.30$, saber que los primeros cinco intentos fallaron no cambia la probabilidad de que hagan falta más de tres intentos adicionales.

La razón es que cada ensayo conserva la misma probabilidad de éxito y es independiente de los anteriores.

11.14. Distribución binomial negativa

Generalicemos la geométrica. Ahora repetimos ensayos independientes hasta conseguir r éxitos.

Sea

X = número total de ensayos necesarios para obtener r éxitos.

Entonces

$$X \sim \text{BinomialNegativa}(r, p).$$

Para

$$x = r, r + 1, r + 2, \dots,$$

la PMF es

$$P(X = x) = \binom{x-1}{r-1} p^r (1-p)^{x-r}.$$

La media y la varianza son

$$E[X] = \frac{r}{p}$$

y

$$\text{Var}(X) = \frac{r(1-p)}{p^2}.$$

11.15. ¿Por qué aparece $\binom{x-1}{r-1}$?

Para que el r -ésimo éxito ocurra exactamente en el ensayo x :

- el ensayo x debe ser éxito;
- en los primeros $x - 1$ ensayos deben aparecer exactamente $r - 1$ éxitos.

Esos $r - 1$ éxitos pueden ubicarse de

$$\binom{x-1}{r-1}$$

maneras.

11.16. Ejemplo: paquetes correctamente recibidos

Cada transmisión llega correctamente con probabilidad $p = 0.8$. Sea X el número total de transmisiones necesarias para conseguir 5 recepciones correctas.

Entonces

$$X \sim \text{BinomialNegativa}(5, 0.8).$$

La probabilidad de necesitar exactamente 7 transmisiones es

$$P(X = 7) = \binom{6}{4} (0.8)^5 (0.2)^2.$$

11.17. Parametrización de `dnbinom()` en R

R cuenta el **número de fracasos antes de alcanzar r éxitos**.

Si

X = número total de ensayos hasta el r -ésimo éxito,

y

$$Y = X - r,$$

entonces

$Y \sim$ la parametrización usada por R.

Por ejemplo, para $X = 7$ y $r = 5$ hay dos fracasos:

```
dnbinom(2, size = 5, prob = 0.8)
```

```
[1] 0.196608
```

11.18. Relación entre geométrica y binomial negativa

La geométrica es el caso particular $r = 1$ de la binomial negativa.

Además, si

$$G_1, \dots, G_r$$

son variables geométricas independientes con el mismo parámetro p , entonces

$$X = G_1 + \dots + G_r$$

tiene distribución binomial negativa bajo la parametrización de número total de ensayos.

11.19. Comparación conceptual

Distribución	¿Qué se fija?	¿Qué cuenta X ?	Soporte
Bernoulli	un ensayo	éxito o fracaso	0, 1
Binomial	n ensayos	número de éxitos	0, ..., n
Geométrica	1 éxito	ensayos hasta el primer éxito	1, 2, ...
Binomial negativa	r éxitos	ensayos hasta el r -ésimo éxito	$r, r + 1, \dots$

Esta tabla suele resolver buena parte de la selección del modelo.

11.20. Funciones principales en R

Para la binomial:

```
dbinom(3, size = 10, prob = 0.4) # P(X=3)
```

```
[1] 0.2149908
```

```
pbinom(3, size = 10, prob = 0.4) # P(X<=3)
```

```
[1] 0.3822806
```

```
rbinom(10, size = 10, prob = 0.4) # simulación
```

```
[1] 5 3 2 5 5 4 7 6 3 4
```

Para la geométrica, recordando que R cuenta fracasos:

```
dgeom(2, prob = 0.4) # 2 fracasos antes del éxito => X=3 ensayos
```

```
[1] 0.144
```

```
pgeom(2, prob = 0.4)
```

```
[1] 0.784
```

```
rgeom(10, prob = 0.4)
```

```
[1] 2 7 1 1 1 0 2 1 1 5
```

Para la binomial negativa, R también cuenta fracasos:

```
dnbinom(3, size = 4, prob = 0.4)
```

```
[1] 0.110592
```

```
pnbinom(3, size = 4, prob = 0.4)
```

```
[1] 0.289792
```

```
rnbinom(10, size = 4, prob = 0.4)
```

```
[1] 9 10 4 3 7 8 6 4 12 7
```

11.21. Simulación binomial

```
set.seed(2026)
n_sim <- 50000
muestra <- rbinom(n_sim, size = 20, prob = 0.04)

mean(muestra)
```

```
[1] 0.80544
```

```
var(muestra)
```

```
[1] 0.777562
```

```
c(media_teorica = 20 * 0.04,  
   var_teorica = 20 * 0.04 * 0.96)
```

```
media_teorica  var_teorica  
          0.800          0.768
```

11.22. Comparar PMF teórica y simulación

```
x <- 0:6  
p_teorica <- dbinom(x, size = 20, prob = 0.04)  
empirica <- prop.table(table(factor(muestra, levels = x)))  
  
data.frame(  
  x = x,  
  teorica = p_teorica,  
  empirica = as.numeric(empirica)  
)
```

```
   x    teorica    empirica  
1 0 4.420024e-01 0.4408288166  
2 1 3.683354e-01 0.3663473269  
3 2 1.457994e-01 0.1486629733  
4 3 3.644985e-02 0.0362407248  
5 4 6.454662e-03 0.0068201364  
6 5 8.606215e-04 0.0009600192  
7 6 8.964808e-05 0.0001400028
```

11.23. Simulación geométrica con la convención del libro

Como `rgeom()` devuelve el número de fracasos antes del éxito, sumamos 1:

```
set.seed(2026)
X <- rgeom(50000, prob = 0.30) + 1
mean(X)
```

```
[1] 3.34562
```

```
var(X)
```

```
[1] 7.910805
```

```
c(media_teorica = 1 / 0.30,
  var_teorica = 0.70 / 0.30^2)
```

```
media_teorica  var_teorica
      3.333333      7.777778
```

11.24. Simulación binomial negativa con la convención del libro

```
r <- 5
p <- 0.8

# R devuelve número de fracasos; sumamos r para obtener ensayos totales
X <- rnbinom(50000, size = r, prob = p) + r
mean(X)
```

```
[1] 6.25212
```

```
var(X)
```

```
[1] 1.577667
```

```
c(media_teorica = r / p,  
   var_teorica = r * (1-p) / p^2)
```

```
media_teorica  var_teorica  
        6.2500        1.5625
```

11.25. Interactivo del capítulo

La versión web incluye un comparador de distribuciones discretas. El estudiante puede elegir:

- Bernoulli;
- binomial;
- geométrica;
- binomial negativa.

Después puede modificar p y, cuando corresponda, n o r . El interactivo actualiza:

- la PMF;
- la media;
- la varianza;
- el soporte visible;
- una probabilidad puntual seleccionada.

El objetivo es observar cómo cambia la forma de la distribución al modificar sus parámetros y, sobre todo, distinguir qué variable está contando cada modelo.

11.26. Actividad con GeoGebra

Para una distribución binomial fija n , crea deslizadores para p y x . Define

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}.$$

Construye una lista de puntos

$$(k, P(X = k)), \quad k = 0, 1, \dots, n.$$

Después modifica p desde valores cercanos a 0 hasta valores cercanos a 1 y observa:

- cómo se desplaza el centro;
- cómo cambia la simetría;
- cómo se modifica la dispersión.

Como extensión, construye una geométrica y observa cómo la cola se hace más larga cuando p disminuye.

11.27. Selección del modelo

Antes de utilizar una fórmula, responde:

1. ¿cada ensayo tiene dos resultados relevantes?
2. ¿la probabilidad de éxito permanece constante?
3. ¿los ensayos pueden considerarse independientes?
4. ¿está fijado el número de ensayos o esperamos hasta alcanzar éxitos?
5. si esperamos, ¿hasta el primer éxito o hasta el r -ésimo?

Estas preguntas permiten distinguir los cuatro modelos de este capítulo.

11.28. Errores frecuentes

- Aplicar una binomial cuando la probabilidad p cambia entre ensayos.
- Confundir “al menos” con “exactamente”.
- Usar `pbinom(x, ...)` como si fuera $P(X = x)$.
- Olvidar que `dgeom()` de R cuenta fracasos, no ensayos totales.
- Olvidar que `dnbinom()` de R también cuenta fracasos antes del r -ésimo éxito.
- Confundir una binomial negativa con una binomial ordinaria.
- Suponer independencia sin justificarla en una aplicación real.

11.29. Resumen

Bernoulli:

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x = 0, 1.$$

Binomial:

$$P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}.$$

Geométrica, contando ensayos hasta el primer éxito:

$$P(X = x) = (1 - p)^{x-1} p.$$

Binomial negativa, contando ensayos hasta el r -ésimo éxito:

$$P(X = x) = \binom{x-1}{r-1} p^r (1 - p)^{x-r}.$$

Las cuatro distribuciones surgen de secuencias de ensayos de Bernoulli, pero responden preguntas diferentes.

11.30. Ejercicios

1. Un componente pasa una prueba con probabilidad 0.92. Define una variable Bernoulli y calcula su media y varianza.
2. En 12 transmisiones independientes, cada una tiene probabilidad 0.85 de éxito. Calcula la probabilidad de exactamente 10 éxitos.
3. Para el ejercicio anterior, calcula $P(X \geq 10)$.
4. Una pieza es defectuosa con probabilidad 0.03. En una muestra independiente de 30 piezas, calcula la probabilidad de ninguna defectuosa.
5. Un enlace conecta con probabilidad 0.25 en cada intento. Calcula la probabilidad de que la primera conexión ocurra en el quinto intento.
6. Para el ejercicio anterior, calcula la probabilidad de requerir más de 6 intentos.
7. Demuestra numéricamente en R la propiedad sin memoria de la geométrica para $p = 0.25$, $s = 4$ y $t = 3$.

8. Cada transmisión tiene probabilidad 0.70 de éxito. Calcula la probabilidad de que el cuarto éxito ocurra exactamente en el sexto intento.
9. Reproduce el ejercicio 8 mediante `dnbinom()` explicando por qué el argumento corresponde a dos fracasos.
10. Simula 100 000 observaciones de una binomial $B(15, 0.4)$ y compara la media y varianza empíricas con las teóricas.
11. Simula una geométrica con la convención del libro a partir de `rgeom()` y verifica su media teórica.
12. **Reto** . Si $X_1, \dots, X_n$ son Bernoulli independientes con probabilidad común p , explica por qué $X_1 + \dots + X_n$ es binomial y utiliza esa representación para obtener su esperanza y varianza.

11.31. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar, modificar y comparar las distribuciones discretas del capítulo.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir cálculos, gráficas y simulaciones en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Comparar PMF, media y varianza al modificar los parámetros.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.

Material	Formato	Acceso	Propósito
Infografía	Imagen / PDF	Próximamente	Síntesis visual de distribuciones, parámetros y fórmulas clave.

Los **cuadernos de R** acompañan este capítulo para reproducir, modificar y extender los ejemplos. El cuaderno de Google Colab permite trabajar desde el navegador. Las presentaciones, videos e infografías se enlazarán en esta misma tabla cuando estén disponibles.

11.32. Referencias del capítulo

El tratamiento de las distribuciones Bernoulli, binomial, geométrica y binomial negativa sigue la presentación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos de ingeniería, ejercicios, código y simulaciones en R son originales; para el enfoque computacional se toma como referencia general Kerns (2010).

12 Distribuciones discretas especiales II: hipergeométrica y Poisson

12.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante podrá reconocer modelos hipergeométricos y Poisson, distinguir muestreo con y sin reemplazo, calcular probabilidades con R, interpretar medias y varianzas, simular ambos modelos y estudiar aproximaciones binomial–hipergeométrica y binomial–Poisson.

12.2. Dos estructuras nuevas

La distribución hipergeométrica aparece al contar éxitos en una muestra tomada **sin reemplazo** de una población finita. La distribución de Poisson aparece al contar eventos en un intervalo de tiempo, longitud, área o volumen cuando existe una tasa media aproximadamente estable.

12.3. Distribución hipergeométrica

Una población de tamaño N contiene K elementos de interés y $N - K$ elementos restantes. Se selecciona una muestra de tamaño n sin reemplazo y se define

X = número de éxitos en la muestra.

Entonces

$$X \sim \text{Hipergeométrica}(N, K, n)$$

y

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}.$$

El soporte satisface

$$\max(0, n - (N - K)) \leq x \leq \min(n, K).$$

La media y la varianza son

$$E[X] = n \frac{K}{N}$$

y

$$\text{Var}(X) = n \frac{K}{N} \left(1 - \frac{K}{N}\right) \frac{N-n}{N-1}.$$

El último factor es la **corrección por población finita**.

12.4. Ejemplo de control de calidad

Un lote contiene 50 componentes, 6 defectuosos. Se eligen 8 sin reemplazo. Si X es el número de defectuosos,

$$X \sim \text{Hipergeométrica}(50, 6, 8).$$

La probabilidad de exactamente dos defectuosos es

$$P(X = 2) = \frac{\binom{6}{2} \binom{44}{6}}{\binom{50}{8}}.$$

En R:

```
dhyper(2, m = 6, n = 44, k = 8)
```

```
[1] 0.1972248
```

```
phyper(2, m = 6, n = 44, k = 8)      # P(X <= 2)
```

```
[1] 0.9556011
```

```
1 - phyper(1, m = 6, n = 44, k = 8)  # P(X >= 2)
```

```
[1] 0.2416237
```

En `dhyper()`, `m` es el número de éxitos de la población, `n` el número de fracasos y `k` el tamaño de muestra.

12.5. Binomial frente a hipergeométrica

Característica	Binomial	Hipergeométrica
Extracciones	independientes	dependientes
Reemplazo	sí o equivalente	no
Probabilidad de éxito	constante	cambia tras cada extracción
Población	conceptual ilimitada	finita

Si n/N es pequeño, una hipergeométrica puede aproximarse por una binomial con

$$p = K/N.$$

```
N <- 500; K <- 50; n <- 10; p <- K/N
x <- 0:n
data.frame(x,
  hipergeometrica = dhyper(x, K, N-K, n),
  binomial = dbinom(x, n, p))
```

```
      x hipergeometrica    binomial
1  0  3.451622e-01 0.3486784401
2  1  3.913403e-01 0.3874204890
3  2  1.952275e-01 0.1937102445
4  3  5.640884e-02 0.0573956280
```

5	4	1.044961e-02	0.0111602610
6	5	1.296221e-03	0.0014880348
7	6	1.089872e-04	0.0001377810
8	7	6.130314e-06	0.0000087480
9	8	2.206502e-07	0.0000003645
10	9	4.586642e-09	0.0000000090
11	10	4.178940e-11	0.0000000001

12.6. Distribución de Poisson

Si X cuenta eventos en un intervalo y la tasa media esperada es $\lambda > 0$, escribimos

$$X \sim \text{Poisson}(\lambda).$$

Su PMF es

$$P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

y satisface

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

12.7. Ejemplo: solicitudes a un servidor

Un servidor recibe en promedio 4 solicitudes por segundo. Bajo un modelo Poisson,

$$X \sim \text{Poisson}(4).$$

```
dpois(6, lambda = 4)      # P(X = 6)
```

```
[1] 0.1041956
```

```
ppois(6, lambda = 4)      # P(X <= 6)
```

```
[1] 0.889326
```

```
1 - ppois(6, lambda = 4) # P(X > 6)
```

```
[1] 0.110674
```

Si la tasa es r eventos por unidad y observamos una longitud t ,

$$\lambda = rt.$$

Por ejemplo, una tasa de 4 eventos por segundo corresponde a $\lambda = 2$ en medio segundo y a $\lambda = 12$ en tres segundos.

12.8. Ejemplo ambiental

Si se observan en promedio 1.8 excedencias de un umbral por mes,

$$X \sim \text{Poisson}(1.8).$$

La probabilidad de al menos una excedencia es

```
1 - dpois(0, lambda = 1.8)
```

```
[1] 0.8347011
```

El modelo Poisson debe justificarse: no basta con que la variable sea un conteo. Conviene revisar estabilidad de la tasa, intervalo definido y ausencia de dependencia fuerte entre eventos.

12.9. Suma de variables Poisson

Si

$$X \sim \text{Poisson}(\lambda_1), \quad Y \sim \text{Poisson}(\lambda_2)$$

son independientes, entonces

$$X + Y \sim \text{Poisson}(\lambda_1 + \lambda_2).$$

12.10. Aproximación binomial por Poisson

Si

$$X \sim \text{Binomial}(n, p)$$

con n grande y p pequeño, manteniendo

$$\lambda = np,$$

entonces

$$X \approx \text{Poisson}(np).$$

Ejemplo:

$$X \sim \text{Binomial}(1000, 0.002), \quad \lambda = 2.$$

```
exacta <- dbinom(3, 1000, 0.002)
aprox <- dpois(3, 2)
c(exacta = exacta, poisson = aprox,
  error_relativo = abs(aprox-exacta)/exacta)
```

exacta	poisson	error_relativo
0.180627732	0.180447044	0.001000334

12.11. Simulación en R

Hipergeométrica:

```
set.seed(2026)
N <- 50; K <- 6; n <- 8
xh <- rhyper(50000, m = K, n = N-K, k = n)
mean(xh); var(xh)
```

```
[1] 0.96446
```

```
[1] 0.7296915
```

```
n*K/N
```

```
[1] 0.96
```

```
n*(K/N)*(1-K/N)*(N-n)/(N-1)
```

```
[1] 0.7241143
```

Poisson:

```
set.seed(2026)
xp <- rpois(50000, lambda = 4)
mean(xp); var(xp)
```

```
[1] 4.01138
```

```
[1] 4.038451
```

En Poisson, ambas cantidades empíricas deben aproximarse a 4.

12.12. Interactivo del capítulo

El recurso web tiene dos comparaciones. En la primera se modifican N , K y n para contrastar la PMF hipergeométrica con una binomial de parámetro $p = K/N$. En la segunda se modifican n y p y se contrasta una binomial con una Poisson de parámetro $\lambda = np$.

Esto permite observar visualmente cuándo las aproximaciones son buenas y cuándo la falta de reemplazo produce diferencias importantes.

12.13. Actividad con GeoGebra

Construye una binomial con parámetros n, p y una Poisson con $\lambda = np$. Representa ambas PMF mediante listas de puntos. Prueba:

- $n = 20, p = 0.30$;
- $n = 100, p = 0.05$;
- $n = 1000, p = 0.002$.

Describe en qué caso se parecen más y explica la razón.

12.14. Selección del modelo

- Muestra de población finita **sin reemplazo**: hipergeométrica.
- Conteo de eventos en un intervalo con tasa media: Poisson.
- Éxitos en n ensayos independientes: binomial.
- Binomial con n grande y p pequeño: considerar aproximación Poisson.

12.15. Errores frecuentes

- Usar binomial cuando el muestreo sin reemplazo representa una parte importante de la población.
- Confundir K con el tamaño de muestra.
- Olvidar que `dhyper()` pide éxitos y fracasos por separado.
- Usar Poisson sólo porque la variable sea un conteo.
- Confundir tasa por unidad con λ del intervalo observado.
- Usar $\lambda = p$ en lugar de $\lambda = np$ para aproximar una binomial.

12.16. Resumen

Hipergeométrica:

$$P(X = x) = \frac{\binom{K}{x} \binom{N-K}{n-x}}{\binom{N}{n}}.$$

Poisson:

$$P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}.$$

Cuando n es grande y p pequeño,

$$\text{Binomial}(n, p) \approx \text{Poisson}(np).$$

12.17. Ejercicios

1. Un lote de 40 piezas contiene 5 defectuosas. Se seleccionan 6 sin reemplazo. Calcula $P(X = 1)$ y $P(X \geq 2)$.
2. Obtén media y varianza para la variable del ejercicio anterior.
3. Compara el ejercicio 1 con una binomial de parámetro $p = 5/40$.
4. Una central recibe en promedio 3.2 llamadas por minuto. Calcula $P(X = 5)$ y $P(X \leq 5)$.
5. Calcula la probabilidad de ninguna llamada durante 30 segundos para la tasa anterior.
6. Una carretera registra en promedio 1.5 incidentes por día. Calcula la probabilidad de al menos dos incidentes en dos días.
7. Compara $P(X = 2)$ para $B(200, 0.01)$ y una Poisson con $\lambda = 2$.
8. Simula una hipergeométrica con $N = 100$, $K = 10$, $n = 20$ y verifica media y varianza.
9. Simula una Poisson con $\lambda = 6$ y compara media y varianza muestrales.
10. **Reto** . Explica por qué la corrección por población finita reduce la varianza respecto de la binomial correspondiente.

12.18. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar y comparar modelos hipergeométrico, binomial y Poisson.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir cálculos, aproximaciones y simulaciones.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar muestreo sin reemplazo y aproximaciones.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de modelos y criterios de selección.

12.19. Referencias del capítulo

El tratamiento sigue Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, ejercicios y simulaciones son originales; el enfoque computacional general toma como referencia Kerns (2010).

13 Distribuciones continuas especiales I: uniforme, exponencial y normal

13.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- reconocer cuándo una variable continua puede modelarse mediante una distribución uniforme, exponencial o normal;
- identificar sus parámetros, soporte, densidad, función de distribución, media y varianza;
- calcular probabilidades mediante integración y mediante funciones de R;
- estandarizar variables normales;
- obtener cuantiles y percentiles;
- interpretar la propiedad sin memoria de la distribución exponencial;
- simular variables continuas y comparar resultados empíricos con modelos teóricos;
- distinguir claramente qué tipo de fenómeno representa cada distribución.

13.2. Tres modelos fundamentales

Las distribuciones uniforme, exponencial y normal aparecen constantemente en ingeniería y ciencias, pero representan situaciones muy diferentes.

- **Uniforme:** todos los valores de un intervalo tienen la misma densidad.
- **Exponencial:** modela tiempos de espera continuos cuando la tasa instantánea de ocurrencia es constante.
- **Normal:** describe fenómenos que se concentran alrededor de un valor central y cuya variabilidad resulta de la combinación de múltiples pequeñas fuentes de perturbación.

Reconocer la estructura del fenómeno es más importante que memorizar una fórmula.

14 Distribución uniforme continua

Decimos que

$$X \sim U(a, b), \quad a < b,$$

si su densidad es

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{en otro caso.} \end{cases}$$

La densidad es constante en todo el intervalo.

14.1. Función de distribución acumulada

La CDF es

$$F_X(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b, \\ 1, & x > b. \end{cases}$$

Por ello, si

$$a \leq c < d \leq b,$$

entonces

$$P(c < X < d) = \frac{d-c}{b-a}.$$

La probabilidad depende únicamente de la longitud relativa del subintervalo.

14.2. Media y varianza de la uniforme

Para

$$X \sim U(a, b),$$

se tiene

$$E[X] = \frac{a + b}{2}$$

y

$$\text{Var}(X) = \frac{(b - a)^2}{12}.$$

14.3. Ejemplo: error de redondeo

Supongamos que un error de redondeo puede considerarse uniformemente distribuido entre -0.5 y 0.5 unidades:

$$X \sim U(-0.5, 0.5).$$

La probabilidad de que el error absoluto sea menor que 0.2 es

$$P(|X| < 0.2) = P(-0.2 < X < 0.2) = \frac{0.4}{1} = 0.4.$$

En R:

```
punif(0.2, min = -0.5, max = 0.5) -  
punif(-0.2, min = -0.5, max = 0.5)
```

```
[1] 0.4
```


14.4. Funciones de R para la uniforme

```
dunif(0.3, min = 0, max = 1) # densidad
```

```
[1] 1
```

```
punif(0.3, min = 0, max = 1) #  $P(X \leq 0.3)$ 
```

```
[1] 0.3
```

```
qunif(0.9, min = 0, max = 1) # percentil 90
```

```
[1] 0.9
```

```
runif(5, min = 0, max = 1) # simulación
```

```
[1] 0.1780398 0.3304586 0.1421050 0.6125489 0.5678432
```

15 Distribución exponencial

La distribución exponencial es uno de los modelos más importantes para tiempos de espera continuos.

Decimos que

$$X \sim \text{Exp}(\lambda), \quad \lambda > 0,$$

si

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

El parámetro λ se interpreta como una tasa.

15.1. CDF y función de supervivencia

Para $x \geq 0$,

$$F_X(x) = 1 - e^{-\lambda x}.$$

Por tanto,

$$P(X > x) = e^{-\lambda x}.$$

Esta última expresión suele llamarse función de supervivencia.

15.2. Media y varianza de la exponencial

Si

$$X \sim \text{Exp}(\lambda),$$

entonces

$$E[X] = \frac{1}{\lambda}$$

y

$$\text{Var}(X) = \frac{1}{\lambda^2}.$$

15.3. Ejemplo: tiempo entre fallas

Si un componente presenta una tasa de falla de

$$\lambda = 0.02 \text{ fallas por hora},$$

y el tiempo hasta la siguiente falla se modela exponencialmente, entonces

$$E[X] = \frac{1}{0.02} = 50 \text{ horas}.$$

La probabilidad de que funcione más de 80 horas es

$$P(X > 80) = e^{-0.02(80)}.$$

En R:

```
pexp(80, rate = 0.02, lower.tail = FALSE)
```

```
[1] 0.2018965
```

15.4. Propiedad sin memoria

La distribución exponencial satisface

$$P(X > s + t \mid X > s) = P(X > t).$$

Si un componente ha sobrevivido s horas y el modelo exponencial es apropiado, el tiempo adicional de espera tiene la misma distribución que al inicio.

Esta propiedad es análoga a la propiedad sin memoria de la distribución geométrica, pero ahora en tiempo continuo.

15.5. Ejemplo numérico de la propiedad sin memoria

Sea

$$X \sim \text{Exp}(0.1).$$

Entonces

$$P(X > 15 \mid X > 10) = P(X > 5) = e^{-0.5}.$$

En R:

```
condicional <- pexp(15, rate = 0.1, lower.tail = FALSE) /  
               pexp(10, rate = 0.1, lower.tail = FALSE)  
directa <- pexp(5, rate = 0.1, lower.tail = FALSE)  
c(condicional = condicional, directa = directa)
```

```
condicional    directa  
0.6065307      0.6065307
```

15.6. Funciones de R para la exponencial

```
dexp(4, rate = 0.2)
```

```
[1] 0.08986579
```

```
pexp(4, rate = 0.2)
```

```
[1] 0.550671
```

```
qexp(0.95, rate = 0.2)
```

```
[1] 14.97866
```

```
rexp(5, rate = 0.2)
```

```
[1] 1.715049 9.064803 1.315143 21.294698 1.751066
```

16 Distribución normal

La distribución normal ocupa un lugar central en probabilidad, estadística, medición e ingeniería.

Decimos que

$$X \sim N(\mu, \sigma^2), \quad \sigma > 0,$$

si su densidad es

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

El parámetro μ determina el centro y σ controla la dispersión.

16.1. Propiedades geométricas

La densidad normal:

- es simétrica respecto de μ ;
- tiene máximo en $x = \mu$;
- es positiva para todo número real;
- se aproxima a cero en ambas colas;
- tiene área total igual a 1.

Además,

$$E[X] = \mu,$$

$$\text{Var}(X) = \sigma^2.$$

16.2. Normal estándar

La normal estándar es

$$Z \sim N(0, 1).$$

Si

$$X \sim N(\mu, \sigma^2),$$

entonces la transformación

$$Z = \frac{X - \mu}{\sigma}$$

produce una variable normal estándar.

Este proceso se llama **estandarización**.

16.3. Ejemplo de estandarización

El diámetro de cierta pieza se modela como

$$X \sim N(20, 0.4^2).$$

Para calcular

$$P(X \leq 20.5),$$

estandarizamos:

$$z = \frac{20.5 - 20}{0.4} = 1.25.$$

Por tanto,

$$P(X \leq 20.5) = P(Z \leq 1.25).$$

En R podemos calcular directamente:

```
pnorm(20.5, mean = 20, sd = 0.4)
```

```
[1] 0.8943502
```

O mediante la normal estándar:

```
pnorm((20.5 - 20) / 0.4)
```

```
[1] 0.8943502
```

16.4. Probabilidad entre dos valores

Para

$$X \sim N(\mu, \sigma^2),$$

$$P(a < X < b) = F_X(b) - F_X(a).$$

En R:

```
pnorm(20.5, 20, 0.4) - pnorm(19.6, 20, 0.4)
```

```
[1] 0.735695
```

16.5. Cuantiles de la normal

A veces conocemos la probabilidad y buscamos el valor x .

Si queremos x tal que

$$P(X \leq x) = 0.95,$$

usamos


```
qnorm(0.95, mean = 20, sd = 0.4)
```

```
[1] 20.65794
```

Los cuantiles son fundamentales en tolerancias, control de calidad e inferencia estadística.

16.6. Regla empírica 68–95–99.7

Para una distribución normal aproximadamente:

$$P(|X - \mu| < \sigma) \approx 0.6827,$$

$$P(|X - \mu| < 2\sigma) \approx 0.9545,$$

$$P(|X - \mu| < 3\sigma) \approx 0.9973.$$

En R:

```
for (k in 1:3) {  
  print(pnorm(k) - pnorm(-k))  
}
```

```
[1] 0.6826895
```

```
[1] 0.9544997
```

```
[1] 0.9973002
```

Esta regla es específica de la normal y no debe confundirse con la desigualdad general de Chebyshev.

16.7. Funciones de R para la normal

```
dnorm(0) # densidad estándar en 0
```

```
[1] 0.3989423
```

```
pnorm(1.96) # P(Z <= 1.96)
```

```
[1] 0.9750021
```

```
qnorm(0.975) # percentil 97.5
```

```
[1] 1.959964
```

```
rnorm(5, mean = 10, sd = 2)
```

```
[1] 10.479765  9.858823 11.315220  9.923364 12.766505
```

16.8. Transformaciones lineales de variables normales

Si

$$X \sim N(\mu, \sigma^2)$$

y

$$Y = aX + b,$$

entonces


$$\boxed{Y \sim N(a\mu + b, a^2\sigma^2)}.$$

La familia normal permanece dentro de la misma familia bajo transformaciones lineales.

16.9. Simulación y comparación gráfica

```
set.seed(2026)
n <- 20000
x <- rnorm(n, mean = 20, sd = 0.4)

hist(x, probability = TRUE, breaks = 35,
     main = "Simulación normal y densidad teórica",
     xlab = "x")
curve(dnorm(x, mean = 20, sd = 0.4),
      add = TRUE, lwd = 2)
```



16.10. Comparación de las tres distribuciones

Distribución	Soporte	Parámetros	Media	Varianza	Aplicación típica
Uniforme	$[a, b]$	a, b	$(a + b)/2$	$(b - a)^2/12$	valor igualmente plausible dentro de un intervalo
Exponencial	$[0, \infty)$	λ	$1/\lambda$	$1/\lambda^2$	tiempo de espera con tasa constante
Normal	$(-\infty, \infty)$	μ, σ	μ	σ^2	mediciones y variación alrededor de un centro

16.11. Interactivo del capítulo

El interactivo permite seleccionar uniforme, exponencial o normal y modificar sus parámetros. También permite elegir un intervalo $[a, b]$ para visualizar el área de probabilidad.

En la normal se muestran además la media, la desviación estándar y la versión estandarizada del intervalo. En la exponencial se muestra la función de supervivencia y en la uniforme se observa que la probabilidad depende directamente de la longitud del intervalo.

16.12. Actividad con GeoGebra

Construye tres densidades controladas por deslizadores:

1. una uniforme $U(a, b)$;
2. una exponencial con parámetro λ ;
3. una normal con parámetros μ y σ .

Para cada una crea dos deslizadores $c < d$ y sombrea el área bajo la curva entre ambos límites. Observa cómo cambia la probabilidad al modificar los parámetros.

En la normal, mueve μ manteniendo σ fija y observa el desplazamiento horizontal. Después fija μ y modifica σ para observar el cambio de dispersión.

16.13. Estrategia de selección del modelo

Antes de elegir una distribución, pregúntate:

- ¿la variable está restringida a un intervalo finito y no hay razón para favorecer una zona? Considere uniforme.
- ¿la variable mide un tiempo de espera positivo con tasa aproximadamente constante? Considere exponencial.
- ¿la variable fluctúa alrededor de un centro debido a muchas pequeñas fuentes de variación? Considere normal.

La elección debe justificarse por el mecanismo del fenómeno, no sólo por la forma de un histograma.

16.14. Errores frecuentes

- Confundir densidad con probabilidad puntual.
- Usar `sd = sigma^2` en R en lugar de `sd = sigma`.
- Confundir `rate = lambda` con la media en la exponencial.
- Aplicar la propiedad sin memoria a cualquier distribución de tiempos.
- Olvidar estandarizar restando la media antes de dividir entre la desviación estándar.
- Usar la regla 68–95–99.7 para distribuciones no normales.
- Interpretar una densidad uniforme como probabilidades positivas en puntos individuales.

16.15. Resumen

Uniforme:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b.$$

Exponencial:

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

Normal:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

Para una normal,

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

16.16. Ejercicios

1. Sea $X \sim U(2, 8)$. Calcula $P(3 < X < 6)$, $E[X]$ y $\text{Var}(X)$.
2. Calcula el percentil 90 de $U(2, 8)$ utilizando R.
3. Sea $X \sim \text{Exp}(0.25)$. Calcula $P(X > 6)$ y $P(2 < X < 5)$.
4. Para la variable anterior, calcula la media y la desviación estándar.
5. Verifica numéricamente la propiedad sin memoria para $s = 4$ y $t = 3$.
6. Sea $X \sim N(100, 15^2)$. Calcula $P(X < 120)$.
7. Para la misma variable, calcula $P(85 < X < 115)$.
8. Encuentra el valor x tal que $P(X \leq x) = 0.95$.
9. Simula 50 000 observaciones de cada una de las tres distribuciones y compara medias y varianzas empíricas con las teóricas.
10. **Reto** . Demuestra que si $X \sim U(a, b)$ entonces $Y = (X - a)/(b - a) \sim U(0, 1)$.
11. **Reto** . Comprueba mediante R que $P(|Z| < 2) \approx 0.9545$ para $Z \sim N(0, 1)$.
12. Propón un ejemplo de ingeniería para cada distribución y justifica por qué el modelo podría ser razonable.

16.17. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar y modificar ejemplos de uniforme, exponencial y normal.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir probabilidades, cuantiles, gráficas y simulaciones.

Material	Formato	Acceso	Propósito
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar parámetros, densidades y áreas de probabilidad.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de distribuciones y fórmulas clave.

16.18. Referencias del capítulo

El tratamiento de las distribuciones uniforme, exponencial y normal sigue la presentación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, ejercicios, simulaciones y código en R son originales; el enfoque computacional general toma como referencia Kerns (2010).

17 Distribuciones continuas especiales II: Gamma, Weibull y Beta

17.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- reconocer situaciones que pueden modelarse mediante distribuciones Gamma, Weibull y Beta;
- interpretar correctamente sus parámetros;
- calcular densidades, probabilidades acumuladas, cuantiles, medias y varianzas;
- relacionar la distribución Gamma con la exponencial y con tiempos de espera acumulados;
- interpretar la distribución Weibull mediante confiabilidad, supervivencia y tasa de falla;
- utilizar la distribución Beta para modelar proporciones y cantidades restringidas a $[0, 1]$;
- utilizar las funciones correspondientes de R sin confundir parametrizaciones;
- simular las tres familias y explorar el efecto de sus parámetros.

17.2. Tres familias muy flexibles

Las distribuciones estudiadas en este capítulo amplían considerablemente el repertorio de modelos continuos.

- La **Gamma** modela cantidades positivas y tiempos acumulados de espera.
- La **Weibull** es una de las distribuciones más importantes en confiabilidad y análisis de vida útil.
- La **Beta** modela variables continuas acotadas entre 0 y 1, como proporciones, fracciones o índices normalizados.

A diferencia de la exponencial, estas familias permiten una gran variedad de formas.

18 Distribución Gamma

Utilizaremos la parametrización

$$X \sim \text{Gamma}(\alpha, \lambda),$$

donde $\alpha > 0$ es el parámetro de forma y $\lambda > 0$ es la tasa.

Su densidad es

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x > 0.$$

Aquí

$$\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$$

es la función Gamma.

18.1. Media y varianza

Para esta parametrización,

$$E[X] = \frac{\alpha}{\lambda}$$

y

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

La desviación estándar es

$$\sigma = \frac{\sqrt{\alpha}}{\lambda}.$$

18.2. Relación con la exponencial

Si

$$\alpha = 1,$$

entonces

$$\Gamma(1) = 1$$

y la densidad Gamma se reduce a

$$f_X(x) = \lambda e^{-\lambda x},$$

por lo que

$$\boxed{\text{Gamma}(1, \lambda) = \text{Exp}(\lambda)}.$$

La exponencial es, por tanto, un caso particular de la Gamma.

18.3. Tiempos de espera acumulados

Si los eventos de un proceso ocurren con tasa λ y los tiempos entre eventos son exponenciales independientes, el tiempo total hasta el evento número r tiene una distribución Gamma con forma r y tasa λ .

Cuando r es entero positivo, esta distribución también se conoce como **Erlang**.

18.3.1. Ejemplo: tiempo hasta la cuarta llegada

Supongamos que llegan en promedio 3 solicitudes por minuto. Si T es el tiempo hasta la cuarta solicitud,

$$T \sim \text{Gamma}(4, 3).$$

La media es

$$E[T] = \frac{4}{3} \text{ minutos.}$$

La probabilidad de que la cuarta solicitud ocurra antes de 2 minutos se obtiene con

```
pgamma(2, shape = 4, rate = 3)
```

```
[1] 0.8487961
```

18.4. rate y scale en R

R permite parametrizar Gamma de dos formas equivalentes:

$$\text{scale} = \theta = \frac{1}{\lambda}.$$

Por tanto,

```
dgamma(2, shape = 4, rate = 3)
```

```
[1] 0.2677052
```

```
dgamma(2, shape = 4, scale = 1/3)
```

```
[1] 0.2677052
```

producen el mismo resultado.

No debemos utilizar simultáneamente **rate** y **scale** sin comprender esta relación.

18.5. Funciones Gamma en R

```
dgamma(2, shape = 4, rate = 3)
```

```
[1] 0.2677052
```

```
pgamma(2, shape = 4, rate = 3)
```

```
[1] 0.8487961
```

```
qgamma(0.95, shape = 4, rate = 3)
```

```
[1] 2.584552
```


```
rgamma(5, shape = 4, rate = 3)
```

```
[1] 0.6260597 0.8797932 2.3234585 1.2401337 0.6530956
```

18.6. Efecto del parámetro de forma

Para valores pequeños de α , la distribución puede ser fuertemente asimétrica hacia la derecha. Al aumentar α , la densidad se vuelve más concentrada y visualmente más simétrica.

```
x <- seq(0, 8, length.out = 500)
plot(x, dgamma(x, 0.7, rate = 1), type = "l",
     ylim = c(0, 0.8), xlab = "x", ylab = "densidad")
lines(x, dgamma(x, 2, rate = 1), lty = 2)
lines(x, dgamma(x, 5, rate = 1), lty = 3)
legend("topright", legend = c("alpha=0.7", "alpha=2", "alpha=5"),
     lty = 1:3)
```



19 Distribución Weibull

La distribución Weibull es especialmente útil en confiabilidad.

Escribiremos

$$X \sim \text{Weibull}(k, \eta),$$

donde

- $k > 0$ es el parámetro de **forma**;
- $\eta > 0$ es el parámetro de **escala**.

Su densidad es

$$f_X(x) = \frac{k}{\eta} \left(\frac{x}{\eta}\right)^{k-1} \exp \left[- \left(\frac{x}{\eta}\right)^k \right], \quad x \geq 0.$$

19.1. CDF y función de supervivencia

La función de distribución es

$$F_X(x) = 1 - \exp \left[- \left(\frac{x}{\eta}\right)^k \right].$$

La función de supervivencia es

$$S(x) = P(X > x) = \exp \left[- \left(\frac{x}{\eta}\right)^k \right].$$

19.2. Tasa de falla

La tasa instantánea de falla es

$$h(x) = \frac{k}{\eta} \left(\frac{x}{\eta} \right)^{k-1}.$$

Esta fórmula explica gran parte de la utilidad de Weibull:

- si $k < 1$, la tasa de falla disminuye con el tiempo;
- si $k = 1$, la tasa es constante;
- si $k > 1$, la tasa de falla aumenta con el tiempo.

Así, k ayuda a distinguir fallas tempranas, fallas aleatorias y desgaste.

19.3. Relación con la exponencial

Si

$$k = 1,$$

entonces

$$f_X(x) = \frac{1}{\eta} e^{-x/\eta}.$$

Por tanto, Weibull con $k = 1$ es exponencial con tasa

$$\lambda = \frac{1}{\eta}.$$

19.4. Media y varianza de Weibull

La media es

$$E[X] = \eta \Gamma \left(1 + \frac{1}{k} \right)$$

y la varianza

$$\text{Var}(X) = \eta^2 \left[\Gamma \left(1 + \frac{2}{k} \right) - \Gamma^2 \left(1 + \frac{1}{k} \right) \right].$$

19.5. Ejemplo de confiabilidad

El tiempo de vida de un componente se modela como

$$X \sim \text{Weibull}(2, 1000),$$

en horas.

La probabilidad de que sobreviva más de 1200 horas es

$$P(X > 1200) = \exp[-(1.2)^2].$$

En R:

```
pweibull(1200, shape = 2, scale = 1000,  
         lower.tail = FALSE)
```

```
[1] 0.2369278
```

Como $k = 2 > 1$, el modelo representa una tasa de falla creciente, coherente con un mecanismo de desgaste.

19.6. Funciones Weibull en R

```
dweibull(800, shape = 2, scale = 1000)
```

```
[1] 0.0008436679
```

```
pweibull(800, shape = 2, scale = 1000)
```

```
[1] 0.4727076
```

```
qweibull(0.90, shape = 2, scale = 1000)
```

```
[1] 1517.427
```

```
rweibull(5, shape = 2, scale = 1000)
```

```
[1] 1071.5685 603.9464 1429.5634 774.8760 755.2925
```

20 Distribución Beta

La distribución Beta se define en el intervalo

$$0 < x < 1.$$

Si

$$X \sim \text{Beta}(\alpha, \beta),$$

con $\alpha > 0$ y $\beta > 0$, su densidad es

$$f_X(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1,$$

donde

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}.$$

20.1. Media y varianza de Beta

Para

$$X \sim \text{Beta}(\alpha, \beta),$$

$$E[X] = \frac{\alpha}{\alpha + \beta}$$

y

$$\text{Var}(X) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}.$$

20.2. Formas de la distribución Beta

La familia Beta es muy flexible:

- $\alpha = \beta = 1$: uniforme en $[0, 1]$;
- $\alpha > 1, \beta > 1$: densidad concentrada en el interior;
- $\alpha > \beta$: mayor concentración hacia 1;
- $\alpha < \beta$: mayor concentración hacia 0;
- $\alpha < 1, \beta < 1$: densidad elevada cerca de ambos extremos.

20.3. Ejemplo: fracción de utilización

Supongamos que la proporción diaria de capacidad utilizada de un sistema se modela mediante

$$X \sim \text{Beta}(5, 2).$$

La media es

$$E[X] = \frac{5}{7} \approx 0.7143.$$

La probabilidad de utilizar más del 80 % de la capacidad es

```
pbeta(0.80, shape1 = 5, shape2 = 2,
      lower.tail = FALSE)
```

```
[1] 0.34464
```

20.4. Uniforme como caso particular de Beta

Para

$$\alpha = \beta = 1,$$

la densidad Beta es

$$f_X(x) = 1, \quad 0 < x < 1,$$

por lo que

$$\boxed{\text{Beta}(1, 1) = U(0, 1)}.$$

20.5. Funciones Beta en R

```
dbeta(0.7, shape1 = 5, shape2 = 2)
```

```
[1] 2.1609
```

```
pbeta(0.7, shape1 = 5, shape2 = 2)
```

```
[1] 0.420175
```

```
qbeta(0.95, shape1 = 5, shape2 = 2)
```

```
[1] 0.9371501
```

```
rbeta(5, shape1 = 5, shape2 = 2)
```

```
[1] 0.7988276 0.5881656 0.5169173 0.9289324 0.3139513
```

20.6. Simulación Gamma

```
set.seed(2026)
xg <- rgamma(50000, shape = 4, rate = 3)
mean(xg)
```

```
[1] 1.336002
```

```
var(xg)
```

```
[1] 0.4405249
```

```
c(media_teorica = 4/3,
  varianza_teorica = 4/9)
```

media_teorica	varianza_teorica
1.3333333	0.4444444

20.7. Simulación Weibull

```
set.seed(2026)
k <- 2
eta <- 1000
xw <- rweibull(50000, shape = k, scale = eta)

media_w <- eta * gamma(1 + 1/k)
var_w <- eta^2 * (gamma(1 + 2/k) - gamma(1 + 1/k)^2)

c(media_empirica = mean(xw), media_teorica = media_w)
```

media_empirica	media_teorica
883.7981	886.2269

```
c(var_empirica = var(xw), var_teorica = var_w)
```

```
var_empirica  var_teorica
      214478.8      214601.8
```

20.8. Simulación Beta

```
set.seed(2026)
a <- 5
b <- 2
xb <- rbeta(50000, a, b)

c(media_empirica = mean(xb),
  media_teorica = a/(a+b))
```

```
media_empirica  media_teorica
      0.7145248      0.7142857
```

20.9. Comparación conceptual

Distribución	Soporte	Parámetros	Uso típico
Gamma	$(0, \infty)$	forma α , tasa λ	tiempos acumulados, cantidades positivas
Weibull	$[0, \infty)$	forma k , escala η	vida útil y confiabilidad
Beta	$(0, 1)$	α, β	proporciones y fracciones

20.10. Interactivo del capítulo

El interactivo permite elegir Gamma, Weibull o Beta y modificar sus parámetros mediante deslizadores.

Para cada distribución se muestran:

- la densidad;
- la media;
- la varianza;
- un intervalo de interés;
- el área de probabilidad dentro del intervalo.

En Weibull se muestra además el comportamiento cualitativo de la tasa de falla: decreciente, constante o creciente según el valor de k .

20.11. Actividad con GeoGebra

Construye una familia Weibull para distintos valores de k manteniendo fija la escala η . Representa simultáneamente la densidad y la función

$$h(x) = \frac{k}{\eta} \left(\frac{x}{\eta} \right)^{k-1}.$$

Compara $k = 0.6$, $k = 1$ y $k = 2$.

Después construye varias densidades Beta en $[0, 1]$ y observa cómo cambia la forma para:

$$(\alpha, \beta) = (1, 1), (2, 5), (5, 2), (0.5, 0.5), (5, 5).$$

20.12. Estrategia de selección del modelo

- Si la variable es positiva y representa un tiempo acumulado hasta varios eventos, considere Gamma.
- Si estudia tiempo de vida y necesita una tasa de falla flexible, considere Weibull.
- Si la variable es una proporción continua restringida a $[0, 1]$, considere Beta.

La decisión debe fundamentarse también en conocimiento del proceso, no sólo en ajuste gráfico.

20.13. Errores frecuentes

- Confundir `rate` y `scale` en la distribución Gamma.
- Suponer que Gamma y exponencial son distribuciones no relacionadas.
- Interpretar k de Weibull como escala en lugar de forma.
- Concluir que Weibull siempre tiene tasa de falla creciente.
- Utilizar Beta para una variable no restringida a $[0, 1]$ sin transformarla.
- Confundir los parámetros `shape1` y `shape2` de R.
- Interpretar valores de densidad como probabilidades puntuales.

20.14. Resumen

Gamma:

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}.$$

Weibull:

$$f(x) = \frac{k}{\eta} \left(\frac{x}{\eta} \right)^{k-1} e^{-(x/\eta)^k}.$$

Beta:

$$f(x) = \frac{x^{\alpha-1} (1-x)^{\beta-1}}{B(\alpha, \beta)}.$$

Casos particulares importantes:

$$\text{Gamma}(1, \lambda) = \text{Exp}(\lambda),$$

$$\text{Weibull}(1, \eta) = \text{Exp}(1/\eta),$$

$$\text{Beta}(1, 1) = U(0, 1).$$

20.15. Ejercicios

1. Sea $X \sim \text{Gamma}(3, 2)$. Calcula media y varianza.
2. Para la variable anterior, calcula $P(X < 2)$ y $P(X > 3)$ en R.
3. Una corriente de eventos tiene tasa 4 por hora. Modela el tiempo hasta el quinto evento y calcula su media.
4. Sea $X \sim \text{Weibull}(1.5, 800)$. Calcula la probabilidad de sobrevivir más de 1000 horas.
5. Para Weibull, explica el comportamiento de la tasa de falla cuando $k = 0.7$, $k = 1$ y $k = 2$.
6. Calcula media y varianza de una $\text{Beta}(4, 3)$.
7. Para $X \sim \text{Beta}(4, 3)$, calcula $P(X > 0.75)$.
8. Compara gráficamente $\text{Beta}(2, 5)$ y $\text{Beta}(5, 2)$ y explica la simetría entre ambas.
9. Simula 50 000 observaciones $\text{Gamma}(4, 3)$ y compara media y varianza empíricas con las teóricas.
10. Simula una $\text{Weibull}(2, 1000)$ y estima por frecuencia relativa $P(X > 1200)$.
11. **Reto** . Verifica numéricamente que $\text{Gamma}(1, \lambda)$ y $\text{Exp}(\lambda)$ producen la misma densidad.
12. **Reto** . Comprueba que $\text{Beta}(1, 1)$ coincide con la uniforme estándar.

20.16. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Ejecutar ejemplos y simulaciones de Gamma, Weibull y Beta.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir probabilidades, cuantiles, confiabilidad y simulaciones.
Interactivo	HTML / GeoGebra	Abrir recurso	Explorar parámetros, densidades, áreas y tasa de falla Weibull.

Material	Formato	Acceso	Propósito
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de las tres familias.

20.17. Referencias del capítulo

El tratamiento de las distribuciones Gamma, Weibull y Beta sigue la presentación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, ejercicios, simulaciones y código en R son originales; el enfoque computacional general toma como referencia Kerns (2010).

21 Variables aleatorias conjuntas, distribuciones marginales y condicionales

21.1. Objetivos de aprendizaje

Al finalizar este capítulo, el estudiante será capaz de:

- describir simultáneamente dos variables aleatorias mediante una distribución conjunta;
- construir e interpretar tablas de probabilidad conjunta para variables discretas;
- obtener distribuciones marginales a partir de una distribución conjunta;
- calcular distribuciones condicionales;
- trabajar con densidades conjuntas continuas mediante integrales dobles;
- identificar correctamente la región de soporte de una densidad bidimensional;
- obtener densidades marginales y condicionales;
- verificar independencia mediante la factorización de la distribución conjunta;
- utilizar R para organizar tablas conjuntas, calcular probabilidades y realizar simulaciones;
- interpretar visualmente dependencia e independencia mediante mapas de calor y regiones en el plano.

21.2. De una variable a dos variables

Hasta ahora hemos estudiado una variable aleatoria a la vez. Sin embargo, muchos problemas de ingeniería y ciencias requieren observar **dos magnitudes simultáneamente**.

Ejemplos:

- temperatura y humedad;
- tiempo de respuesta y número de solicitudes;
- diámetro y longitud de una pieza;
- concentración de dos contaminantes;
- número de fallas de dos subsistemas;

- voltaje de entrada y voltaje de salida.

Si X y Y se observan en el mismo experimento, la distribución conjunta permite estudiar no sólo cada variable por separado, sino también la forma en que se relacionan.

21.3. Variables aleatorias conjuntas discretas

Si X y Y son discretas, definimos la función de masa conjunta por

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

Debe satisfacer

$$p_{X,Y}(x, y) \geq 0$$

y

$$\sum_x \sum_y p_{X,Y}(x, y) = 1.$$

21.4. Ejemplo: dos subsistemas

Supongamos que X es el número de fallas observadas en un subsistema A y Y el número de fallas de un subsistema B durante un intervalo. La distribución conjunta es

$X \backslash Y$	0	1	2	Total
0	0.20	0.10	0.05	0.35
1	0.15	0.20	0.10	0.45
2	0.05	0.10	0.05	0.20
Total	0.40	0.40	0.20	1.00

Cada celda representa una probabilidad conjunta. Por ejemplo,

$$P(X = 1, Y = 0) = 0.15.$$

21.5. Probabilidad de una región discreta

Para calcular

$$P(X \geq 1, Y \leq 1),$$

sumamos las celdas compatibles:

$$P(X \geq 1, Y \leq 1) = 0.15 + 0.20 + 0.05 + 0.10 = 0.50.$$

La idea general es

$$P((X, Y) \in A) = \sum_{(x, y) \in A} p_{X, Y}(x, y).$$

21.6. Distribuciones marginales discretas

La distribución marginal de X se obtiene sumando sobre todos los valores de Y :

$$p_X(x) = \sum_y p_{X, Y}(x, y).$$

Análogamente,

$$p_Y(y) = \sum_x p_{X, Y}(x, y).$$

En una tabla conjunta, las marginales corresponden a los totales por fila y columna.

Para el ejemplo:

$$p_X(0) = 0.35, \quad p_X(1) = 0.45, \quad p_X(2) = 0.20,$$

y

$$p_Y(0) = 0.40, \quad p_Y(1) = 0.40, \quad p_Y(2) = 0.20.$$

21.7. Cálculo de marginales en R

```
P <- matrix(c(
  0.20, 0.10, 0.05,
  0.15, 0.20, 0.10,
  0.05, 0.10, 0.05
), nrow = 3, byrow = TRUE)

rownames(P) <- paste0("X=", 0:2)
colnames(P) <- paste0("Y=", 0:2)

P
```

	Y=0	Y=1	Y=2
X=0	0.20	0.1	0.05
X=1	0.15	0.2	0.10
X=2	0.05	0.1	0.05

```
rowSums(P)  # marginal de X
```

	X=0	X=1	X=2
	0.35	0.45	0.20

```
colSums(P)  # marginal de Y
```

	Y=0	Y=1	Y=2
	0.4	0.4	0.2

```
sum(P)      # debe ser 1
```

```
[1] 1
```

21.8. Distribuciones condicionales discretas

Si $P(Y = y) > 0$, definimos

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

De manera análoga,

$$p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}.$$

21.9. Ejemplo condicional

Queremos obtener la distribución de X sabiendo que $Y = 1$.

Como

$$P(Y = 1) = 0.40,$$

entonces

$$P(X = 0 | Y = 1) = \frac{0.10}{0.40} = 0.25,$$

$$P(X = 1 | Y = 1) = \frac{0.20}{0.40} = 0.50,$$

$$P(X = 2 | Y = 1) = \frac{0.10}{0.40} = 0.25.$$

La distribución condicional vuelve a sumar 1.

En R:

```
py <- colSums(P)
P[, "Y=1"] / py["Y=1"]
```

	X=0	X=1	X=2
Y=0	0.25	0.50	0.25

21.10. Independencia de variables aleatorias discretas

X y Y son independientes si para todo par (x, y) ,

$$p_{X,Y}(x, y) = p_X(x)p_Y(y).$$

Si esta igualdad falla para siquiera un par con probabilidad relevante, las variables no son independientes.

21.11. Verificación en R

```
px <- rowSums(P)
py <- colSums(P)
P_ind <- outer(px, py)

P
```

	Y=0	Y=1	Y=2
X=0	0.20	0.1	0.05
X=1	0.15	0.2	0.10
X=2	0.05	0.1	0.05

```
P_ind
```

	Y=0	Y=1	Y=2
X=0	0.14	0.14	0.07
X=1	0.18	0.18	0.09
X=2	0.08	0.08	0.04

```
P - P_ind
```


	Y=0	Y=1	Y=2
X=0	0.06	-0.04	-0.02
X=1	-0.03	0.02	0.01
X=2	-0.03	0.02	0.01

```
max(abs(P - P_ind))
```

```
[1] 0.06
```

Si el máximo es cero salvo error numérico, la tabla factoriza y las variables son independientes.

21.12. Independencia y condicionamiento

Si X y Y son independientes y $p_Y(y) > 0$, entonces

$$p_{X|Y}(x | y) = p_X(x).$$

Es decir, conocer Y no cambia la distribución de X .

Esta es una de las interpretaciones más importantes de independencia.

21.13. Función de distribución conjunta

Para dos variables aleatorias cualesquiera definimos

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y).$$

En el caso discreto,

$$F_{X,Y}(x, y) = \sum_{u \leq x} \sum_{v \leq y} p_{X,Y}(u, v).$$

Las CDF marginales pueden recuperarse mediante límites:

$$F_X(x) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y),$$

$$F_Y(y) = \lim_{x \rightarrow \infty} F_{X,Y}(x, y).$$

21.14. Variables aleatorias conjuntas continuas

Si (X, Y) es un vector aleatorio continuo, una densidad conjunta $f_{X,Y}(x, y)$ debe satisfacer

$$f_{X,Y}(x, y) \geq 0$$

y

$$\iint_{\mathbb{R}^2} f_{X,Y}(x, y) \, dx \, dy = 1.$$

Para una región A del plano,

$$P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) \, dx \, dy.$$

En dos dimensiones, comprender la **región de integración** es tan importante como conocer la fórmula de la densidad.

21.15. Ejemplo continuo sobre una región triangular

Considere

$$f_{X,Y}(x, y) = 2,$$

sobre la región

$$0 < y < x < 1,$$

y cero fuera de ella.

La región es el triángulo debajo de la recta $y = x$ y encima del eje x dentro del cuadrado unitario.

Verificamos la normalización:

$$\int_0^1 \int_0^x 2 \, dy \, dx = \int_0^1 2x \, dx = 1.$$

21.16. Probabilidad sobre una subregión

Calculemos

$$P(X < 0.8, Y < 0.3).$$

Debido al soporte triangular, debemos dividir la integración según la relación entre x y 0.3:

$$P(X < 0.8, Y < 0.3) = \int_0^{0.3} \int_0^x 2 \, dy \, dx + \int_{0.3}^{0.8} \int_0^{0.3} 2 \, dy \, dx.$$

La geometría del soporte evita integrar sobre zonas donde la densidad es cero.

21.17. Densidades marginales

Para obtener la marginal de X , integramos respecto de y :

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dy.$$

En el ejemplo triangular, para $0 < x < 1$,

$$f_X(x) = \int_0^x 2 \, dy = 2x.$$

Para Y ,

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx .$$

Como para un y fijo se tiene $y < x < 1$,

$$f_Y(y) = \int_y^1 2 dx = 2(1 - y), \quad 0 < y < 1.$$

Observe que ambas marginales están normalizadas:

$$\int_0^1 2x dx = 1,$$

$$\int_0^1 2(1 - y) dy = 1.$$

21.18. Densidades condicionales

Si $f_X(x) > 0$, la densidad condicional de Y dado $X = x$ es

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

Para nuestro ejemplo,

$$f_{Y|X}(y | x) = \frac{2}{2x} = \frac{1}{x},$$

para

$$0 < y < x.$$

Por tanto, dado $X = x$, la variable Y se distribuye uniformemente en $(0, x)$.

De forma análoga,

$$f_{X|Y}(x | y) = \frac{2}{2(1-y)} = \frac{1}{1-y},$$

para

$$y < x < 1.$$

21.19. Independencia en el caso continuo

Si X y Y tienen densidades, son independientes cuando

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

para todos los puntos relevantes, salvo posibles excepciones de área cero.

En el ejemplo triangular,

$$f_X(x)f_Y(y) = 4x(1-y),$$

que no coincide con la densidad conjunta constante 2. Además, el soporte triangular no es un rectángulo producto. Por tanto, las variables son dependientes.

21.20. Ejemplo continuo independiente

Sea

$$X \sim U(0, 1), \quad Y \sim U(0, 2),$$

independientes. Entonces

$$f_X(x) = 1, \quad 0 < x < 1,$$

$$f_Y(y) = \frac{1}{2}, \quad 0 < y < 2,$$

y

$$f_{X,Y}(x,y) = \frac{1}{2}$$

sobre el rectángulo

$$0 < x < 1, \quad 0 < y < 2.$$

La región de soporte sí es producto de los soportes marginales.

21.21. Cálculos bidimensionales en R

Para el ejemplo triangular podemos definir

```

fxy <- function(x, y) {
  ifelse(x > 0 & x < 1 & y > 0 & y < x, 2, 0)
}

fx <- function(x) ifelse(x > 0 & x < 1, 2*x, 0)
fy <- function(y) ifelse(y > 0 & y < 1, 2*(1-y), 0)

```

La probabilidad de la subregión anterior puede calcularse mediante integración iterada:

```

p1 <- integrate(function(x) 2*x, 0, 0.3)$value
p2 <- integrate(function(x) rep(2*0.3, length(x)), 0.3, 0.8)$value
p1 + p2

```

```
[1] 0.39
```

21.22. Simulación de una distribución conjunta discreta

Podemos simular directamente una tabla conjunta convirtiendo las celdas en categorías.

```

set.seed(2026)

coords <- expand.grid(X = 0:2, Y = 0:2)
prob <- as.vector(t(P))

idx <- sample(seq_len(nrow(coords)),
              size = 50000,
              replace = TRUE,
              prob = prob)

sim <- coords[idx, ]

prop.table(table(sim$X, sim$Y))

```

	0	1	2
0	0.19920	0.14806	0.05204
1	0.09978	0.20070	0.09914
2	0.05140	0.09962	0.05006

```
prop.table(table(sim$X))
```

	0	1	2
	0.39930	0.39962	0.20108

```
prop.table(table(sim$Y))
```

	0	1	2
	0.35038	0.44838	0.20124

Las frecuencias empíricas deben acercarse a la distribución conjunta y a sus marginales.

21.23. Simulación del ejemplo triangular

Una manera eficiente de simular la densidad

$$f_{X,Y}(x,y) = 2, \quad 0 < y < x < 1,$$

es aprovechar sus marginales y condicionales.

Como

$$f_X(x) = 2x,$$

la CDF marginal es

$$F_X(x) = x^2,$$

y por transformada inversa

$$X = \sqrt{U_1}, \quad U_1 \sim U(0,1).$$

Dado $X = x$, $Y \mid X = x \sim U(0, x)$, así que


$$Y = XU_2,$$

con $U_2 \sim U(0,1)$ independiente de U_1 .

```
set.seed(2026)
n <- 20000
u1 <- runif(n)
u2 <- runif(n)
X <- sqrt(u1)
Y <- X * u2

plot(X, Y, pch = 16, cex = 0.35,
      xlab = "X", ylab = "Y",
      main = "Simulación sobre soporte triangular")
abline(0, 1, lty = 2)
```



Simulación sobre soporte triangular



21.24. Visualización mediante mapa de calor

Para una distribución discreta conjunta, un mapa de calor permite identificar rápidamente dónde se concentra la probabilidad.

```
image(x = 0:2, y = 0:2, z = P,  
      xlab = "Y", ylab = "X",  
      main = "Mapa de calor de la PMF conjunta")
```



Un patrón concentrado cerca de una diagonal puede indicar asociación, mientras que una tabla que factoriza como producto de marginales representa independencia.

21.25. Interactivo del capítulo

El interactivo del capítulo utiliza una tabla conjunta 3×3 con marginales fijas. Un deslizador modifica un parámetro de asociación sin cambiar dichas marginales.

El estudiante puede observar simultáneamente:

- la PMF conjunta como mapa de calor;
- las marginales de X y Y ;
- una distribución condicional seleccionada;
- la tabla que correspondería a independencia, $p_X(x)p_Y(y)$;
- la diferencia entre la distribución real y la independiente;
- un indicador numérico de separación respecto de la independencia.

Esto permite ver una idea crucial: **dos distribuciones pueden tener exactamente las mismas marginales y, sin embargo, estructuras conjuntas muy distintas.**

21.26. Actividad con GeoGebra

21.27. Parte A: soporte continuo

Dibuja el cuadrado unitario y la región

$$0 < y < x < 1.$$

Utiliza un deslizador $c \in (0, 1)$ y representa la recta vertical $x = c$. La sección vertical de la región tiene longitud c , por lo que

$$f_X(c) = 2c.$$

Después usa una recta horizontal $y = d$. La sección horizontal tiene longitud $1 - d$, de modo que

$$f_Y(d) = 2(1 - d).$$

Esta construcción ofrece una interpretación geométrica directa de la marginalización.

21.28. Parte B: condicionamiento

Fija $X = c$. El segmento posible para Y es

$$0 < Y < c.$$

Observa que la densidad condicional sobre ese segmento es uniforme:

$$f_{Y|X}(y | c) = \frac{1}{c}.$$

21.29. Estrategia de resolución

Ante un problema con dos variables:

1. identifica si la distribución conjunta es discreta o continua;
2. determina con cuidado el soporte conjunto;
3. verifica normalización;
4. para marginalizar, suma o integra sobre la otra variable;
5. para condicionar, divide la conjunta entre la marginal correspondiente;
6. para independencia, compara la conjunta con el producto de marginales;
7. en el caso continuo, dibuja primero la región de integración;
8. interpreta el resultado: marginalizar elimina información sobre una variable; condicionar incorpora información sobre ella.

21.30. Errores frecuentes

- Confundir una probabilidad conjunta con una probabilidad condicional.
- Obtener marginales dividiendo en lugar de sumar o integrar.
- Olvidar normalizar una distribución condicional.
- Integrar sobre un rectángulo cuando el soporte real es triangular u otra región.
- Concluir independencia sólo porque las marginales parecen sencillas.
- Creer que conocer las dos marginales determina la distribución conjunta.
- En variables continuas, interpretar $f_{X,Y}(x, y)$ como una probabilidad puntual.

21.31. Resumen

Para variables discretas:

$$p_X(x) = \sum_y p_{X,Y}(x, y),$$

$$p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}.$$

Para variables continuas:

$$f_X(x) = \int f_{X,Y}(x, y) dy,$$

$$f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}.$$

La independencia se expresa mediante

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

o, en el caso continuo,

$$f_{X,Y}(x, y) = f_X(x)f_Y(y).$$

21.32. Ejercicios

1. Para la tabla conjunta del capítulo, calcula $P(X = 2, Y \geq 1)$.
2. Obtén todas las distribuciones condicionales $p_{X|Y}(x | y)$.
3. Verifica si X y Y son independientes en esa tabla.
4. Construye una tabla conjunta independiente utilizando $p_X = (0.2, 0.5, 0.3)$ y $p_Y = (0.4, 0.35, 0.25)$.
5. Para $f(x, y) = 2$ sobre $0 < y < x < 1$, calcula $P(Y < 0.25)$.
6. Para la misma densidad, calcula $P(X > 0.6)$ mediante la marginal de X .
7. Obtén $f_{Y|X}(y | 0.8)$ y calcula $P(Y < 0.3 | X = 0.8)$.
8. Explica por qué el soporte triangular prueba que X y Y no pueden ser independientes en el ejemplo continuo.
9. Simula 100 000 pares del ejemplo triangular y compara histogramas marginales con $f_X(x) = 2x$ y $f_Y(y) = 2(1 - y)$.
10. Construye en R una tabla conjunta con marginales prefijadas y modifica la dependencia sin alterar esas marginales.
11. **Reto** . Demuestra que si X y Y son independientes, entonces $F_{X,Y}(x, y) = F_X(x)F_Y(y)$.
12. **Reto** . Propón dos distribuciones conjuntas diferentes que tengan las mismas marginales.

21.33. Materiales complementarios del capítulo

Material	Formato	Acceso	Propósito
Cuaderno de Google Colab	Notebook interactivo (R)	Abrir en Colab	Explorar tablas conjuntas, marginales, condicionales, independencia y simulación.
Cuaderno de R	R Markdown	Abrir cuaderno R	Reproducir cálculos y visualizaciones bidimensionales en R/RStudio.
Interactivo	HTML / GeoGebra	Abrir recurso	Visualizar dependencia, marginales y distribuciones condicionales.
Presentación	PDF / PPT	Próximamente	Se incorporará cuando se proporcionen los enlaces.
Video	Video	Próximamente	Explicación audiovisual complementaria.
Infografía	Imagen / PDF	Próximamente	Síntesis visual de distribución conjunta, marginalización y condicionamiento.

21.34. Referencias del capítulo

El tratamiento de distribuciones conjuntas, marginales, condicionales e independencia sigue la presentación estándar de Walpole et al. (2012), Devore (2016), Montgomery y Runger (2018) y Johnson (2018). Los ejemplos, ejercicios, simulaciones y código en R son originales; el enfoque computacional general toma como referencia Kerns (2010).

Referencias

Devore, Jay L. 2016. *Probability and Statistics for Engineering and the Sciences*. 9.^a ed. Cengage Learning.

Johnson, Richard A. 2018. *Miller & Freund's Probability and Statistics for Engineers*. 9.^a ed. Pearson.

Kerns, G. Jay. 2010. *Introduction to Probability and Statistics Using R*. 1.^a ed.

Montgomery, Douglas C., y George C. Runger. 2018. *Applied Statistics and Probability for Engineers*. 7.^a ed. Wiley.

Walpole, Ronald E., Raymond H. Myers, Sharon L. Myers, y Keying Ye. 2012. *Probabilidad y estadística para ingeniería y ciencias*. 9.^a ed. Pearson.